

第 2 讲

LLM 辅助文献、 推导与问题定义

AI 赋能的物理学研究：工具、方法与前沿

AI 提出候选，人类研究者确立结论。

AI proposes candidates; the human researcher establishes the conclusion.

周毅

中国科学院物理研究所

2026 年 9 月



LLM 的解释如何仍然经得起核查？

**LLM 能概括论文、解释公式、补全推导——
如何看清输出从何而来，又如何确认理解
仍建立在原文证据与可检验推理之上？**

本讲立场

LLM 通过有限上下文中的下一 token 预测生成候选；检索和工具调用提供外部通道。论文原文、符号定义、模型假设、独立基准和反例决定结论是否成立。

AI 提出候选，人类研究者确立结论。

第 1 讲回顾：候选只有经过审计才成为结论

开场环节：4 分钟

1. AI 输出是**候选**，不是证据。
2. 问题定义、基线和验收标准必须先于计算。
3. 量纲正确、曲线尖锐或代码可运行，都不足以证明物理结论。
4. 一维最近邻零场 Ising 模型在 $T > 0$ 没有相变；转移矩阵给出独立的解析反证。
5. 好的项目不仅报告“发现了什么”，还应说明什么可靠、什么不确定，以及什么会推翻自己的结论。

课堂行动 逐句回顾：每句话针对第 1 讲的哪个环节？哪一句今天会再次用到？

验证链不变——候选 → 审计 → 结论；今天把它用于文献阅读、公式审计与问题定义。

本讲按一条证据链组织

90 分钟



共同公式案例

量子力学的**变分原理**：上界、驻点与基态不是同一个结论。

课堂产出

一张“主张-证据-边界-位置”审计卡，以及一项可证伪的最小任务。

90 分钟的每个环节都有可追溯的课堂产出。

本讲交付可追溯的阅读与问题定义


1. 区分 token、上下文、注意力、下一 token 概率、采样、检索和工具调用。
2. 说明为何注意力权重和展示的中间推理本身既非解释，也不证明结论正确。
3. 将论文结论拆成可定位的**主张、证据、假设与边界**。
4. 使用 LLM 辅助概念解释和阅读定位，但不把其摘要、引文或推导直接当作证据。
5. 审计公式的符号、定义域、近似、量纲、极限、对称性、特例与反例。
6. 从阅读记录形成可证伪主张、独立基准（oracle，即不依赖待审计输出的核查基准）与最小可执行任务。

本讲产出：一张可追溯的阅读卡，和带 oracle 的可证伪问题定义。

证据问题 1

LLM 输出由哪些环节形成？

从文本输入到生成输出是一条条件概率链



概念边界

Transformer 是架构，下一 token 预测是这里讨论的生成目标。模型生成内容、检索结果与工具执行结果、经人工核查的科学结论必须分别记录。

自回归 LLM 逐步预测下一 token，而非从事实数据库检索答案。

token 不是“词”，上下文也不是无限记忆

tokenization

tokenizer 将文本切分为 token 并映射为编号；
token 可能是汉字、词的一部分、标点或代码片段。

示意： $E[\psi]$ 可能被切成 $E / [/ \psi /]$ 等多个 token。

有限上下文

系统指令、用户问题、历史对话、论文片段、检索结果和工具执行结果共同占用窗口；超出长度后需要截断、压缩或重新选择。

常见误解

“材料已放入上下文” $\neq$ “模型已完整、正确地使用材料”。

课堂行动 查看对话输入：区分指令、原文、检索、工具与模型生成内容。

token 与上下文决定模型“看到什么”，不保证模型“用对什么”。

注意力按当前输入混合信息

混合权重本身不是解释

$$h'_i = \sum_j \alpha_{ij} v_j, \quad \alpha_{ij} \geq 0,$$
$$\sum_j \alpha_{ij} = 1.$$

v_j 是第 j 个位置的值向量, h'_i 是位置 i 混合后的新表示; α_{ij} 表示某层 (layer) 某头 (head) 在本次前向计算中的信息混合系数。特邀讲座 (第 2.5 讲) 先介绍 Transformer 架构与 Agent 使用经验; 正式的 Q, K, V 、多头结构、位置编码和掩码留到第 6 讲。

不能直接推出

- 因果贡献
- 特征重要性
- 模型“真正的理由”
- 物理关联函数
- 输出正确性

解释性主张仍需消融、反事实受控替换、独立基准与物理检验。

下一 token 概率经解码后才成为具体文本

$$p(z_{t+1} = j \mid z_{\leq t}) = \frac{e^{\ell_j}}{\sum_k e^{\ell_k}}.$$

循环生成

选择一个 token $\rightarrow$ 追加到上下文 $\rightarrow$ 再预测下一 token, 直到停止。

解码选择

- 贪心：取最大概率
- 温度：改变分布尖锐度
- top- k /top- p ：限制候选集合

虚构的错误结论（故意设置）

低温度或多次得到同一回答 $\Rightarrow$ 回答已经过事实核查。二者只改变或反映当前模型下的输出概率。

解码只从概率分布中选择 token, 不提供事实核查。

检索和工具调用把外部结果写回上下文

检索增强生成

问题 → 检索论文/网页/本地资料 → 返回片段与元数据 → 模型组织回答。

检索风险

来源质量、版本错配、召回遗漏、片段不支持主张或断章取义。

工具调用

模型生成工具名与参数 → 外部程序执行搜索、计算、代码或数据库操作 → 返回结果。

工具风险

工具选错、参数错误、权限越界、环境不一致、执行成功但物理设置错误。

检索结果和工具执行结果更容易追溯，但仍需核查来源、输入、参数、环境与解释。

四类内容必须在研究记录中分开

流程位置： 原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

内容	可提供什么	最低核查要求
模型生成 检索结果	解释、候选推导、代码或检索词。 可定位片段、来源和元数据。	标记为候选；返回原文、公式或独立基准。 打开原始来源；核对版本、上下文和支持范围。
计算/代码工具	给定输入与环境下的执行结果。	保存参数、单位、代码、依赖、输出与独立测试。
人工结论	经选择、推导与核查后的研究判断。	明确证据链、适用边界、不确定度和责任人。

四类内容分开标记，每条结论才能追溯证据来源。

课堂行动 教师演示：对一段真实 AI 回答逐句标注所属类型，学生口头预判下一句。

长推理文本既不代表内部机制，也不构成证明

虚构的等式：两条需要主动拒绝的说法（故意：把表面特征当作证据）

推理文字更长 = 推理更正确

注意力权重图清晰 = 物理机制已解释

可接受的证据

检查可复算的中间结果、工具输入输出、原始来源、反例、解析极限和独立数值基准；不根据语气、自我反思措辞或解释长度判断可靠性。

后续课程分工

第 2.5 讲（特邀）：Transformer 架构初步与 Agent 使用经验；第 4.5 讲：样本、特征、损失、梯度与最小训练链；第 5 讲：完整反向传播、自动微分与科学验证；第 6 讲：注意力/Transformer 架构与对称性；第 7 讲：自回归分布与生成采样。

中间推理文本仍是模型输出；可靠性只看可验证步骤与外部证据。

证据问题 2

一条论文主张何以可追溯？

什么是有效的文献阅读？

一个可操作的定义

本讲的答案：有效阅读是**能产出可复核记录**的阅读。四条可操作判据：

1. **能定位**：每个主张都能标明原文位置；
2. **能区分**：分得清原文直接陈述、自己完成的推导与待核查的猜测；
3. **能质疑**：说得出结论的边界、一个反例方向和一个待核查问题；
4. **能转化**：读完能产出一个可证伪的下一步任务，而不是“我懂了”。

有效阅读的产出不是“理解了”，而是一份别人能复核的记录。

不同材料承担不同角色

材料可以互补，不能任意替代

材料	适合做什么	不能单独证明什么
原始论文、补充材料、数据与代码	定位作者主张、公式定义、实验或数值设置与结论边界。	未写出的机制、未报告的误差控制或作者未检验过的外推。
综述、教材与可靠数据库	建立背景、术语和已知基准；寻找原始文献线索。	某一篇论文的具体实现、数据处理或精确表述。
LLM 摘要、解释和问答	生成阅读线索、翻译术语、比较表述、列待核查问题。	引文真实性、公式正确性、原文结论、数值结果或作者意图。
自己的笔记与推导	保留理解路径、标明缺口、设计验证与问题定义。	没有来源和检验支撑的事实性结论。

LLM 是阅读与推理的助手，不是原文证据的替身。

流畅的 LLM 输出不能替代原文证据

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

三类常见混淆

- 一条“很像真的”参考文献 $\Rightarrow$ 引用已核查。
- 通俗复述一个结论 $\Rightarrow$ 已理解模型假设和定量证据。
- 多个 AI 输出一致 $\Rightarrow$ 获得独立验证。


实际遗漏

- 引文可能不存在、错配或版本不对。
- 原文的符号定义、模型边界和误差控制可能缺失。
- 输出可能来自同一训练语料或同一提示链。

相互一致不等于相互独立。

一条可审计的阅读记录必须回答四个问题

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务



最小闭环

任何准备写入报告或用于后续计算的结论，都应附带原文位置、模型假设、至少一项支持证据，以及一项尚未解决的核查问题。

可审计的阅读记录必须同时写明主张、证据、边界和原文位置。

阅读卡把“我看懂了”变成可复核记录

阅读卡示例

主张：在给定模型与参数范围内，某变分 ansatz 的能量接近基态能量。

证据：正文能量比较图、优化设置，以及与小系统精确对角化的对照。

边界：只报告有限尺寸、特定参数和给定网络结构；不能直接外推到热力学极限。

位置：正文第 3 节、图 2、式 (5) 及补充材料的训练细节。

下一步核查：确认能量误差定义；检查基准独立性、误差条、尺寸和随机种子。

它支持什么？


在**这一模型**、**这一参数范围**、**这一 ansatz**下，能量误差可能足够小。

它还不足以支持什么？

机制解释、其他 Hamiltonian、热力学极限或未报告的误差控制。

阅读卡只支持限定范围内的误差主张，不能外推。

LLM 辅助阅读应闭合为一条证据链



回查规则

来源缺失、符号冲突或前提不足时，返回原文定位或修改调用规范，不继续扩写未经核查的解释。

先定位，再解释；先写假设，再写推导；先定义验收，再扩展阅读。

课堂操作：为一条结论建立最小阅读卡

6 分钟：现场调用 + 全班共填

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

现场演示

教师现场对 NQS 论文摘要 (arXiv:1606.02318) 发两次真实调用——先宽泛提问，再按调用规范提问；全班对照输出填写活动卡 A (AI4Phys-2-auditcard.pdf)。

课堂行动 全班共填：主张、原文位置、一个直接证据、两个假设或边界、一个待核查问题。

1. 不评价论文“看起来是否先进”，只判断记录能否由同学追溯。
2. 结论必须是完整句子，而不是“神经网络量子态”之类的主题词。
3. 原文位置至少精确到页码、图号、公式号、段落或代码版本之一。
4. 本环节只完成阅读卡，不提前做公式审计与问题定义。

同学能据此追溯原文，才算一张阅读卡。

证据问题 3

**一次 AI 调用如何才算
可以验收？**

提示词应是单次 AI 调用规范

不是“让模型更会说话”的技巧

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

字段	需要明确的内容
来源与位置	论文题目、版本、页码、公式号或原文片段；不要要求模型猜测来源。
目标	解释概念、逐步核对推导、比较定义，还是提出待核查问题？
模型与符号	自由度、Hamiltonian、单位制、边界条件、符号定义和已知近似。
约束	不编造引用；将事实、推导和猜测分开；信息缺失时明确提问。
输出格式	主张-证据-边界表、逐行推导、符号表、反例或待核查清单。
验收条件	量纲、极限、对称性、已知特例、独立基准（oracle）与不确定度。

提示不写边界和验收条件，输出再流畅也无从判定是否适用。

一份可审计的单次论文阅读调用

建议模板

来源：我正在阅读 {论文题目/版本} 的第 {页码或公式号}，原文是 {粘贴片段}。

目标：请解释该段要回答的物理问题，并逐一说明符号 {...} 的定义。

模型与假设：体系是 {...}；已知近似、边界条件和单位制是 {...}。

请求：请分为“原文直接陈述”“由公式可推出”“需要额外核查”三栏。

验收：指出至少两个待检查的极限、对称性、特例或独立基准；不要提供无法定位的引用。

不确定性：若原文缺少关键条件，请列出需要返回原文确认的问题。

任务规范要求模型标明不确定性，而不是用流畅语言填补空白。

输出必须按证据类型分层

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

原文直接陈述

可定位的事实、定义、数值结果和作者的限定表述。

由公式可推出

在明确前提下的代数推导、极限或逻辑后果。

需要额外核查

缺失的定义、未验证的类比、外推、引用和机制解释。

事实、推导与猜测不能混写。

解释再长，也不构成证明

需要保留的不确定性

不要把流畅语言误读为推理证据

LLM 可以写出很长的中间解释，但这些文字既不反映模型的内部机制，也不构成正确的物理证明。

1. 标出原文直接写出的事实。
2. 标出自己或 AI 根据明确前提完成的推导。
3. 标出尚待核查的猜测、类比或后续任务。
4. 对每一条外部引用返回 DOI、原文或可靠数据库核查。

保留“不知道什么”是研究记录的一部分。

课堂操作：把宽泛提问改写成调用规范

5 分钟：3 分钟改写 + 2 分钟现场跑

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

宽泛提问

“请解释这篇论文，并告诉我它的结论是否正确。”

可验收提问

指定页码和公式；要求列符号、假设和三类证据；指出两个可检查的极限或基准；缺信息时返回问题而不是猜测。

课堂行动 独立改写一条常用提示；教师随后把一条学生规范真实发给模型，与宽泛提问的输出并排对比。

可验收的提问自带来源、输出格式与验收条件。

证据问题 4

一个公式结论如何经受 审计？

变分原理的结论首先依赖明确前提

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

设 H 为自伴算符，其谱的下确界为 E_0 （基态能量）；试探态 $|\psi\rangle$ 属于 H 的定义域且不为零：

$$E[\psi] = \frac{\langle \psi | H | \psi \rangle}{\langle \psi | \psi \rangle} \geq E_0.$$

审计前提

- H 自伴
- 谱下有界
- ψ 属于定义域
- $\langle \psi | \psi \rangle \neq 0$

共同案例参考：D. J. Griffiths and D. F. Schroeter, *Introduction to Quantum Mechanics*, 变分原理章节。

上界不来自公式外形，而来自算符、态和谱满足的条件。

谱分解证明的是能量上界

$$H|n\rangle = E_n|n\rangle, \quad E_n \geq E_0,$$
$$|\psi\rangle = \sum_n c_n|n\rangle.$$

$$E[\psi] = \frac{\sum_n |c_n|^2 E_n}{\sum_n |c_n|^2} = \sum_n p_n E_n,$$

$$p_n = \frac{|c_n|^2}{\sum_m |c_m|^2}, \quad p_n \geq 0, \quad \sum_n p_n = 1.$$

$E[\psi]$ 是本征能量的加权平均，因此不小于 E_0 ；连续谱由谱测度给出相同逻辑。

达到上界等号需要态完全落在基态子空间

非简并基态

$$E[\psi] = E_0 \iff |\psi\rangle \propto |0\rangle.$$

简并基态

$E[\psi] = E_0$ 当且仅当 $|\psi\rangle$ 完全落在基态子空间中。

“能量接近基态” 不等于 “态已是基态”：精度与证据要求不同。

驻值条件与全局最小条件不是同一句话

归一化约束下，引入 Lagrange 乘子 ε ：

$$\mathcal{L}[\psi, \varepsilon] = \langle \psi | H | \psi \rangle - \varepsilon (\langle \psi | \psi \rangle - 1).$$

$$\delta \mathcal{L} = 0 \quad \implies \quad H|\psi\rangle = \varepsilon|\psi\rangle.$$

正确逻辑

驻点可以是极小、极大或鞍点 (saddle point)；激发态同样满足 $\delta \mathcal{L} = 0$ 。区分基态与其他驻点需要能量比较或二阶条件，而不是驻值条件本身。

补充

左乘 $\langle \psi |$ 可得 $\varepsilon = E[\psi]$ 。

每个本征态都是驻点，但只有取得全局最小的驻点才对应基态。

虚构的错误 AI 推理（故意：把必要条件当充分条件）

红色标记逻辑跳步

错误推理

“由 $\delta E[\psi] = 0$ 可知 ψ 是本征态；又因为变分原理给出 $E[\psi] \geq E_0$ ，所以任意驻点都是基态。”

错误在哪里？


不等式只说明所有试探态的能量不低于 E_0 ；它不把任意本征值变成 E_0 。推理遗漏了**全局最小**这个条件。

一个有效反例足以证伪“任意驻点都是基态”。

二能级模型是审计“驻点即基态”的最小 oracle

$$H = \begin{pmatrix} 0 & 0 \\ 0 & \Delta \end{pmatrix}, \quad \Delta > 0,$$

$$|\psi(\theta)\rangle = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix}, \quad E(\theta) = \Delta \sin^2 \theta.$$



$\theta = \pi/2$ 满足 $dE/d\theta = 0$ ，但对应激发态而非基态。

课堂核查：优化停止不能证明已经找到基态

4 分钟，两人一组 + 现场提问

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

1. 哪些 θ 给出全局最小？哪些给出局部最大？
2. 若优化程序停在 $\theta = \pi/2$ ，它满足驻值条件吗？满足变分上界吗？
3. 仅报告“梯度已收敛”能否证明找到了基态？
4. 还需要什么独立检查：多初值、精确对角化、误差条，还是参数扫描？

课堂行动 两人一组：用二能级模型写出一条错误主张和一个 oracle，并写出用 oracle 证伪该主张的计算。

梯度收敛只说明到达驻点；基态判定需要独立 oracle。

公式审计卡应覆盖逻辑、反例与实现

流程位置： 原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

审计项目	对变分原理要问什么	可复核依据
符号与定义域	H 是否自伴？ ψ 是否非零且属于定义域？	原文定义、教材定理、算符域说明。
归一化与尺度	为什么 $E[\psi]$ 有分母？	$\psi \rightarrow \alpha\psi$ 后能量不变。
逻辑类型	上界、等式、驻值条件，还是经验观察？	谱分解、变分计算或数值反例。
等号条件	何时达到 E_0 ？基态是否简并？	基态子空间与系数条件。
反例与基准	最小模型能否推翻看似合理的推论？	二能级矩阵、ED 或解析极限。
数值实现	停止条件、采样误差和 ansatz 偏差如何区分？	多初值、精确基准、误差条和扫描。

公式审计先问条件、定义和逻辑类型，再问推导是否流畅。

证据问题 5

如何把阅读转为可证伪问题？

一个最小任务必须有主张、oracle 与验收

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → [可证伪任务](#)

对有限维 Hamiltonian $H(g)$ 与参数化试探态 $|\psi_\theta(g)\rangle$:

问题

在 $g \in [0, 2]$ 的给定网格上，参数化试探态能否将变分能量 $E_\theta(g)$ 逼近精确基态能量 $E_0(g)$?

可证伪主张

对每个规定的 g ,

$$0 \leq E_\theta(g) - E_0(g) \leq \varepsilon.$$

独立基准与验收

oracle: 有限维矩阵的精确对角化给出 $E_0(g)$ 。

报告网格、初值、停止条件、能量误差、随机种子和失败点。

“优化器收敛”不是“已经得到基态”的同义词。

从宽泛兴趣到可执行研究问题

宽泛表述

“我想用 LLM 阅读一篇关于神经网络量子态的论文。”

可执行表述

定位变分能量定义和优化目标的原文位置；列出 ansatz、采样方式和 Hamiltonian 假设；用有限系统精确对角化作 oracle，检查报告的能量误差是否满足容差 (tolerance)；说明比较不能证明哪些更大系统或热力学极限结论。

可证伪条件

若关键公式无法在原文定位，符号定义与实现不一致，或有限基准误差超出容差，则不能接受“该方法在此设置下达到预期精度”的主张。

可执行表述必须包含原文定位、假设、oracle、容差与外推边界。

课堂收束：把审计卡转成问题定义卡

4 分钟：独立填写后互检

流程位置：原文定位 → 调用规范 → 候选输出 → 证据分层 → 物理审计 → 阅读卡 → 可证伪任务

使用前面完成的阅读卡与公式审计结果，不重新概括整篇论文；填写课堂活动卡 B 部分 AI4Phys-2-auditcard.pdf。

必须写出

1. 一句可证伪主张；
2. 一个独立 oracle 或最小基线，以及它能排除的错误主张。

还要写出

3. 一项可观察的验收条件；
4. 第一步最小任务和失败模式。

课堂行动 互检：oracle 是否独立？成功与失败是否都有可观察判据？

没有失败判据的问题，还不是可执行研究问题。

证据问题 6

如何提交并自检本讲成果？

作业 1: AI 辅助论文理解、公式审计与问题定义

提交内容

1. 一页中文导读：论文研究什么，作者实际主张什么，证据和边界分别是什么。
2. 一个关键公式或算法步骤：原文定位、符号定义、推导或复现说明与至少两项物理审计。
3. 初步问题定义表：可证伪主张、独立基准 (oracle)、验收条件、最小任务与失败模式。
4. AI 使用记录：模型/工具与访问日期、检索或工具调用、输入材料、用途、人工核查、采纳与拒绝内容；未使用 AI 时说明替代核查方式。

评分重点

原文核查、物理判断、问题定义和记录完整性；不以 AI 输出篇幅或术语数量评分。

作业 1 把课堂工作流完整迁移到你自己的论文。

课后任务使用可填写模板 `AI4Phys-2-homework.pdf`；提交方式与截止时间以课程平台通知为准。

建议阅读：为共同公式与研究迁移提供支点

1. **必读：** G. Carleo *et al.*, “Machine Learning and the Physical Sciences,” *Rev. Mod. Phys.* **91**, 045002 (2019): 引言与任务分类部分。 <https://doi.org/10.1103/RevModPhys.91.045002>
2. **选读：** S. Keshav, “How to Read a Paper,” *ACM SIGCOMM Comput. Commun. Rev.* **37**(3), 83–84 (2007): 三遍阅读法；第三遍“虚拟重构”对应可复核阅读卡。
<https://doi.org/10.1145/1273445.1273458>
3. **选读：** 一篇与自己研究方向相关的原始论文：优先选择模型清晰、包含关键公式和可对照结果的论文。
4. **课前短材料：** 课程资源页的“从 token 到工具调用”概念图：区分组成部分及其证据边界。
5. **选读：** D. J. Griffiths and D. F. Schroeter, *Introduction to Quantum Mechanics*: 变分原理章节，用于核查上界、驻值条件与等号情形。

阅读问题

Keshav 第三遍“虚拟重构”与阅读卡的字段如何一一对应？Griffiths 变分章节的等号条件如何由二能级 oracle 体现？

先用共同公式学习审计，再将同一工作流迁移到自己的研究问题。

带走的六句话

1. 本讲讨论的自回归 LLM 在有限上下文中反复预测下一 token；Transformer 是架构，检索与工具调用是外部通道。
2. 注意力权重和展示的中间推理本身不是解释，也不证明结论正确。
3. LLM 的解释是候选阅读路径，不是论文原文或公式正确性的证据。
4. 可靠阅读记录同时写明主张、证据、边界和原文位置。
5. 公式审计先问条件、定义和逻辑类型，再问推导是否流畅。
6. 好的问题从论文中的一句主张出发，明确 oracle、验收条件和可证伪结果。

候选答案必须回到证据、反例与独立基准。

离开前自检

1. token、上下文、注意力、下一 token 概率和采样分别做什么？
2. 检索结果或工具执行结果为何更可追溯，却仍不能免检？
3. 为什么注意力权重或长推理文本不能直接证明答案正确？
4. 阅读卡中的“边界”和“位置”分别解决什么问题？
5. 变分上界依赖哪些前提？为什么 $\theta = \pi/2$ 是驻点却不是基态？
6. 为准备阅读的论文写出一个可证伪主张、一个 oracle 和一个验收条件。

每一问都应能用原文位置、公式条件或独立基准回答。

提交前逐项核对：原文位置、模型边界、独立基准、验收条件与 AI 使用记录。

**解释可以很快；
证据必须可追溯。**

第 2 讲结束