

Coding Agent 与 可复现数值实验

AI 赋能的物理学研究：工具、方法与前沿

AI 提出候选，人类研究者确立结论。

AI proposes candidates; the human researcher establishes the conclusion.

周毅

中国科学院物理研究所

2026 年 9 月

可运行脚本何以成为可信物理结果？

当 Coding Agent 能迅速写出、
运行并修改数值代码时，
**一个可运行的脚本何以成为
可复核的物理结果？**

本讲立场

Agent 可以提出候选实现、测试草稿和调试线索；任务规范（task specification）、最小权限、独立基准、物理审计和完整运行记录，才决定结果是否可信。

本讲按一条证据链组织

六个环节，90 分钟



$10 + 17 + 15 + 25 + 15 + 8 = 90$ 分钟。

共同数值案例

一维SSH 模型 (Su-Schrieffer-Heeger 二聚化链): 周期边界解析色散、二聚化极限、端点态与有限尺寸扫描。


课堂产出

一份可验收任务规范、一张 SSH 验证卡，以及一项最小可复现实验计划。

共同案例：一维 SSH 模型

本讲任务、演示与审查的共同对象

- 每个单元胞含 A、B 两个格点。
- 跃迁交替：胞内 t_1 ，胞间 t_2 。
- 开链（OBC）首尾截止；周期链（PBC）多一条末端键。



为什么选它

有解析能带、两个可手算的二聚化极限和端点局域态：每一步都能设独立基准。

一个简单的模型，足以撑起一整条证据链。

本讲交付可验证、可复现的数值 workflows

1. 将物理问题写成模型、输入、输出、边界、测试和验收条件齐全的任务规范。
2. 将 Coding Agent 视为受约束协作者：其计划、代码和自我解释都不是独立证据。
3. 区分单元测试、回归测试、物理基准和独立 oracle 的作用。
4. 用 SSH 的解析能带、二聚化极限、端点局域性和有限尺寸扫描审计实现。
5. 交付代码、测试、环境、命令、参数、种子、图表脚本和 AI 使用记录。

每节一个证据问题；每页一个可检验结论。

证据问题 1

**一项数值任务如何才算
可以验收？**

可运行不是数值正确

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

三类常见错觉

- Agent 能解释每一行代码 $\Rightarrow$ 模型已被核查。
- 本征值程序没有报错 $\Rightarrow$ 矩阵构造和边界条件正确。
- 图像与预期很像 $\Rightarrow$ 已通过物理验证。

这些仍未被证明

- Hamiltonian 与基矢顺序
- 参数约定与边界条件
- 数值方法与误差控制
- 物理解释与结论边界

同一 Agent 生成的代码、测试、解释和图表不是相互独立的证据。

任务规范先定义什么算正确

自然语言问题必须变成可检查的承诺

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

字段	需要明确的内容
物理问题	研究哪个模型、可观测量或现象；哪些结论需要判断？
模型与约定	自由度、Hamiltonian、单位、基矢顺序、参数范围和边界条件。
输入与输出	函数接口、数据形状、图表、表格和保存路径。
允许与禁止	可用库、可读写目录、网络和命令权限；禁止处理的数据、密钥和破坏性操作。
最小测试	手工矩阵、解析式、已知极限、对称性或独立小系统基准。
验收条件	比较量、容差 (tolerance)、失败判据、随机种子和必须报告的边界。

任务规范并非给 Agent 的修辞模板，而是人、代码、测试和结果共同契约。

SSH 任务规范：先写接口与验收，再写代码

最小版本

问题：构造 L 个单元胞的无自旋 SSH 链，比较 PBC 与 OBC 的单粒子谱。

输入： $L \in \mathbb{N}$ 、实数跃迁 t_1, t_2 、边界参数 `periodic`。

输出：Hamiltonian、排序本征值、PBC 解析能带比较、OBC 低能态概率分布。

最小测试：Hermiticity; $t_2 = 0$; $t_1 = 0$; PBC 解析色散。

验收：保存参数、版本、命令和图表脚本；任一最小测试失败时，不报告拓扑或边界态结论。

谱比较的明确容差

排序后逐项比较数值与解析 PBC 谱：

$$\max_j |E_j^{\text{num}} - E_j^{\text{ana}}| \leq 10^{-10} \max(1, |t_1| + |t_2|).$$

模型已在开场引入；Hamiltonian 与解析能带将在第 3 节正式写出。这里只关注如何把问题写成可验收的接口与判据

失败判据防止事后解释

理解一个方法，就是理解它的失败模式

待检验主张

在本讲的截断（termination，链末端从哪条键截止）与手征对称性约定下，若 $|t_2| > |t_1|$ 且链长相对局域长度足够大，则有一对端点局域低能态，其能量劈裂随 L 增大而减小。

出现以下任一情况，即不接受该主张：

1. PBC 谱未在指定容差内匹配解析 $E_{\pm}(k)$ 。
2. $t_1 = 0$ 的 OBC 极限没有两个零本征值。
3. 被标为边界态的本征矢，其主要权重在链中央而非端点附近。
4. 改变 L 后，劈裂和局域性随尺寸的变化违背预期。

先决定什么结果会推翻主张，才能避免“代码运行后再解释”。

课堂操作：把宽泛请求改成可验收任务

4 分钟，两人一组

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

宽泛

“请用 Agent 写一个模拟 Ising 模型的程序，并画出相图。”

可验收

明确维度、耦合、边界条件和 Agent 可读写目录；先对照一维精确解与高温极限；扫描系统尺寸；测试失败时报告磁化强度差异而非生成相图。

课堂行动 两人一组：为自己的一个数值任务补齐模型约定、一个 oracle、一个容差和一个失败判据。

证据问题 2

Coding Agent 如何成为受约束协作者？

人机分工应围绕证据，而非“自动化程度”

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

环节	Agent 可以协助	研究者必须负责
规划	文件结构、函数接口、测试清单和待澄清问题。	模型、边界、物理目标、权限和验收标准。
实现	函数、测试、文档字符串和作图草稿。	矩阵元、索引、单位、库调用和参数约定。
运行与调试	报错解释、问题定位和修补候选。	命令、文件访问和是否接受修改。
验证	比较表、回归测试和可视化候选。	独立 oracle、误差、收敛与物理含义。
交付	README、环境和运行说明。	完整记录、可复核结论与 AI 使用披露。

Agent 可以协助实现；研究者不能把定义正确性的责任外包。

Agent 的自我修正不是独立验证

看似严谨的闭环

Agent 写代码 → Agent 生成测试 →
Agent 运行测试 → Agent 解释图像 →
“已验证”。

共享错误来源


代码、测试、解释和图像可能继承同一个错误基矢顺序、错误边界条件或错误物理假设。

相互一致不等于相互独立。

解析基准、手工矩阵和独立实现才能针对同源错误提供外部约束。

建议采用“计划-最小改动-自动测试-物理审计”循环

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交



1. 先要求计划，列出文件、接口、测试和待澄清问题。
2. 一次只改一个函数或一个测试，避免无关重构掩盖物理错误。
3. 先读差异，再运行；测试通过后仍须做物理审计。
4. 保留失败的输入、报错和修补过程。

循环的每一步都留下可读、可测、可回滚的记录。

教师演示：同一 SSH 任务，两种请求

4 分钟，两次真实调用对比

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

第一次：宽泛请求

“帮我检查这个 SSH 代码。”

计划、测试与改动范围全凭 Agent 自行发挥。

第二次：规范任务卡（沿用 p11 结构）

只读沙盒目录、不改文件；审查 `ssh_hamiltonian` 的键连接与边界处理；以 PBC 解析色散与 $t_1 = 0$ 极限为基准；先交计划、测试清单与预期输出，等待人工确认。

课堂行动 教师演示：对同一 SSH 任务连发两次真实调用；全班并排对比两次的计划质量与改动范围。

演示环境：独立沙盒目录（仅预置教学代码与空测试目录），Coding Agent 以最小权限运行、禁止联网安装；预跑记录与截图已备案。

同一任务、同一 Agent：任务规范改变计划质量与改动范围。

最小权限是科学工作流的一部分

最小权限（least privilege）原则

每个工具、Agent 和协作者只获得完成当前任务所必需的最小权限——文件、命令、网络、数据和凭证概莫能外；不确定是否需要时，默认不授予。它既是安全原则，也是科学原则：权限边界限制了错误能被 Agent 放大的范围，并使每一次执行可解释、可审计。

风险点	最低要求
文件与命令	在专用工作目录中运行；不执行无法解释、会删除文件或改变系统状态的命令。
网络与数据	未发表数据、审稿内容、个人信息和受限代码不得上传到未授权服务。
凭证与密钥	不在提示、代码、Notebook、终端历史或公开仓库中写访问令牌。
依赖与环境	记录 Python、库和系统版本；导出环境文件，避免只依赖本机隐式状态。
随机性与修改	保存随机种子、关键提示、Agent 实际改动、人工修改、测试命令和失败案例。

可复现不等于“代码公开”；它要求同等授权的读者能重走结果生成路径。

课堂操作：执行前先审查 Agent 计划

4 分钟，两人一组

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

拟议计划

“我将重写项目目录、安装最新依赖、运行所有脚本，并根据输出自动修复错误。”

第一步：用四个问题审查这份计划。

1. 哪些文件、命令、网络访问或安装动作尚未获授权？
2. 如何把计划缩小为一个可阅读、可回滚的最小改动？
3. 应要求 Agent 先列出哪些测试和预期输出？
4. 哪项物理检查不能由同一段实现及其自测替代？

课堂行动 第二步：两人一组，将拟议计划改写为“修改范围、权限、测试、验收、记录”五项清单。

证据问题 3

SSH 实现如何经受物理 审计？


先固定模型、基矢和边界条件

一个布尔参数对应一条实际跃迁

$$H_{\text{OBC}} = t_1 \sum_{n=0}^{L-1} (|n, A\rangle\langle n, B| + \text{h.c.}) + t_2 \sum_{n=0}^{L-2} (|n+1, A\rangle\langle n, B| + \text{h.c.}).$$
$$H_{\text{PBC}} = H_{\text{OBC}} + t_2 (|0, A\rangle\langle L-1, B| + \text{h.c.}).$$

约定基矢：

$$(A_0, B_0, A_1, B_1, \dots, A_{L-1}, B_{L-1}).$$



periodic 不是作图细节：它改变连接图、动量、边界态和可得出的物理结论。

周期边界给出独立的解析能带基准

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

$$q(k) = t_1 + t_2 e^{-ik}, \quad H(k) = \begin{pmatrix} 0 & q(k) \\ q^*(k) & 0 \end{pmatrix}, \quad E_{\pm}(k) = \pm \sqrt{t_1^2 + t_2^2 + 2t_1 t_2 \cos k}.$$

$k = 2\pi m/L$, 其中 $m = 0, \dots, L-1$ 。

可检验结论

PBC 数值矩阵的排序本征值必须逐项匹配离散 k 网格上的解析谱。

带隙

当 $t_1, t_2 > 0$: $\Delta_{\text{bulk}} = 2|t_1 - t_2|$, 在 $t_1 = t_2$ 闭合。

PBC 谱基准必须匹配边界、基矢与动量约定。

两个二聚化极限是更强的边界 oracle

$t_2 = 0$: 胞内孤立二聚体



每个二聚体给出 $\pm t_1$; 没有端点零模。

$t_1 = 0$: 胞间二聚体与未配对端点



A_0 与 B_{L-1} 未配对: 两个严格零模, 完全位于端点。

极限直接检验键连接和边界处理;
一般参数下的“图像很像”做不到这一点。

拓扑指标不能脱离截断、对称性和有限尺寸

截断：链末端从哪条键截止 (termination)

在本讲的单元胞约定中，若

$$|t_2| > |t_1|,$$

则 $H(k)$ 的非对角元 $q(k) = t_1 + t_2 e^{-ik}$ 绕原点一次；这个绕行次数就是绕数 ν ，即拓扑指标，固定绕行方向后 $|\nu| = 1$ 。

本讲的模型只含 A、B 子格间跃迁，因此有手征对称性： $\Gamma = \text{diag}(1, -1, \dots)$ ， $\Gamma H \Gamma = -H$ ；加入在位项或同子格跃迁会破坏它。

正确的有限链表述

在指定截断、无同子格在位项且链长相对局域长度足够大时，开链有一对端点局域低能态；劈裂随 L 增大而减小。

**“不是严格零”不等于“没有边界态”；
必须同时检查局域性、截断和尺寸依赖。**

第一个最小改动：实现构造函数，物理判断留给基准

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

```
import numpy as np
def ssh_hamiltonian(n_cells, t1, t2, periodic=False):
    h = np.zeros((2 * n_cells, 2 * n_cells), dtype=float)
    for n in range(n_cells):
        a, b = 2 * n, 2 * n + 1
        h[a, b] = h[b, a] = t1
        if n < n_cells - 1:
            h[b, 2 * (n + 1)] = h[2 * (n + 1), b] = t2
    if periodic:
        h[2 * n_cells - 1, 0] += t2
        h[0, 2 * n_cells - 1] += t2
    return h
```

为何使用 += ?

当 $L = 1$ 时，周期键与胞内键作用于同一对轨道，故矩阵元应为 $t_1 + t_2$ ，不能覆盖为 t_2 。

SSH 验证卡：每项测试排除哪一种错误？

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

测试	应比较什么	排除什么错误
形状与 Hermiticity	H 为 $2L \times 2L$, 且 $H = H^\dagger$ 。	尺寸、非对称赋值和部分索引错误。
PBC 色散	排序数值谱与离散解析谱逐项比较，满足指定容差。	漏键、错误周期键、错误跃迁或动量约定。
$t_2 = 0$ 极限	只出现 $\pm t_1$ 的二聚体能级。	胞间键未关闭或胞内键位置错误。
$t_1 = 0$ OBC 极限	两个端点零模及其端点概率分布。	误加周期键、边界索引或基矢解释错误。
手征配对	$\Gamma H \Gamma = -H$ 与 $\pm E$ 谱配对。	意外在位项、同子格跃迁或符号错误。
尺寸扫描	改变 L ，记录近零劈裂与端点权重。	将有限尺寸劈裂误报为相变或实现失败。

单元测试能定位局部错误；解析极限与物理基准才约束实现的物理含义。

课堂代码审查：AI 先审 + 人工 oracle 对照

7 分钟：两人一组 + 审计卡

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

虚构的错误实现（故意：periodic=False 时仍加入末端键）

```
h[2 * n_cells - 1, 0] = h[0, 2 * n_cells - 1] = t2
```

错误定位：删掉 p24 的 if 守卫，开链被误加末端周期键——违反任务规范的模型约定；矩阵却仍对称、谱仍平滑：Hermiticity 检验矩阵性质，不检验是否守约。

最小反例 ($L \geq 2$): $H_{2L-1,0}^{\text{OBC}} = 0$,
 $H_{2L-1,0}^{\text{PBC}} = t_2$ 。

课堂行动 两人一组：先把片段发给 AI 审查并记录结论，再用矩阵元素测试复核 AI 的判定。

AI 的审查意见也是候选；独立 oracle 才能当场判定。

讨论后核对：测试必须针对错误假设

1. 开链末端元素为零是直接检查“是否误加周期键”的最短路径。
2. Hermiticity 只说明矩阵对称，不说明它实现了正确的连接图。
3. $t_1 = 0$ 的 OBC 极限给出两个端点零模，是可手工核对的 oracle。
4. 一般参数下应同时报告谱、端点权重和随 L 变化的劈裂。
5. 通过上述测试之前，不能把数值输出命名为“拓扑边界态”。

好的测试不是“多跑几个”；而是每一个都能排除一种错误主张。

失败模式反向改写 workflow

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

课堂上遇到的失败	固化为下一轮的… …
开链误加末端键 (p26)	矩阵元素检查进入回归测试
跑通、矩阵对称就声称正确	PBC 解析谱与二聚化极限立为验收条件 (p21/p22)
截断、基矢约定含糊 (p20/p23)	写进任务规范的模型约定
测试失败仍继续作图下结论	事先写失败判据：失败即停止解释、返回实现核查 (p10)
失败来源无法复查	保存输入、矩阵差异、日志与人工干预记录

**失败不只是一要保存的结果；
它应改写下一轮的任务规范、测试和验收条件。**

证据问题 4

何为可复现的数值交付？

单元测试、物理基准与 oracle 不能混为一谈

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

层级	SSH 例子	作用与局限
单元测试	矩阵形状、Hermiticity、周期键是否存在。	快速定位局部实现错误；不自动证明物理解释。
回归测试	固定输入的谱、图表数据或哈希保持不变。	防止已知结果被改坏；也可能固化原有错误。
物理基准	PBC 色散、二聚化极限、手征配对。	用独立物理结构排除具体错误；须匹配同一约定。
独立 oracle	手工小系统键、解析解或独立实现。	预先规定何为通过；不能与待审计代码共享错误来源。

oracle 是预先写明的独立判据，不是 Agent 对自身输出的解释。

虚构的错误 Agent 推理（故意：把必要条件当作充分验证）

反面动机：可复现交付要防的具体失败模式

错误推理

“矩阵是 Hermitian, eigvalsh 成功返回实本征值，因此开边界实现正确；若未观察到零模，该参数区间就是平庸相。”

错误定位

Hermiticity 是实现正确的必要条件，不是充分验证：它不检查末端是否误连为周期键，也不检查截断、二聚化极限、手征对称性或有限尺寸劈裂。

**一个可运行的实现只能产生候选；
物理基准才决定候选能否成为结论。**

最小可复现实验应保留完整的结果生成路径

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → [人工提交](#)

```
ssh-lab/  
  src/ssh.py  
  tests/test_ssh.py  
  scripts/make_figures.py  
  outputs/  
  README.md  
  environment.yml
```

读 README 就应能知道

- 运行什么命令
- 应看到什么输出
- 什么结果表示失败
- 结论不能推广到什么范围

图表不是交付终点；
能从干净环境重走“代码-数据-图表-结论”才是。

可复现交付必须记录六类材料

实现与验证

1. 源代码：模型、接口、默认参数和基矢约定。
2. 测试：物理理由、输入、预期输出和容差。
3. 结果：原始数值、图表、生成脚本和失败输出，不只保留截图。

环境与责任

1. 环境：Python、库、系统版本、种子与采样设置。
2. 命令：从干净环境到出图的完整执行顺序。
3. AI 使用记录：工具与版本、关键提示、实际修改、人工审查和未采用内容。

可复现记录应包含失败路径，因为它界定了结论在哪里不成立。

为今天的 SSH 审查补齐最小交付清单

2 分钟

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → [人工提交](#)

以今天的 SSH 代码审查为例

审查结论本身不能说明输入、环境、测试或判定过程。

1. 这次审查的输入（两份代码版本）、环境和提示词记录在哪里？
2. AI 的审查结论经过了哪个独立 oracle 复核？
3. 哪些原始记录必须一并保存？
4. Agent 在哪里提出了候选，研究者又在哪里做了决定和修正？

课后随作业 2 完成：列出一个操作记录、一个 oracle、一个失败案例和一条 AI 使用记录。

证据问题 5

如何将 workflow 迁移到自己的项目？

把 Agent 请求写成受控的研究任务

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

建议结构

物理任务：我要实现 {模型/论文算法}，目标可观测量是 {...}。

模型约定：自由度、Hamiltonian、单位、基矢、边界和参数范围是 {...}。

实现范围：只修改 {文件或目录}；允许 {库}；不要访问网络、删除文件或读取 {受限目录}。

测试：先实现 {手工矩阵/解析极限/对称性/小系统}；给出预期输出和容差。

输出：提交代码差异、命令、测试结果、图表脚本和需要人工决定的问题。

验收与记录：oracle 不通过时停止扩展；记录工具/版本、提示、人工修改、种子与限制。

**好的 Agent 请求不要求“自动完成”；
它要求明确的范围、验证标准和不确定性说明。**

从宽泛任务到可复现实验

宽泛表述

“请用 Agent 写 SSH 程序，并画出拓扑相图。”

可执行表述

固定基矢并分别构造 OBC/PBC；先以解析色散检查 PBC，再以 $t_2 = 0$ 和 $t_1 = 0$ 的 OBC 极限检查键连接；扫描 t_1/t_2 与 L ，保存端点权重、参数和作图脚本。

可证伪条件

PBC 谱偏离解析基准、二聚化极限失败，或低能态不局域于端点时，不能接受“实现显示了指定截断下 SSH 边界态”的主张。

可执行表述必须同时给出验收动作和必存记录。

项目推进：选择最小而非最大的任务

可作为最小可复现实验的任务

- SSH 的 PBC/OBC 谱、端点态和尺寸扫描。
- 横场 Ising 链的小尺寸精确对角化。
- 自己论文中一张图的最小复现。
- 经教师确认的项目最小任务。


选择标准

- 有独立基准或简单极限
- 有明确失败模式
- 能保存完整运行记录
- 能在短时间内闭合验证链

任务选择不在于代码规模，而在于能否独立验收一个物理主张。

核对：先把项目组织成证据链

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交



1. 你的结论能否写成完整句子，说清模型、参数、边界和尺寸范围？
2. oracle 是否独立于待审计实现，通过条件是否预先写明？
3. 失败时能否留下可据以定位错误的矩阵差异、日志或原始数据？
4. 另一位研究者能否照着 README 重现你的图，并说清它不能说明什么？

证据问题 6

如何完成并自检本讲成果？

作业 2: Coding Agent 与可复现数值实验

提交内容

1. 任务规范：模型约定、输入输出、边界、测试和验收条件。
2. 代码与测试：源文件、测试命令、至少两项物理或解析基准和失败输出。
3. 可复现记录：环境、依赖、命令、参数、种子、原始数值和绘图脚本。
4. 结果说明：通过/未通过检查、结论边界和一个失败模式。
5. AI 使用记录：工具与版本、任务、关键提示、实际修改、人工审查和未采用内容。

评分重点

任务规范、测试与物理判断、可复现性和诚实的失败分析；不以自动生成代码量、文件数量或图表装饰性评分。

可选择 SSH、横场 Ising 链小尺寸对角化、论文图复现或经教师确认的项目最小任务。

建议阅读：为代码实践与复现记录提供共同标准

1. **选读**：W. P. Su, J. R. Schrieffer and A. J. Heeger, “Solitons in Polyacetylene,” *Phys. Rev. Lett.* **42**, 1698–1701 (1979)。 <https://doi.org/10.1103/PhysRevLett.42.1698>
2. **必读**：G. Wilson *et al.*, “Good Enough Practices in Scientific Computing,” *PLoS Comput. Biol.* **13**, e1005510 (2017)：版本控制、测试与自动化部分。
<https://doi.org/10.1371/journal.pcbi.1005510>
3. **选读**：G. K. Sandve *et al.*, “Ten Simple Rules for Reproducible Computational Research,” *PLoS Comput. Biol.* **9**, e1003285 (2013)。 <https://doi.org/10.1371/journal.pcbi.1003285>

阅读问题

SSH 原文的解析结果如何充当独立 oracle？Wilson 与 Sandve 的哪两条可写入运行记录？

先用小型可解释模型建立验证习惯，
再将同一链条迁移到自己的研究。

带走的五句话

1. Coding Agent 的代码、解释和自我修正都是候选，不是正确性的独立证据。
2. 任务规范先定义模型、权限、测试和验收，实现才有可审计的正确性标准。
3. Hermiticity、无报错和漂亮图形都是必要但不充分的软件或数值条件。
4. SSH 的解析色散、二聚化极限、端点局域性和尺寸扫描共同检验实现。
5. 可复现交付必须包含代码、测试、环境、命令、参数、生成路径、AI 使用记录和失败边界。

离开前自检

1. 为什么 Agent 的“代码已通过自检”不能替代独立 oracle ?
2. SSH 的 OBC 与 PBC Hamiltonian 差别在哪一条末端跃迁 ?
3. 为什么 $t_1 = 0$ 的 OBC 极限能检验端点零模和边界实现 ?
4. Hermiticity 能排除什么错误, 又不能排除哪类边界错误 ?
5. 为自己的一个数值任务写出模型约定、一个最小测试、一个 oracle 和一个失败判据。
6. 你最近的一次失败改写了哪条任务规范、测试或验收条件 ?

提交前逐项核对: 任务规范、权限边界、独立基准、环境命令、失败记录与 AI 使用记录。

**代码可以很快；
结果必须可复现。**

第 3 讲结束