

第 2 讲

LLM 辅助文献、 推导与问题定义

AI 赋能的物理学研究：工具、方法与前沿

课程讲义 (Article Note)

周毅

中国科学院物理研究所

2026 年 9 月

本讲核心问题

LLM 能快速概括论文、解释公式、补全推导。

我们如何理解这些输出从何而来，又如何确认自己的理解仍建立在 **原文证据与可检验的物理推理**之上？

本讲立场：LLM 通过有限上下文中的下一 token 预测生成候选；检索与工具调用提供外部信息或行动通道。这些能力可以加快阅读、辅助解释、草拟推导；但结论是否成立，取决于论文原文、符号定义、模型假设、独立基准和反例。

本讲以量子力学的**变分原理**为共同公式案例；学生再将同一工作流迁移到自己的论文或研究问题。不要求预先掌握机器学习；要求能够读取基本物理公式，并愿意追问每个结论的来源、条件与反例。

Contents

1 本讲目标与使用方式	3
2 从 token 到工具调用：LLM 输出如何形成	4
3 从论文文字到可审计的主张	6
4 单次 AI 调用需要可验收规范	8
5 共同公式案例：变分原理如何经受审计	9
6 从公式阅读到可执行研究问题	12
7 课堂收束：把审计卡转成问题定义卡	13
8 作业、阅读与最小提交材料	15
9 本讲小结与自检	16

1 本讲目标与使用方式

1.1 学习目标

完成本讲后，你应能够：

1. 借助概念流程图，分清 token、有限上下文、注意力、下一 token 概率、解码/采样、检索与工具调用各自的作用。
2. 说明为什么注意力权重和模型展示的中间推理本身不能充当解释，也不能证明结论正确。
3. 将一篇论文中的结论拆成可定位的**主张、证据、假设与边界**。
4. 使用 LLM 辅助概念解释和阅读定位，但不把其摘要、引文或推导直接当作证据。
5. 审计一个公式的符号、定义域、近似、量纲、极限、对称性、已知特例与反例。
6. 从论文阅读记录形成一个可证伪主张、独立基准（oracle，即不依赖待审计输出的核查基准）和最小可执行任务。

1.2 90 分钟课堂安排

时长	环节	本讲产出
4 min	开场：第 1 讲回顾	逐句回顾验证链（候选 → 审计 → 结论），预告本讲的真实 AI 调用环节。
20 min	LLM 机制图景与边界	从 token、上下文和注意力到下一 token 概率、采样、检索与工具调用。
20 min	文献阅读 workflow	教师现场两次调用共同论文摘要，全班共填“主张-证据-边界-位置”阅读卡。
12 min	单次 AI 调用规范	一份包含来源、假设、约束、输出格式和验收条件的调用规范；现场对比宽泛提问。
20 min	公式审计	用变分原理区分上界、驻点与基态；二能级模型作为最小 oracle。
14 min	问题定义与作业说明	把审计卡转成问题定义卡：可证伪主张、oracle 与最小任务初稿。

1.3 开场：第 1 讲回顾（4 分钟）

开场回顾：4 分钟

本次上课尚无第 1 讲提交材料可供比较，改为逐句回顾第 1 讲建立的验证链。逐句确认下面每句话在第 1 讲的哪个环节建立，并判断哪一句今天会再次用到：

1. AI 输出是**候选**，不是证据。

2. 问题定义、基线和验收标准必须先于计算。

3. 量纲正确、曲线尖锐或代码可运行，都不足以证明物理结论。

4. 一维最近邻零场 Ising 模型在 $T > 0$ 没有相变；转移矩阵给出独立的解析反证。
5. 好的项目不仅报告“发现了什么”，还应说明什么可靠、什么不确定，以及什么会推翻自己的结论。

验证链不变——候选 $\rightarrow$ 审计 $\rightarrow$ 结论；本讲把它用于文献阅读、公式审计与问题定义，并将在阅读卡共填、调用规范对比和陷阱提问等环节真实调用 AI。

1.4 本讲的工作规则

1. **先定位，再解释。**先标注论文页码、图号、公式号或段落，再请 AI 协助解释。
2. **先写假设，再写推导。**符号定义、模型、近似和适用范围不是推导后的注脚。
3. **先定义验收，再扩展阅读。**知道什么结果会支持、削弱或证伪一个主张。
4. **分清生成与证据。**模型生成内容、检索结果、工具执行结果和经人工核查的结论必须分别标记。

本讲的核心追问 不要问“LLM 对这篇论文的解释对不对？”，而要问：“它的每一句解释对应原文中的哪一处？依赖哪些假设？我用什么物理或数值证据核查？”

2 从 token 到工具调用：LLM 输出如何形成

2.1 文本先变成 token，模型只看到有限上下文

语言模型不直接读取“词义”，而是先由 tokenizer 将文本切分为 token 并映射为整数编号。token 可能是一个汉字、词的一部分、标点、空格模式或代码片段，因此 token 不等同于自然语言中的“词”。例如（仅为示意，具体切分依赖所用 tokenizer）：中文常按单字或词片切分，“变分原理”可能被切成四个 token；公式文本 $E[\psi]$ 可能被切成 E 、 $[$ 、 ψ 、 $]$ 等若干 token；同一个词在不同 tokenizer 下切分可以不同。设当前上下文中的 token 序列为

$$z_1, z_2, \dots, z_t.$$

模型实际处理的是一个有最大长度限制的上下文窗口。系统指令、用户问题、对话历史、粘贴的论文片段、检索结果和工具执行结果都可能占用这个窗口；超出窗口的内容需要截断、压缩或重新选择。

信息进入上下文，不代表模型已正确使用。 信息可能已被截断，可能淹没在长文本中、与其他指令冲突，也可能在生成时关联错误。因此“我已经把论文放进上下文”不能替代对最终回答的逐项核查。

2.2 自回归 LLM 输出下一 token 的条件概率

在本讲讨论的自回归 LLM 中，Transformer 主干将当前 token 序列变成上下文化表示，语言模型输出层再将当前位置的表示映射为下一 token 的 logit ℓ_j 。softmax 将 logits 转为条件概率：

$$p(z_{t+1} = j \mid z_{\leq t}) = \frac{\exp(\ell_j)}{\sum_k \exp(\ell_k)}. \quad (1)$$

选择一个 token 后，将它追加到上下文，再重复同一过程，最终形成一段文本。因此，这类语言模型的基本生成过程是**反复预测下一 token**，不是在回答时从一个事实数据库中直接取回整段标准答案。Transformer 是网络架构；下一 token 预测是这里采用的生成目标，两者不能视为同义词。

流畅性的来源与限度 训练使模型能够给许多语言和推理模式分配较高概率，但式 (1) 并不包含“该 token 必须真实”“该引用必须存在”或“该推导必须正确”的约束。语言通顺与科学正确是两项不同的验收标准。

2.3 注意力是信息混合机制，本身不是解释

注意力使一个位置的表示根据当前输入，汇集其他位置的信息。概念上可写成

$$h'_i = \sum_j \alpha_{ij} v_j, \quad \alpha_{ij} \geq 0, \quad \sum_j \alpha_{ij} = 1, \quad (2)$$

其中 v_j 是由第 j 个位置形成的值向量， α_{ij} 是当前参数化下的信息混合权重。特邀讲座（第 2.5 讲）将初步介绍 Transformer 架构与 Agent 使用经验；正式的 Q, K, V 、缩放点积、多头结构、位置编码和掩码将在第 6 讲讨论。

注意力权重不是物理解释或正确性证明。 式 (2) 中较大的 α_{ij} 只说明某层某头在该次前向计算中的混合系数较大，并不意味着因果贡献、特征重要性、模型“真正使用的理由”或物理关联函数。解释性主张仍需消融、受控替换（反事实测试）、独立基准和物理检验。

2.4 解码与采样把概率分布变成具体输出

给定下一 token 概率后，系统还需决定如何选择 token。贪心解码选择概率最大的 token；温度、top- k 或 top- p 等采样规则会改变多样性和随机性。这些规则影响输出风格和稳定性，却不承担事实核查：

- 同一提示在随机采样下可能产生不同回答；
- 更低温度通常使输出更稳定，但不会把错误事实变成正确事实；
- 多次采样得到相同答案，只能说明该答案在当前模型与提示下概率较高，不能替代独立证据。

2.5 检索和工具调用是外部通道

现代 LLM 系统常把生成模型与外部组件组合：

问题 → 检索或工具选择 → 检索或工具结果 → 写入上下文 → 继续生成。

检索增强生成（RAG）通常先从论文库、网页或本地资料中选择片段，再让模型基于这些片段回答。工具调用则由模型生成工具名与参数，由外部程序执行搜索、计算、代码或数据库操作，再把结果返回模型。外部通道可以提高可核查性，但每一环仍可能失败。

环节	提供什么	仍需核查什么
模型参数中的模式	术语解释、候选推导、语言与代码模式。	事实是否真实，适用条件是否匹配，知识是否过时。
当前上下文	用户给出的原文、假设、约束和对话历史。	是否完整、是否冲突、是否被正确引用。
检索结果	可定位的外部文本、元数据或候选来源。	来源质量、版本、片段是否支持当前主张，是否遗漏反证。
计算/代码工具	在给定输入和环境下的执行结果。	参数、单位、代码、依赖、权限、数值误差和独立基准。
最终生成文本	对上述信息的组织、解释和候选结论。	每一主张的来源、逻辑、边界及可复核证据。

工具执行结果也不是免检答案。 模型可能选择错误工具、生成错误参数或误读返回结果；检索系统可能召回不相关、过时或断章取义的片段；代码工具可能在错误环境中成功运行。必须保存来源、输入、参数、版本、权限边界和输出，并用独立方法复核关键结论。

2.6 展示的“推理过程”不能代表内部机制，也不能证明结论正确

有些模型或系统在推理阶段投入更多计算，或借助搜索、工具、可验证反馈与自我修订，来提升多步任务的表现。然而，用户看到的中间推理文本仍是模型输出：可能略去真实的计算路径，可能是事后合理化，也可能在中间步骤出错。评估时应检查**最终可验证步骤与外部证据**，而不是根据文字长度、语气或“反思”措辞判断可靠性。

本讲与后续课程的分工 本讲只建立机制与证据边界的概念图景；Transformer 架构初步介绍与 Agent 使用经验见第 2.5 讲（特邀讲座）；样本、特征、损失、梯度和最小训练链在第 4.5 讲建立，完整反向传播、自动微分和科学验证在第 5 讲学习，注意力/Transformer 的架构与对称性在第 6 讲学习，自回归分布与生成采样在第 7 讲（特邀讲座）学习。

3 从论文文字到可审计的主张

本讲所说的有效文献阅读，指能产出**可复核记录**的阅读。具体有四条可操作的判据：

- 1. **能定位**：每个主张都能标明原文位置；
- 2. **能区分**：分得清原文直接陈述、自己完成的推导与待核查的猜测；
- 3. **能质疑**：说得出结论的边界、一个反例方向和一个待核查问题；
- 4. **能转化**：读完能产生出一个可证伪的下一步任务，而不是止步于“我懂了”。

本节把这一标准操作化为“主张-证据-边界-位置”的阅读记录。

3.1 LLM 输出不能替代原文证据

不同材料在阅读 workflow 中承担不同角色。各类材料可以互补，但不能随意替代：

材料	适合做什么	不能单独证明什么
原始论文正文、补充材料、数据与代码	定位作者实际主张、公式定义、实验/数值设置与结论边界。	未写出的机制、未报告的误差控制，或作者没有检验过的外推。
综述、教材与可靠数据库	建立背景、术语和已知基准；找到原始文献线索。	某一篇论文的具体实现、数据处理或精确表述。
LLM 的摘要、解释和问答	生成阅读线索、翻译术语、比较表述、列出待核查问题。	引文真实性、公式正确性、原文结论、数值结果或作者意图。
自己的笔记与推导	保留理解路径、标明缺口、设计验证与问题定义。	没有来源和检验支撑的事实性结论。

三类常见混淆

- LLM 列出一篇“很像真的”参考文献 $\Rightarrow$ 误以为该引用真实存在。
- LLM 用通俗语言复述一个结论 $\Rightarrow$ 误以为已理解其模型假设和定量证据。
- 多个 AI 输出相互一致 $\Rightarrow$ 误以为获得独立验证；这些输出可能源自相同的训练语料或同一提示链。

3.2 主张、证据、边界与位置

一条可审计的阅读记录至少回答四个问题：

1. **主张是什么？** 使用可被支持或证伪的完整句子，而非主题词。
2. **证据是什么？** 是解析推导、实验数据、数值比较、定理，还是经验观察？
3. **边界是什么？** 模型、参数范围、近似、样本、误差控制和未检验情形是什么？
4. **位置在哪里？** 页码、章节、公式号、图号、补充材料编号或代码版本是什么？

阅读卡示例（格式示意）

主张： 在给定模型与参数范围内，某种变分 ansatz 的能量接近基态能量。

证据： 正文中的能量比较图、方法段的优化设置，以及与小系统精确对角化的对照。


边界： 只报告有限尺寸、特定参数和给定网络结构；不能直接外推到热力学极限或其他 Hamiltonian。

位置： 正文第 3 节、图 2、式 (5) 及补充材料的训练细节。

下一步核查： 确认能量误差定义；比较基准是否独立；检查误差条、系统尺寸和随机种子。

3.3 把阅读动作变成证据链

推荐采用下面的顺序：



候选输出包括模型生成内容、检索结果和工具执行结果。若分层或审计暴露来源缺失、符号冲突或前提不足，应返回原文定位或修改调用规范，而不是继续扩写未经核查的解释。

阅读中的最小闭环 任何一条准备写入报告或用于后续计算的结论，都应附带：原文位置、模型假设、至少一项支持证据，以及一项尚未解决的核查问题。

课堂操作：6 分钟，现场调用 + 全班共填
教师现场对共同阅读论文的摘要（G. Carleo and M. Troyer, *Science* **355**, 602 (2017), arXiv:1606.02318）发两次真实调用——先宽泛提问，再按调用规范提问；全班对照输出，在课堂活动卡 A 部分（AI4Phys-2-auditcard.pdf）共填一张阅读卡：一句关键主张、原文位置、一项直接证据、两个假设或边界，以及一个待核查问题。填写要求：不评价论文“看起来是否先进”，只判断记录能否由同学追溯；主张必须是完整句子而非主题词；原文位置至少精确到页码、图号、公式号、段落或代码版本之一。此处只完成阅读卡，不提前做公式审计与问题定义。

4 单次 AI 调用需要可验收规范

4.1 调用前先固定问题与验收

一次提示或工具调用与其说是“让模型更会说话”的技巧，不如说是一份执行规范：规定这次交互的输入、目标、输出和验收方式。若不写明模型边界和验收条件，输出再流畅，也无法判断是否适用于正在阅读的论文。

字段	应明确的内容
来源与位置	论文题目、版本、页码、公式号或粘贴的原文片段；不要要求模型猜测来源。
目标	解释概念、逐步核对推导、比较两种定义，还是提出待核查问题？
模型与符号	自由度、Hamiltonian、单位制、边界条件、每个符号的定义与未给出的条件。
约束	不编造引用；将事实、推导和猜测分开；遇到信息缺失时明确提问。
输出格式	主张–证据–边界表、逐行推导、符号表、反例，或待核查清单。
验收条件	量纲、极限、对称性、已知特例、独立基准（oracle）和不确定度。

4.2 一个用于论文阅读的单次调用模板

来源：我正在阅读 {论文题目/版本} 的第 {页码或公式号}，原文是 {粘贴片段}。

目标：请解释该段想回答的物理问题，并逐一说明符号 {...} 的定义。

模型与假设：体系是 {...}；已知近似、边界条件和单位制是 {...}。

请求：请将回答分为“原文直接陈述”“由公式可推出”“需要额外核查”三栏。

验收：指出至少两个应检查的极限、对称性、已知特例或独立基准；不要提供未能定位的引用。

不确定性：若原文缺少关键条件，请列出需要返回原文确认的问题。

填写示例（以共同阅读论文的摘要为对象）

来源：G. Carleo and M. Troyer, *Science* **355**, 602 (2017), arXiv:1606.02318；摘要中介绍变分表示的两句（已粘贴原文）。

目标：解释作者如何把量子态表示为变分 ansatz，并逐一说明能量期望值表达式中每个符号的含义。

模型与假设：格点自旋模型（横场 Ising、反铁磁 Heisenberg）；ansatz 为受限 Boltzmann 机；关注基态能量。

请求：请将回答分为“原文直接陈述”“由公式可推出”“需要额外核查”三栏。

验收：变分能量满足上界方向 $E \geq E_0$ ； $E[\psi]$ 在 $\psi \rightarrow a\psi$ 下不变；以有限系统精确对角化为独立基准。

不确定性：摘要未给出的优化算法、采样方式与误差估计，请列为需要返回正文核查的问题，不要猜测。

4.3 需要保留的不确定性

不要把流畅语言误读为推理证据。 LLM 可以写出很长的中间解释，但这段文字既不反映模型的内部机制，也不构成正确的物理证明。提交笔记时，至少区分：

1. 原文直接写出的事实；
2. 自己或 AI 根据明确前提完成的推导；
3. 尚待核查的猜测、类比或后续任务。

课堂操作：5 分钟（3 分钟独立改写 + 2 分钟现场跑）

把一条常用的宽泛提问（如“请解释这篇论文，并告诉我它的结论是否正确”）改写为可验收的单次调用规范：补齐来源与位置、模型与符号、输出格式和至少两项验收条件；信息缺失时要求模型返回问题，而不是猜测。教师随后把一条学生规范真实发给模型，与宽泛提问的输出并排对比，全班指出两者在可定位性上的差别。

5 共同公式案例：变分原理如何经受审计

5.1 先写清楚公式成立的条件

设 Hamiltonian H 为自伴算符，其谱的下确界为 E_0 （基态能量）；试探态 $|\psi\rangle$ 属于 H 的定义域且不为零。变分能量定义为

$$E[\psi] = \frac{\langle \psi | H | \psi \rangle}{\langle \psi | \psi \rangle}. \quad (3)$$

在这些条件下，

$$E[\psi] \geq E_0. \quad (4)$$

共同案例参考：D. J. Griffiths and D. F. Schroeter, *Introduction to Quantum Mechanics*, 变分原理章节。以下推导用于审计该标准结论的前提、等号条件和常见误读。

审计起点 式 (4) 并非单凭符号外形就能成立，而要依赖 H 的自伴性、下有界谱、试探态的定义域以及分母不为零。脱离这些条件，同样的写法未必构成能量上界。

5.2 谱分解只保证上界，不保证得到基态

先以离散谱记号说明。令

$$H|n\rangle = E_n|n\rangle, \quad E_n \geq E_0,$$

并展开

$$|\psi\rangle = \sum_n c_n |n\rangle.$$

代入式 (3) 得

$$E[\psi] = \frac{\sum_n |c_n|^2 E_n}{\sum_n |c_n|^2} = \sum_n p_n E_n, \quad p_n = \frac{|c_n|^2}{\sum_m |c_m|^2}, \quad p_n \geq 0, \quad \sum_n p_n = 1. \quad (5)$$

因此 $E[\psi]$ 是本征能量的加权平均，必不小于 E_0 。更一般的连续谱情形可由谱测度给出相同结论；本讲使用离散谱形式只是为了清楚展示逻辑。

等号条件也必须写出：若基态非简并， $E[\psi] = E_0$ 当且仅当 $|\psi\rangle$ 与基态成正比；若基态简并，则 $|\psi\rangle$ 必须完全落在基态子空间中。

5.3 驻值条件与极小值条件不是同一句话

若施加归一化 $\langle \psi | \psi \rangle = 1$ ，引入 Lagrange 乘子 ε ：

$$\mathcal{L}[\psi, \varepsilon] = \langle \psi | H | \psi \rangle - \varepsilon (\langle \psi | \psi \rangle - 1). \quad (6)$$

把 $|\psi\rangle$ 与 $\langle \psi|$ 的变分独立处理，驻值条件为

$$\delta \mathcal{L} = 0 \implies H|\psi\rangle = \varepsilon |\psi\rangle. \quad (7)$$

再左乘 $\langle \psi|$ 可知 $\varepsilon = E[\psi]$ 。

式 (7) 说明**每个本征态都是驻点**，而非每个驻点都是基态。只有在所有允许试探态中取得全局最小的驻点才对应基态。

虚构的错误 AI 推理（故意：把必要条件当充分条件）

“由 $\delta E[\psi] = 0$ 可知 ψ 是本征态；又因为变分原理给出 $E[\psi] \geq E_0$ ，所以任意驻点都是基态。”

错误位置：不等式只说明所有试探态的能量不低于 E_0 ；它不把任意本征值变成 E_0 。推理遗漏了“全局最小”这个条件。

5.4 二能级反例是最小 oracle

取

$$H = \begin{pmatrix} 0 & 0 \\ 0 & \Delta \end{pmatrix}, \quad \Delta > 0,$$

并令

$$|\psi(\theta)\rangle = \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix}.$$

该态已经归一化，故

$$E(\theta) = \langle \psi(\theta) | H | \psi(\theta) \rangle = \Delta \sin^2 \theta. \quad (8)$$

在 $\theta = 0, \pi/2, \pi, \dots$ 处， $dE/d\theta = 0$ ；但 $\theta = \pi/2$ 对应能量 Δ 的激发态，而非基态。这个 2×2 模型是审计“驻点即基态”错误的最小 oracle：不依赖 LLM 输出，并可直接计算所有结论。

课堂核查：4 分钟，两人一组 + 现场提问 请用式 (8) 回答：

1. 哪些 θ 给出全局最小？哪些给出最大？
2. 若优化程序停在 $\theta = \pi/2$ ，它满足驻值条件吗？满足变分上界吗？
3. 仅报告“梯度已收敛”能否证明找到了基态？
4. 还需要什么独立检查：多初值、精确对角化、误差条，还是参数扫描？

两人一组用二能级模型写出一条错误主张和一个 oracle，并写出用 oracle 证伪该主张的计算。教师随后把陷阱问题“采样 100 个构型后能量不再下降，能否断言找到基态？”真实发给 LLM，当场用 oracle 检验这段流畅的回答。

5.5 公式审计卡

审计项目	对变分原理要问什么	可复核依据
符号与定义域	H 是否自伴？ ψ 是否非零且属于定义域？	原文定义、教材定理、算符域说明。
归一化与尺度	为什么式 (3) 有分母？	$\psi \rightarrow a\psi$ 后能量应不变。
逻辑类型	结论是上界、等式、驻值条件还是经验观察？	谱分解、变分计算或数值反例。
等号条件	何时达到 E_0 ？是否允许基态简并？	基态子空间与系数 c_n 的条件。
反例与基准	最小模型能否推翻某个看似合理的推论？	二能级矩阵、精确对角化或解析极限。
数值实现	优化器停止、采样误差和 ansatz 偏差如何区分？	多初值、精确基准、误差条与参数扫描。

6 从公式阅读到可执行研究问题

6.1 把“理解公式”改写为可检验任务

阅读公式后的下一步不是笼统地问“能否用 AI 做这个问题”，而是明确研究对象、可观测量、主张、oracle 和验收条件。例如，对一个有限维 Hamiltonian $H(g)$ 和参数化试探态 $|\psi_\theta(g)\rangle$ ，可写成：

问题：在 $g \in [0, 2]$ 的给定网格上，参数化试探态能否将变分能量 $E_\theta(g)$ 逼近精确基态能量 $E_0(g)$ ？

主张：对每个规定的 g ，优化后满足

$$0 \leq E_\theta(g) - E_0(g) \leq \varepsilon.$$

oracle：有限维矩阵的精确对角化给出 $E_0(g)$ 。

验收：报告 g 网格、初值、优化停止条件、能量误差、随机种子和失败点；不将“优化器收敛”表述为“已经得到基态”。

边界：结论只针对该 Hamiltonian、ansatz、参数范围和有限维基准，不能径直推广到更大系统。

6.2 从宽泛兴趣到研究问题

宽泛表述

“我想用 LLM 阅读一篇关于神经网络量子态的论文。”

可执行表述

“我将定位该论文中变分能量定义和优化目标的原文位置，列出 ansatz、采样方式和 Hamiltonian 的假设；对一个有限系统用精确对角化作为 oracle，检查文中或复现代码报告的能量误差是否满足给定容差（tolerance）；最后说明该比较不能证明哪些更大系统或热力学极限结论。”

可证伪条件

若关键公式无法在原文定位，符号定义与实现不一致，或有限基准的能量误差超出容差，则不能接受“该方法在此设置下达到预期精度”的主张。

6.3 课程提交规范：整合阅读、审计与下一步任务

前一节的“单次 AI 调用规范”只约束一次模型或工具交互；下面的课程提交规范覆盖完整 workflow，可以包含多次调用、原文回查、独立计算、人工判断和最终问题定义。两者不是同一层级。

字段	提交时需要写清楚的内容
论文与位置	题目、作者、版本、页码/公式号/图号；引用的原文片段。
物理问题	体系、自由度、可观测量和作者实际要回答的问题。
关键主张	一句可被支持或证伪的陈述；不要只写“研究相变”或“使用机器学习”。
公式或算法步骤	符号表、输入输出、假设、近似和结果的逻辑类型。
物理审计	至少两项：量纲、极限、对称性、已知特例、反例、独立基准或误差分析。
下一步任务	最小可复现实验、oracle、验收条件、失败模式与记录要求。
AI 使用记录	模型/工具与访问日期、是否检索或执行工具、输入材料、用途、采纳或修改内容，以及人工核查方式。

7 课堂收束：把审计卡转成问题定义卡

活动时间：4 分钟；先独立填写，再与同伴互检

材料：使用前面已经完成的阅读卡和公式审计结果，不重新概括整篇论文。

目标：将已经核查的论文主张转化为一项成功与失败都有可观察判据的任务，填写课堂活动卡 B 部分（AI4Phys-2-auditcard.pdf）。

问题定义卡内容：

1. 一句可证伪主张。
2. 一个独立 oracle 或最小基线，以及它能排除的错误主张。
3. 一项定量或可观察的验收条件。
4. 第一步最小任务和一项可能失败模式。

7.1 互检标准

一张合格的问题定义卡必须建立在可追溯的阅读卡和公式审计上：

1. 读者能找到你引用的原文位置，而不是只看到 AI 的复述。
2. 读者能区分作者报告的结果、你据此完成的推导和尚待确认的猜测。
3. 关键公式的符号、定义域和近似均已写明。
4. 你提出的 oracle 独立于待审计输出，且能明确排除至少一种错误主张。
5. 后续任务的成功与失败均有可观察的判据，而非“让 AI 再解释一次”。

8 作业、阅读与最小提交材料

8.1 作业 1：AI 辅助论文理解、公式审计与问题定义

提交内容：

1. 一页中文导读：论文研究什么，作者实际主张什么，证据和边界分别是什么。
2. 一个关键公式或算法步骤：原文定位、符号定义、推导/复现说明与至少两项物理审计。
3. 初步问题定义表：可证伪主张、独立基准 (oracle)、验收条件、最小任务与失败模式。
4. AI 使用记录：模型/工具与访问日期、检索或工具调用、输入材料、用途、人工核查、采纳内容和未采用内容；未使用 AI 时说明替代核查方式。

评分重点：原文核查、物理判断、问题定义和记录完整性；不以 AI 输出篇幅或术语数量评分。

提交方式与截止时间：以课程平台通知为准；可在课程平台发布的可填写模板 AI4Phys-2-homework.pdf 上完成，或按相同字段提交排版后的 PDF。

8.2 建议阅读

1. G. Carleo *et al.*, “Machine Learning and the Physical Sciences,” *Rev. Mod. Phys.* **91**, 045002 (2019): 引言与任务分类部分。
<https://doi.org/10.1103/RevModPhys.91.045002>
2. S. Keshav, “How to Read a Paper,” *ACM SIGCOMM Computer Communication Review* **37**(3), 83–84 (2007): 三遍阅读法；其第三遍“虚拟重构”对应本讲可复核的阅读卡。
<https://doi.org/10.1145/1273445.1273458>
3. 一篇与自己研究方向相关的原始论文（作业 1 使用）：优先选择包含清晰模型、关键公式和可对照结果的论文。
4. 课程资源页的“从 token 到工具调用”概念图：复习各组成部分及其证据边界。
5. D. J. Griffiths and D. F. Schroeter, *Introduction to Quantum Mechanics*: 变分原理章节，用于核查式 (3)–(7) 的条件与等号情形。

9 本讲小结与自检

9.1 带走的六句话

1. 本讲讨论的自回归 LLM 在有限上下文中反复预测下一 token；Transformer 是架构，检索与工具调用是外部通道。
2. 注意力权重和展示的中间推理本身不是解释，也不证明结论正确。
3. LLM 的解释是候选阅读路径，不是论文原文或公式正确性的证据。
4. 可靠阅读记录要同时写明主张、证据、边界和原文位置。
5. 公式审计先问条件、定义和逻辑类型，再问推导是否流畅。
6. 好的问题从论文中的一句主张出发，明确 oracle、验收条件和可证伪结果。

9.2 自检问题

1. token、上下文、注意力、下一 token 概率和采样分别做什么？
2. 检索结果或工具执行结果为何更可追溯，却仍不能免检？
3. 为什么注意力权重或长推理文本不能直接证明答案正确？
4. 阅读卡中的“边界”和“位置”分别解决什么问题？
5. 变分上界依赖哪些前提？为什么二能级模型中 $\theta = \pi/2$ 是驻点却不是基态？
6. 为你准备阅读的论文写出一个可证伪主张、一个 oracle 和一个验收条件。