

## 第 3 讲

# Coding Agent 与 可复现数值实验

AI 赋能的物理学研究：工具、方法与前沿

**AI 提出候选，人类研究者确立结论。**

*AI proposes candidates; the human researcher establishes the conclusion.*

周毅

中国科学院物理研究所

2026 年 9 月



# 可运行脚本何以成为可信物理结果？

---

当 Coding Agent 能迅速写出、  
运行并修改数值代码时，  
**一个可运行的脚本何以成为  
可复核的物理结果？**

## 本讲立场

Agent 可以提出候选实现、测试草稿和调试线索；任务规范（task specification）、最小权限、独立基准、物理审计和完整运行记录，才决定结果是否可信。

# 本讲按一条证据链组织

## 六个环节，90 分钟



$10 + 17 + 15 + 25 + 15 + 8 = 90$  分钟。

### 共同数值案例

一维SSH 模型 (Su-Schrieffer-Heeger 二聚化链): 周期边界解析色散、二聚化极限、端点态与有限尺寸扫描。


### 课堂产出

一份可验收任务规范、一张 SSH 验证卡，以及一项最小可复现实验计划。

# 共同案例：一维 SSH 模型

本讲任务、演示与审查的共同对象

- 每个单元胞含 A、B 两个格点。
- 跃迁交替：胞内  $t_1$ ，胞间  $t_2$ 。
- 开链（OBC）首尾截止；周期链（PBC）多一条末端键。



## 为什么选它

有解析能带、两个可手算的二聚化极限和端点局域态：每一步都能设独立基准。

一个简单的模型，足以撑起一整条证据链。

# 本讲交付可验证、可复现的数值 workflows

---

1. 将物理问题写成模型、输入、输出、边界、测试和验收条件齐全的任务规范。
2. 将 Coding Agent 视为受约束协作者：其计划、代码和自我解释都不是独立证据。
3. 区分单元测试、回归测试、物理基准和独立 oracle 的作用。
4. 用 SSH 的解析能带、二聚化极限、端点局域性和有限尺寸扫描审计实现。
5. 交付代码、测试、环境、命令、参数、种子、图表脚本和 AI 使用记录。

**每节一个证据问题；每页一个可检验结论。**

证据问题 1

**一项数值任务如何才算  
可以验收？**

# 可运行不是数值正确

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

## 三类常见错觉

- Agent 能解释每一行代码  $\Rightarrow$  模型已被核查。
- 本征值程序没有报错  $\Rightarrow$  矩阵构造和边界条件正确。
- 图像与预期很像  $\Rightarrow$  已通过物理验证。

## 这些仍未被证明

- Hamiltonian 与基矢顺序
- 参数约定与边界条件
- 数值方法与误差控制
- 物理解释与结论边界

同一 Agent 生成的代码、测试、解释和图表不是相互独立的证据。

# 任务规范先定义什么算正确

## 自然语言问题必须变成可检查的承诺

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

| 字段    | 需要明确的内容                               |
|-------|---------------------------------------|
| 物理问题  | 研究哪个模型、可观测量或现象；哪些结论需要判断？              |
| 模型与约定 | 自由度、Hamiltonian、单位、基矢顺序、参数范围和边界条件。    |
| 输入与输出 | 函数接口、数据形状、图表、表格和保存路径。                 |
| 允许与禁止 | 可用库、可读写目录、网络和命令权限；禁止处理的数据、密钥和破坏性操作。   |
| 最小测试  | 手工矩阵、解析式、已知极限、对称性或独立小系统基准。            |
| 验收条件  | 比较量、容差 (tolerance)、失败判据、随机种子和必须报告的边界。 |

任务规范并非给 Agent 的修辞模板，而是人、代码、测试和结果共同契约。

# SSH 任务规范：先写接口与验收，再写代码

## 最小版本

**问题：**构造  $L$  个单元胞的无自旋 SSH 链，比较 PBC 与 OBC 的单粒子谱。

**输入：** $L \in \mathbb{N}$ 、实数跃迁  $t_1, t_2$ 、边界参数 `periodic`。

**输出：**Hamiltonian、排序本征值、PBC 解析能带比较、OBC 低能态概率分布。

**最小测试：**Hermiticity;  $t_2 = 0$ ;  $t_1 = 0$ ; PBC 解析色散。

**验收：**保存参数、版本、命令和图表脚本；任一最小测试失败时，不报告拓扑或边界态结论。

## 谱比较的明确容差

排序后逐项比较数值与解析 PBC 谱：

$$\max_j |E_j^{\text{num}} - E_j^{\text{ana}}| \leq 10^{-10} \max(1, |t_1| + |t_2|).$$

模型已在开场引入；Hamiltonian 与解析能带将在第 3 节正式写出。这里只关注如何把问题写成可验收的接口与判据

# 失败判据防止事后解释

理解一个方法，就是理解它的失败模式

## 待检验主张

在本讲的截断（termination，链末端从哪条键截止）与手征对称性约定下，若  $|t_2| > |t_1|$  且链长相对局域长度足够大，则有一对端点局域低能态，其能量劈裂随  $L$  增大而减小。

出现以下任一情况，即不接受该主张：

1. PBC 谱未在指定容差内匹配解析  $E_{\pm}(k)$ 。
2.  $t_1 = 0$  的 OBC 极限没有两个零本征值。
3. 被标为边界态的本征矢，其主要权重在链中央而非端点附近。
4. 改变  $L$  后，劈裂和局域性随尺寸的变化违背预期。

**先决定什么结果会推翻主张，才能避免“代码运行后再解释”。**

# 课堂操作：把宽泛请求改成可验收任务

4 分钟，两人一组

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

---

## 宽泛

“请用 Agent 写一个模拟 Ising 模型的程序，并画出相图。”

## 可验收

明确维度、耦合、边界条件和 Agent 可读写目录；先对照一维精确解与高温极限；扫描系统尺寸；测试失败时报告磁化强度差异而非生成相图。

**课堂行动** 两人一组：为自己的一个数值任务补齐模型约定、一个 oracle、一个容差和一个失败判据。

证据问题 2

# Coding Agent 如何成为受约束协作者？

# 人机分工应围绕证据，而非“自动化程度”

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

| 环节    | Agent 可以协助            | 研究者必须负责               |
|-------|-----------------------|-----------------------|
| 规划    | 文件结构、函数接口、测试清单和待澄清问题。 | 模型、边界、物理目标、权限和验收标准。   |
| 实现    | 函数、测试、文档字符串和作图草稿。     | 矩阵元、索引、单位、库调用和参数约定。   |
| 运行与调试 | 报错解释、问题定位和修补候选。       | 命令、文件访问和是否接受修改。       |
| 验证    | 比较表、回归测试和可视化候选。       | 独立 oracle、误差、收敛与物理含义。 |
| 交付    | README、环境和运行说明。       | 完整记录、可复核结论与 AI 使用披露。  |

Agent 可以协助实现；研究者不能把定义正确性的责任外包。

# Agent 的自我修正不是独立验证

## 看似严谨的闭环

Agent 写代码 → Agent 生成测试 →  
Agent 运行测试 → Agent 解释图像 →  
“已验证”。

## 共享错误来源


代码、测试、解释和图像可能继承同一个错误基矢顺序、错误边界条件或错误物理假设。

**相互一致不等于相互独立。**

**解析基准、手工矩阵和独立实现才能针对同源错误提供外部约束。**

# 建议采用“计划-最小改动-自动测试-物理审计”循环

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交



1. 先要求计划，列出文件、接口、测试和待澄清问题。
2. 一次只改一个函数或一个测试，避免无关重构掩盖物理错误。
3. 先读差异，再运行；测试通过后仍须做物理审计。
4. 保留失败的输入、报错和修补过程。

循环的每一步都留下可读、可测、可回滚的记录。

# 教师演示：同一 SSH 任务，两种请求

4 分钟，两次真实调用对比

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

## 第一次：宽泛请求

“帮我检查这个 SSH 代码。”

计划、测试与改动范围全凭 Agent 自行发挥。

## 第二次：规范任务卡（沿用 p11 结构）

只读沙盒目录、不改文件；审查 `ssh_hamiltonian` 的键连接与边界处理；以 PBC 解析色散与  $t_1 = 0$  极限为基准；先交计划、测试清单与预期输出，等待人工确认。

**课堂行动** 教师演示：对同一 SSH 任务连发两次真实调用；全班并排对比两次的计划质量与改动范围。

演示环境：独立沙盒目录（仅预置教学代码与空测试目录），Coding Agent 以最小权限运行、禁止联网安装；预跑记录与截图已备案。

**同一任务、同一 Agent：任务规范改变计划质量与改动范围。**

# 最小权限是科学 workflows 的一部分

## 最小权限 (least privilege) 原则

每个工具、Agent 和协作者只获得完成当前任务所必需的最小权限——文件、命令、网络、数据和凭证概莫能外；不确定是否需要时，默认不授予。它既是安全原则，也是科学原则：权限边界限制了错误能被 Agent 放大的范围，并使每一次执行可解释、可审计。

| 风险点    | 最低要求                                   |
|--------|----------------------------------------|
| 文件与命令  | 在专用工作目录中运行；不执行无法解释、会删除文件或改变系统状态的命令。    |
| 网络与数据  | 未发表数据、审稿内容、个人信息和受限代码不得上传到未授权服务。        |
| 凭证与密钥  | 不在提示、代码、Notebook、终端历史或公开仓库中写访问令牌。      |
| 依赖与环境  | 记录 Python、库和系统版本；导出环境文件，避免只依赖本机隐式状态。   |
| 随机性与修改 | 保存随机种子、关键提示、Agent 实际改动、人工修改、测试命令和失败案例。 |

可复现不等于“代码公开”；它要求同等授权的读者能重走结果生成路径。

# 课堂操作：执行前先审查 Agent 计划

4 分钟，两人一组

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

## 拟议计划

“我将重写项目目录、安装最新依赖、运行所有脚本，并根据输出自动修复错误。”

第一步：用四个问题审查这份计划。

1. 哪些文件、命令、网络访问或安装动作尚未获授权？
2. 如何把计划缩小为一个可阅读、可回滚的最小改动？
3. 应要求 Agent 先列出哪些测试和预期输出？
4. 哪项物理检查不能由同一段实现及其自测替代？

**课堂行动** 第二步：两人一组，将拟议计划改写为“修改范围、权限、测试、验收、记录”五项清单。

证据问题 3

# SSH 实现如何经受物理 审计？


# 先固定模型、基矢和边界条件

## 一个布尔参数对应一条实际跃迁

$$H_{\text{OBC}} = t_1 \sum_{n=0}^{L-1} (|n, A\rangle \langle n, B| + \text{h.c.}) + t_2 \sum_{n=0}^{L-2} (|n+1, A\rangle \langle n, B| + \text{h.c.}).$$
$$H_{\text{PBC}} = H_{\text{OBC}} + t_2 (|0, A\rangle \langle L-1, B| + \text{h.c.}).$$

约定基矢：

$$(A_0, B_0, A_1, B_1, \dots, A_{L-1}, B_{L-1}).$$



periodic 不是作图细节：它改变连接图、动量、边界态和可得出的物理结论。

# 周期边界给出独立的解析能带基准

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

$$q(k) = t_1 + t_2 e^{-ik}, \quad H(k) = \begin{pmatrix} 0 & q(k) \\ q^*(k) & 0 \end{pmatrix}, \quad E_{\pm}(k) = \pm \sqrt{t_1^2 + t_2^2 + 2t_1 t_2 \cos k}.$$

$k = 2\pi m/L$ , 其中  $m = 0, \dots, L-1$ 。

## 可检验结论

PBC 数值矩阵的排序本征值必须逐项匹配离散  $k$  网格上的解析谱。

## 带隙

当  $t_1, t_2 > 0$ :  $\Delta_{\text{bulk}} = 2|t_1 - t_2|$ , 在  $t_1 = t_2$  闭合。

**PBC 谱基准必须匹配边界、基矢与动量约定。**

## 两个二聚化极限是更强的边界 oracle

$t_2 = 0$ : 胞内孤立二聚体



每个二聚体给出  $\pm t_1$ ; 没有端点零模。

$t_1 = 0$ : 胞间二聚体与未配对端点



$A_0$  与  $B_{L-1}$  未配对: 两个严格零模, 完全位于端点。

极限直接检验键连接和边界处理;  
一般参数下的“图像很像”做不到这一点。

# 拓扑指标不能脱离截断、对称性和有限尺寸

截断：链末端从哪条键截止 (termination)

在本讲的单元胞约定中，若

$$|t_2| > |t_1|,$$

则  $H(k)$  的非对角元  $q(k) = t_1 + t_2 e^{-ik}$  绕原点一次；这个绕行次数就是绕数  $\nu$ ，即拓扑指标，固定绕行方向后  $|\nu| = 1$ 。

本讲的模型只含 A、B 子格间跃迁，因此有手征对称性： $\Gamma = \text{diag}(1, -1, \dots)$ ， $\Gamma H \Gamma = -H$ ；加入在位项或同子格跃迁会破坏它。

## 正确的有限链表述

在指定截断、无同子格在位项且链长相对局域长度足够大时，开链有一对端点局域低能态；劈裂随  $L$  增大而减小。

**“不是严格零”不等于“没有边界态”；  
必须同时检查局域性、截断和尺寸依赖。**

# 第一个最小改动：实现构造函数，物理判断留给基准

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

```
import numpy as np
def ssh_hamiltonian(n_cells, t1, t2, periodic=False):
    h = np.zeros((2 * n_cells, 2 * n_cells), dtype=float)
    for n in range(n_cells):
        a, b = 2 * n, 2 * n + 1
        h[a, b] = h[b, a] = t1
        if n < n_cells - 1:
            h[b, 2 * (n + 1)] = h[2 * (n + 1), b] = t2
    if periodic:
        h[2 * n_cells - 1, 0] += t2
        h[0, 2 * n_cells - 1] += t2
    return h
```

## 为何使用 += ?

当  $L = 1$  时，周期键与胞内键作用于同一对轨道，故矩阵元应为  $t_1 + t_2$ ，不能覆盖为  $t_2$ 。

# SSH 验证卡：每项测试排除哪一种错误？

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

| 测试               | 应比较什么                                      | 排除什么错误              |
|------------------|--------------------------------------------|---------------------|
| 形状与 Hermiticity  | $H$ 为 $2L \times 2L$ , 且 $H = H^\dagger$ 。 | 尺寸、非对称赋值和部分索引错误。    |
| PBC 色散           | 排序数值谱与离散解析谱逐项比较，满足指定容差。                    | 漏键、错误周期键、错误跃迁或动量约定。 |
| $t_2 = 0$ 极限     | 只出现 $\pm t_1$ 的二聚体能级。                      | 胞间键未关闭或胞内键位置错误。     |
| $t_1 = 0$ OBC 极限 | 两个端点零模及其端点概率分布。                            | 误加周期键、边界索引或基矢解释错误。  |
| 手征配对             | $\Gamma H \Gamma = -H$ 与 $\pm E$ 谱配对。      | 意外在位项、同子格跃迁或符号错误。   |
| 尺寸扫描             | 改变 $L$ ，记录近零劈裂与端点权重。                       | 将有限尺寸劈裂误报为相变或实现失败。  |

单元测试能定位局部错误；解析极限与物理基准才约束实现的物理含义。

# 课堂代码审查：AI 先审 + 人工 oracle 对照

7 分钟：两人一组 + 审计卡

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

虚构的错误实现（故意：periodic=False 时仍加入末端键）

```
h[2 * n_cells - 1, 0] = h[0, 2 * n_cells - 1] = t2
```

**错误定位：**删掉 p24 的 if 守卫，开链被误加末端周期键——违反任务规范的模型约定；矩阵却仍对称、谱仍平滑：Hermiticity 检验矩阵性质，不检验是否守约。

**最小反例 ( $L \geq 2$ ):**  $H_{2L-1,0}^{\text{OBC}} = 0$ ,  
 $H_{2L-1,0}^{\text{PBC}} = t_2$ 。

**课堂行动** 两人一组：先把片段发给 AI 审查并记录结论，再用矩阵元素测试复核 AI 的判定。

AI 的审查意见也是候选；独立 oracle 才能当场判定。

## 讨论后核对：测试必须针对错误假设

---

1. 开链末端元素为零是直接检查“是否误加周期键”的最短路径。
2. Hermiticity 只说明矩阵对称，不说明它实现了正确的连接图。
3.  $t_1 = 0$  的 OBC 极限给出两个端点零模，是可手工核对的 oracle。
4. 一般参数下应同时报告谱、端点权重和随  $L$  变化的劈裂。
5. 通过上述测试之前，不能把数值输出命名为“拓扑边界态”。

好的测试不是“多跑几个”；而是每一个都能排除一种错误主张。

# 失败模式反向改写 workflow

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

| 课堂上遇到的失败            | 固化为下一轮的…                      |
|---------------------|-------------------------------|
| 开链误加末端键 (p26)       | 矩阵元素检查进入回归测试                  |
| 跑通、矩阵对称就声称正确        | PBC 解析谱与二聚化极限立为验收条件 (p21/p22) |
| 截断、基矢约定含糊 (p20/p23) | 写进任务规范的模型约定                   |
| 测试失败仍继续作图下结论        | 事先写失败判据：失败即停止解释、返回实现核查 (p10)  |
| 失败来源无法复查            | 保存输入、矩阵差异、日志与人工干预记录           |

**失败不只是一要保存的结果；  
它应改写下一轮的任务规范、测试和验收条件。**

证据问题 4

# 何为可复现的数值交付？

# 单元测试、物理基准与 oracle 不能混为一谈

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

| 层级        | SSH 例子                    | 作用与局限                    |
|-----------|---------------------------|--------------------------|
| 单元测试      | 矩阵形状、Hermiticity、周期键是否存在。 | 快速定位局部实现错误；不自动证明物理解释。    |
| 回归测试      | 固定输入的谱、图表数据或哈希保持不变。       | 防止已知结果被改坏；也可能固化原有错误。     |
| 物理基准      | PBC 色散、二聚化极限、手征配对。        | 用独立物理结构排除具体错误；须匹配同一约定。   |
| 独立 oracle | 手工小系统键、解析解或独立实现。          | 预先规定何为通过；不能与待审计代码共享错误来源。 |

oracle 是预先写明的独立判据，不是 Agent 对自身输出的解释。

# 虚构的错误 Agent 推理（故意：把必要条件当作充分验证）

反面动机：可复现交付要防的具体失败模式

## 错误推理

“矩阵是 Hermitian, `eigvalsh` 成功返回实本征值，因此开边界实现正确；若未观察到零模，该参数区间就是平庸相。”

## 错误定位

Hermiticity 是实现正确的必要条件，不是充分验证：它不检查末端是否误连为周期键，也不检查截断、二聚化极限、手征对称性或有限尺寸劈裂。

**一个可运行的实现只能产生候选；  
物理基准才决定候选能否成为结论。**

# 最小可复现实验应保留完整的结果生成路径

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → [人工提交](#)

---

```
ssh-lab/  
  src/ssh.py  
  tests/test_ssh.py  
  scripts/make_figures.py  
  outputs/  
  README.md  
  environment.yml
```

## 读 README 就应能知道

- 运行什么命令
- 应看到什么输出
- 什么结果表示失败
- 结论不能推广到什么范围

**图表不是交付终点；  
能从干净环境重走“代码-数据-图表-结论”才是。**

# 可复现交付必须记录六类材料

## 实现与验证

1. 源代码：模型、接口、默认参数和基矢约定。
2. 测试：物理理由、输入、预期输出和容差。
3. 结果：原始数值、图表、生成脚本和失败输出，不只保留截图。

## 环境与责任

1. 环境：Python、库、系统版本、种子与采样设置。
2. 命令：从干净环境到出图的完整执行顺序。
3. AI 使用记录：工具与版本、关键提示、实际修改、人工审查和未采用内容。

可复现记录应包含失败路径，因为它界定了结论在哪里不成立。

# 为今天的 SSH 审查补齐最小交付清单

2 分钟

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

---

## 以今天的 SSH 代码审查为例

审查结论本身不能说明输入、环境、测试或判定过程。

1. 这次审查的输入（两份代码版本）、环境和提示词记录在哪里？
2. AI 的审查结论经过了哪个独立 oracle 复核？
3. 哪些原始记录必须一并保存？
4. Agent 在哪里提出了候选，研究者又在哪里做了决定和修正？

课后随作业 2 完成：列出一个操作记录、一个 oracle、一个失败案例和一条 AI 使用记录。

证据问题 5

**如何将 workflows 迁移到自己的项目？**

# 把 Agent 请求写成受控的研究任务

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

## 建议结构

**物理任务：**我要实现 {模型/论文算法}，目标可观测量是 {...}。

**模型约定：**自由度、Hamiltonian、单位、基矢、边界和参数范围是 {...}。

**实现范围：**只修改 {文件或目录}；允许 {库}；不要访问网络、删除文件或读取 {受限目录}。

**测试：**先实现 {手工矩阵/解析极限/对称性/小系统}；给出预期输出和容差。

**输出：**提交代码差异、命令、测试结果、图表脚本和需要人工决定的问题。

**验收与记录：**oracle 不通过时停止扩展；记录工具/版本、提示、人工修改、种子与限制。

**好的 Agent 请求不要求“自动完成”；  
它要求明确的范围、验证标准和不确定性说明。**

# 从宽泛任务到可复现实验

## 宽泛表述

“请用 Agent 写 SSH 程序，并画出拓扑相图。”

## 可执行表述

固定基矢并分别构造 OBC/PBC；先以解析色散检查 PBC，再以  $t_2 = 0$  和  $t_1 = 0$  的 OBC 极限检查键连接；扫描  $t_1/t_2$  与  $L$ ，保存端点权重、参数和作图脚本。

## 可证伪条件

PBC 谱偏离解析基准、二聚化极限失败，或低能态不局域于端点时，不能接受“实现显示了指定截断下 SSH 边界态”的主张。

可执行表述必须同时给出验收动作和必存记录。

# 项目推进：选择最小而非最大的任务

---

## 可作为最小可复现实验的任务

- SSH 的 PBC/OBC 谱、端点态和尺寸扫描。
- 横场 Ising 链的小尺寸精确对角化。
- 自己论文中一张图的最小复现。
- 经教师确认的项目最小任务。

## 选择标准


- 有独立基准或简单极限
- 有明确失败模式
- 能保存完整运行记录
- 能在短时间内闭合验证链

**任务选择不在于代码规模，而在于能否独立验收一个物理主张。**

# 核对：先把项目组织成证据链

流程位置：任务规范 → Agent 计划 → 最小改动 → 自动测试 → 物理审计 → 人工提交

---



1. 你的结论能否写成完整句子，说清模型、参数、边界和尺寸范围？
2. oracle 是否独立于待审计实现，通过条件是否预先写明？
3. 失败时能否留下可据以定位错误的矩阵差异、日志或原始数据？
4. 另一位研究者能否照着 README 重现你的图，并说清它不能说明什么？

证据问题 6

# 如何完成并自检本讲成果？

## 作业 2: Coding Agent 与可复现数值实验

### 提交内容

1. 任务规范：模型约定、输入输出、边界、测试和验收条件。
2. 代码与测试：源文件、测试命令、至少两项物理或解析基准和失败输出。
3. 可复现记录：环境、依赖、命令、参数、种子、原始数值和绘图脚本。
4. 结果说明：通过/未通过检查、结论边界和一个失败模式。
5. AI 使用记录：工具与版本、任务、关键提示、实际修改、人工审查和未采用内容。

### 评分重点

任务规范、测试与物理判断、可复现性和诚实的失败分析；不以自动生成代码量、文件数量或图表装饰性评分。

可选择 SSH、横场 Ising 链小尺寸对角化、论文图复现或经教师确认的项目最小任务。

## 建议阅读：为代码实践与复现记录提供共同标准

1. **选读**：W. P. Su, J. R. Schrieffer and A. J. Heeger, “Solitons in Polyacetylene,” *Phys. Rev. Lett.* **42**, 1698–1701 (1979)。 <https://doi.org/10.1103/PhysRevLett.42.1698>
2. **必读**：G. Wilson *et al.*, “Good Enough Practices in Scientific Computing,” *PLoS Comput. Biol.* **13**, e1005510 (2017)：版本控制、测试与自动化部分。  
<https://doi.org/10.1371/journal.pcbi.1005510>
3. **选读**：G. K. Sandve *et al.*, “Ten Simple Rules for Reproducible Computational Research,” *PLoS Comput. Biol.* **9**, e1003285 (2013)。 <https://doi.org/10.1371/journal.pcbi.1003285>

### 阅读问题

SSH 原文的解析结果如何充当独立 oracle？Wilson 与 Sandve 的哪两条可写入运行记录？

先用小型可解释模型建立验证习惯，  
再将同一链条迁移到自己的研究。

# 带走的五句话

---

1. Coding Agent 的代码、解释和自我修正都是候选，不是正确性的独立证据。
2. 任务规范先定义模型、权限、测试和验收，实现才有可审计的正确性标准。
3. Hermiticity、无报错和漂亮图形都是必要但不充分的软件或数值条件。
4. SSH 的解析色散、二聚化极限、端点局域性和尺寸扫描共同检验实现。
5. 可复现交付必须包含代码、测试、环境、命令、参数、生成路径、AI 使用记录和失败边界。

# 离开前自检

---

1. 为什么 Agent 的“代码已通过自检”不能替代独立 oracle ?
2. SSH 的 OBC 与 PBC Hamiltonian 差别在哪一条末端跃迁 ?
3. 为什么  $t_1 = 0$  的 OBC 极限能检验端点零模和边界实现 ?
4. Hermiticity 能排除什么错误, 又不能排除哪类边界错误 ?
5. 为自己的一个数值任务写出模型约定、一个最小测试、一个 oracle 和一个失败判据。
6. 你最近的一次失败改写了哪条任务规范、测试或验收条件 ?

提交前逐项核对: 任务规范、权限边界、独立基准、环境命令、失败记录与 AI 使用记录。

**代码可以很快；  
结果必须可复现。**

第 3 讲结束