第 5 讲课后任务材料

作业 4 / 方法实践 A

Ising 相分类与科学机器学习（ML）审计

AI 赋能的物理学研究：工具、方法与前沿

任务：使用提供或自行生成的二维零场 Ising 构型，比较一个物理基线和一个机器学习模型，完成从任务定义、生成组隔离、基线比较到物理一致性测试的验证链。
路径规则：本实践与第 8 讲的方法实践 B——神经网络量子态（NQS）/变分蒙特卡洛（VMC）小系统基准——二选一，共同构成第 4 项必做作业。学生在第 8 讲后确认路径；选择方法实践 B 的学生无需提交本实践。
提交：审计报告 PDF、代码与运行说明、数据/生成说明、机器可读结果表、图表生成脚本及 AI 使用记录。提交方式与截止时间以课程平台通知为准。

九项提交类别：任务卡；生成组划分；泄漏检查；物理基线；多随机种子（不少于 5 个）；临界窗口或分布变化测试；至少一个破坏性测试；结果解释；AI 使用记录。
评价原则：评价聚焦任务定义、独立验证、物理判断、可复现性和诚实的失败分析；最高准确率不是主要评价指标。
实现自检：建议在双精度小模型/小 batch 上比较有限差分与自动微分梯度；该检查服务于实现质量，不单列为第十项提交。

姓名： **学号：** **提交日期：**

A. 预注册（pre-registration）任务卡

目标：在查看最终测试结果之前，先写清模型要泛化到什么分布、什么是独立样本，以及当前实验最多允许得出哪一层结论。

1. 目标主张：一句可由当前实验支持或推翻的完整陈述

2. 输入与标签：输入包含什么、允许使用哪些输入通道？标签 $y = \mathbb{I}(T < T_c)$ 由生成协议（label-generation protocol）给出——有限尺寸下不能从单个构型读出；写明生成温度、T_c 取值与标注规则

3. 样本单位与生成组：样本单位是什么？生成组取独立 Monte Carlo（MC）链、时间块还是其他单位？为什么它可以作为划分单位？

4. 评价问题：分别说明独立同分布（IID）测试与临界窗口（或分布变化）测试各自回答什么问题

5. 优先审计：写出最值得先排查的一条泄漏路径和一个模型失败模式

B. 数据卡与隔离审计

目标：让读者能够重建数据生成与划分，并确认同一生成组、同一原始样本及其增强版本没有跨越训练、验证和测试集合。

字段	填写内容
物理模型	哈密顿量、J、外场、边界条件、格点类型。
控制参数	温度范围、温度点、尺寸 L、每组 (T, L) 的独立链数。
采样流程	算法、热化（thermalization，丢弃初始未平衡段）步数、采样间隔、每链快照数、随机种子。
实现信息	数据来源、代码版本、依赖环境、数据文件及其校验和。

1. 热化与相关性证据：展示能量/磁化强度时间序列或自相关，说明热化步数与采样间隔的依据

2. 分组划分：训练/验证/IID 测试分别包含哪些链或时间块？划分是否在任何预处理之前完成？

3. 临界/迁移集合：预留了哪些温度、尺寸、边界条件或独立采样实现？

泄漏自检

- ☐ 同一原始构型及其翻转、旋转、平移版本只出现在同一集合中
- ☐ 同一独立链或预先定义的时间块不跨集合
- ☐ 标准化、主成分分析（PCA）、特征选择和阈值候选只用训练数据拟合
- ☐ 文件名、目录、样本顺序、填充值和数组尺寸不直接编码标签
- ☐ 不同类别使用相同采样算法、精度和数据处理流程
- ☐ 测试集未用于选择阈值、模型、超参数或决定报告哪个随机种子

C. 模型、基线与实现核查

目标：写清前向计算、损失与参数更新，确定简单方法能够解释多少，再判断复杂模型是否提供了大于变异的稳定增量。所有可调参数由验证集决定。

推荐的实现自检 若使用自定义损失、层或训练实现，可选择一个参数 θ_j，用中心有限差分（FD）计算

$$g_j^{\mathrm{FD}} = \frac{\mathcal{L}(\boldsymbol{\theta} + \epsilon \boldsymbol{e}_j) - \mathcal{L}(\boldsymbol{\theta} - \epsilon \boldsymbol{e}_j)}{2\epsilon},$$

并与 `backward` 得到的自动微分（AD）梯度 g_j^{AD} 比较。建议使用双精度、固定小 batch，扫描若干 ϵ，记录相对偏差随 ϵ 的变化。

1. 模型卡：写出前向计算链、各张量形状、参数量，以及激活函数和损失的选择理由

2. 实现自检（推荐）：所做的梯度核查、小 batch 过拟合或其他独立检查，及其结果

3. 常数/多数类基线：类别比例、机会水平，以及为何选择准确率或平衡准确率

4. 物理基线： $m = L^{-2}\sum_i \sigma_i$、$\hat{y}_m = \mathbb{I}(|m| > m_0)$**；写出** m_0 **的验证集选择过程**

5. 可选简单特征模型：每格能量 $e = -L^{-2}\sum_{\langle ij \rangle} \sigma_i\sigma_j$**；若使用** $(|m|, e)$ **对数几率回归（log-odds regression），写出特征、归一化和正则化**

6. ML 模型训练：优化器、学习率、batch 大小、早停（early stopping）、训练/验证曲线和超参数候选

7. 公平比较：各方法是否使用同一生成组、指标和测试权限？调参预算如何记录？

训练随机种子结果

种子	模型/配置 ID	验证指标	IID 测试	备注
1				
2				
3				
4				
5				

8. 汇总：报告全部种子的均值与标准差，并说明该标准差没有覆盖哪些不确定度

D. 温度分辨结果、临界窗口与分布变化

目标：不只报告总准确率。结果至少沿温度展开，并完成下列两类任务中的一类：**临界窗口分析**或**预先声明的分布变化测试**。

主要结果图（粘贴或注明报告中的图号）：

建议同图展示 $|m|$ 基线与 ML 模型的 $p(y=1\mid T)$ 或温度分箱指标；
标明 T_c、训练区间、临界窗口、随机种子/独立链变异，并按尺寸分面。

1. 图的生成路径：数据表、脚本、命令、配置和输出文件分别是什么？

2. 温度分辨观察：模型与 $|m|$ 基线在哪些温度区间表现稳定？主要偏差出现在哪里？

3. 必做二选一：(a) 临界窗口中的预测概率与有限尺寸类别重叠；(b) 跨尺寸、边界条件或采样实现的迁移结果

评价汇总

评价集合	$\lvert m\rvert$ 基线	ML 均值	离散程度	解释
独立链 IID 测试				
临界窗口或迁移集				
最困难温度区间				

4. 变异来源：哪些温度区间的变异主要来自模型种子，哪些更可能来自有限样本或分布变化？

E. 物理一致性、结论边界与 AI 使用记录

目标：通过至少一个主动破坏模型捷径的测试，判断高性能是否与已知物理结构一致。

破坏性测试（至少完成一项）

测试	选择	主要判据
标签置乱后重训	☐	性能应回到机会水平。
全局自旋翻转（$\mathbb{Z}_2$，即 $\boldsymbol{\sigma} \to -\boldsymbol{\sigma}$）：比较 $p(\boldsymbol{\sigma})$ 与 $p(-\boldsymbol{\sigma})$	☐	零场标签下预测应近似不变。
平移/旋转同一构型	☐	预测不应依赖位置或边界捷径。
只用 $(\lvert m\rvert, e)$ 的特征受限模型	☐	量化复杂模型的增量。
删除文件名、顺序、填充等元数据	☐	性能不应依赖非物理通道。

1. 测试定义与结果：写出变换、指标、样本范围和定量结果

2. 模型学到了什么：当前证据支持磁化强度、能量、局部相关或其他哪种解释？

3. 结论边界：列出三项当前证据尚不足以支持的主张，并写出各自升级所需的证据

4. 下一项测试：若继续研究，哪项测试成本最低、最能区分两种竞争解释？

5. AI 使用记录：工具/模型类别、用途、输入边界、关键输出、人工核查和记录位置；若未使用 AI，注明“未使用”，并说明结果的人工核查流程

F. 可复现提交与评价维度

提交前自检

检查项	完成
模型卡写明前向链、张量形状、损失、优化器和参数量	☐
实现经过梯度核查、小 batch 过拟合或其他独立检查	☐
任务卡写明评价分布、样本单位和目标主张	☐
数据按独立链/生成组划分，相关快照和增强版本未跨集合	☐
所有预处理和模型选择均未使用测试数据	☐
报告了多数类基线、$\lvert m\rvert$ 基线和一个 ML 模型的结果	☐
至少 5 个训练种子的结果全部报告，未只挑选最佳结果	☐
结果随温度展开，并完成临界窗口或分布变化测试	☐
完成至少一项破坏性测试（标签置乱、对称性、特征受限或元数据清除）	☐
结论区分“预测标签”“利用特征”“迁移稳健”和“定位相变”	☐
代码、环境、命令、配置、结果表和图表脚本可定位	☐
AI 使用情况（或未使用声明）与人工核查流程如实记录	☐

评价维度

1. **问题定义：**评价分布、样本单位和结论层级是否明确。
2. **模型与优化：**前向链、损失、实现自检、训练曲线和参数更新是否清楚且可复核。
3. **数据隔离：**生成组划分、自相关意识和泄漏审计是否可信。
4. **比较设计：**基线是否合理调优，模型选择与计算预算是否公平。
5. **变异来源：**是否区分训练波动、有限样本和系统偏差。
6. **物理解释：**对称性、临界区、尺寸效应和结论边界是否处理正确。
7. **可复现与责任：**材料能否重建结果，AI 使用是否透明且人工核查充分。

建议阅读

1. **必读：**P. Mehta et al., “A High-Bias, Low-Variance Introduction to Machine Learning for Physicists,” *Phys. Rep.* **810**, 1–124 (2019)，选读监督学习、神经网络基础和 Ising 案例部分。
https://doi.org/10.1016/j.physrep.2019.03.001
2. **选读：**J. Carrasquilla and R. G. Melko, “Machine Learning Phases of Matter,” *Nat. Phys.* **13**, 431–434 (2017).
https://doi.org/10.1038/nphys4035