第 4.5 讲

机器学习零基础入门
概念与最小训练闭环

AI 赋能的物理学研究：工具、方法与前沿

零基础桥接讲义（Bridge Note）

周毅

中国科学院物理研究所

2026 年 10 月

本讲核心问题

机器学习与人工编写固定规则有什么不同？模型究竟从数据中“学”到了什么？
样本、特征、标签、模型、预测、参数和损失如何连接成一次训练？
怎样用独立数据判断模型能否处理新的物理数据？

本讲定位：这是第 4 讲与第 5 讲之间的 90 分钟翻转式桥接单元。首要目标是为没有任何机器学习基础的学生建立概念地图；公式、手算和代码帮助看清概念之间的关系，完成标准是能够复述并使用这张概念地图。第 5 讲将在此基础上展开数据泄漏、分布外测试、物理基线和 Ising 科学验证。

本讲用“根据实验特征预测一个连续量”作为贯穿例子，
先建立直觉，再观察一次梯度更新和一条最小 PyTorch 训练链。
本讲从零开始；学生能够阅读基本 Python 即可，公式推导由教师引导。

Contents

1 本讲目标与完成方式 **3**
1.1 核心学习目标 . . . 3
1.2 90 分钟桥接安排 . . . 3

2 机器学习是什么 **3**
2.1 从人工规则到从例子学习 . . . 3
2.2 训练与推断 . . . 4

3 从科研数据到学习任务 **4**
3.1 监督学习的最小对象 . . . 4
3.2 数据表示、划分与预处理 . . . 5
3.3 分类、回归、监督与无监督 . . . 6
3.4 参数、超参数与模型容量 . . . 6

4 最小模型与损失：用公式明确角色 **6**
4.1 线性回归：预测一个连续量 . . . 7
4.2 对数几率回归（log-odds regression）：输出二分类概率 . . . 7
4.3 神经网络是可训练函数的组合 . . . 8
4.4 训练损失、经验风险与报告指标 . . . 8

5 训练如何组织：认识 batch 与 epoch **8**
5.1 四个常用训练单位 . . . 9
5.2 从 batch 损失到一次更新 . . . 9

6 教师引导：梯度如何产生一次参数更新 **9**
6.1 先手算一个标量例子 . . . 9
6.2 学习率决定步长，不决定目标 . . . 10

7 代码地图：最小 PyTorch 训练闭环 **10**
7.1 数据加载与关键训练步骤 . . . 10
7.2 运行前先检查形状 . . . 12
7.3 训练模式与评价模式 . . . 12

8 训练、验证与测试的权限 **12**
8.1 三个集合回答三个问题 . . . 12
8.2 欠拟合、过拟合与泛化间隙 . . . 13
8.3 桥接单元建立数据权限，第 5 讲展开验证专题 . . . 13

9 概念自检与第 5 讲衔接 **13**
9.1 八项概念自检 . . . 13
9.2 本讲小结 . . . 14
9.3 建议阅读 . . . 14

1 本讲目标与完成方式

1.1 核心学习目标

完成本讲后，你应能够：

1. 用自己的语言说明机器学习与固定规则程序的区别，以及训练与推断的区别。
2. 在一个物理例子中指出样本、特征、标签/目标、模型、预测、参数和损失。
3. 根据目标判断分类或回归，区分监督学习与无监督学习。
4. 沿“数据 → 模型 → 预测 → 损失 → 参数更新 → 新数据检验”解释完整学习闭环。
5. 说明训练集、验证集和测试集的分工，并直观识别欠拟合与过拟合。

1.2 90 分钟桥接安排

时长	环节	学习产出
15 min	机器学习是什么	比较固定规则与从例子学习；区分训练和推断。
15 min	基本对象	在贯穿例子中识别样本、特征、标签、模型、参数、预测和损失。
15 min	常见任务	区分分类/回归、监督/无监督，定位线性模型与神经网络。
15 min	模型如何学习	用预测误差、损失、参数、梯度和学习率解释一次改进。
10 min	训练如何组织	直观理解 dataset、batch、iteration、epoch。
10 min	最小代码地图	观察数学对象如何对应到 PyTorch 训练链。
10 min	新数据与概念自检	识别欠拟合/过拟合，理解训练、验证、测试分工。

本讲完成标准 用普通语言说明模型接收什么、输出什么、怎样调整参数，以及如何判断它能否处理没见过的数据。公式和代码为这张概念图提供精确表达。

2 机器学习是什么

2.1 从人工规则到从例子学习

传统程序通常由人明确写出规则：

$$\boxed{\text{输入} + \text{人工规则} \longrightarrow \text{输出}}.$$

例如，若温度换算关系已知，程序只需执行给定公式。监督机器学习采用不同分工：

$$\boxed{\text{输入–目标示例} + \text{模型} + \text{损失} \longrightarrow \text{训练后的参数}}.$$

研究者定义数据、模型形式和评价方式，训练过程根据许多示例调整模型参数。因此，机器学习中的“学习”首先是**参数随训练数据改变**。物理规律、因果机制和解释范围还需要独立证据支持。

方式	人提供什么	计算机做什么
固定规则程序	明确公式、阈值或算法步骤	对新输入执行相同规则。
监督机器学习	示例、模型、损失和训练设置	调整参数，使预测更接近目标。

2.2 训练与推断

训练（training）阶段可以看到训练样本的目标，并反复调整参数；**推断（inference）**阶段固定训练后的参数，只把新输入变成预测。一套模型在训练时做的事和投入使用时做的事不同：

$$\text{训练：数据与目标} \to \text{调整参数}, \qquad \text{推断：新输入} \to \text{预测}.$$

先建立六步概念图

$$\boxed{\text{数据} \to \text{模型} \to \text{预测} \to \text{损失} \to \text{参数更新} \to \text{新数据检验}}.$$

本讲后面的术语、公式和代码为这六个位置填写更精确的名称。

3 从科研数据到学习任务

3.1 监督学习的最小对象

给定 N 个样本，可把输入写成

$$X = \begin{bmatrix} \boldsymbol{x}_1^{\mathsf{T}} \\ \boldsymbol{x}_2^{\mathsf{T}} \\ \vdots \\ \boldsymbol{x}_N^{\mathsf{T}} \end{bmatrix} \in \mathbb{R}^{N \times d}, \qquad \boldsymbol{y} = (y_1, \ldots, y_N)^{\mathsf{T}}.$$

$\boldsymbol{x}_i \in \mathbb{R}^d$ 是第 i 个样本的 d 个输入特征，y_i 是该样本的目标。监督学习寻找一个带参数的映射

$$\hat{y}_i = f_{\boldsymbol{\theta}}(\boldsymbol{x}_i),$$

使预测 $\hat{y}_i$ 与目标 y_i 在选定损失下尽量一致。

对象	例子	必须能回答的问题
样本 sample	一次实验、一幅图像、一个构型	什么算一个独立研究对象？
特征 feature	温度、谱峰、像素、局域环境	哪些量被输入模型？单位和形状是什么？
标签/目标 target	类别、能量、力、参数	它来自测量、计算、人工规则还是生成协议？
参数 parameter	w, b 或网络权重	哪些量由训练数据更新？
超参数 hyperparameter	学习率、层数、正则化强度	哪些量由研究者设定或用验证集选择？
预测 prediction	$\hat{y}$ 或 $p(y=1 \mid x)$	输出是实数、类别还是概率？
损失 loss	MSE、BCE	它比较预测与目标的什么差距？

第一项基本习惯　看到一个机器学习问题时，先写出 X 的形状、y 的含义、模型输出的形状，再讨论算法名称。样本和特征维度混淆，会使代码即使运行也回答错误问题。

3.2　数据表示、划分与预处理

原始数据通常不能直接进入模型。一个最小数据流程是

$$\boxed{\text{原始数据} \to \text{定义样本单位与特征} \to \text{划分数据} \to \text{拟合预处理} \to \text{训练模型}}.$$

首先确认每一行或每一个张量（多维数组）究竟代表一个独立样本，记录特征单位、缺失值、异常值和测量精度。随后先划分训练、验证和测试数据，再只用训练集估计预处理参数。

例如，对第 j 个连续特征做标准化：

$$\tilde{x}_{ij} = \frac{x_{ij} - \mu_j^{(\mathrm{train})}}{s_j^{(\mathrm{train})}},$$

其中均值 $\mu_j^{(\mathrm{train})}$ 和标准差 $s_j^{(\mathrm{train})}$ 只能由训练集计算，再冻结并应用到验证集、测试集和未来数据。标准化不会增加信息，但可避免不同单位或量级使优化器沿某些方向步长极不均衡。

数据权限规则　先划分训练、验证和测试数据，再用训练集拟合均值、方差、主成分或特征选择等变换，最后把同一变换应用于其余数据。这个顺序保持测试数据独立。

3.3 分类、回归、监督与无监督

任务	目标形式	物理例子
回归 regression	连续数值 $y \in \mathbb{R}^m$	从结构预测能量；从标定信号估计参数。
分类 classification	离散类别 $y \in \{1, \dots, K\}$	判断谱线所属类型；识别已定义的状态区域。
监督学习 supervised	训练样本带目标 (x_i, y_i)	用已知能量或类别拟合预测映射。
无监督学习 unsupervised	只有输入 x_i	聚类（clustering）、降维或表示学习（representation learning）寻找低维结构；结果仍需物理解释。

分类与回归由**要预测的目标**决定。同一个神经网络可以输出连续量，也可以输出类别概率。无监督学习通过距离（样本间相似性的度量，如 $\|\boldsymbol{x}_i - \boldsymbol{x}_j\|$）、表示、维数和聚类规则等建模选择组织未标注数据。

3.4 参数、超参数与模型容量

训练阶段用带目标的数据和损失调整模型参数：

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} \mathcal{L}.$$

推断阶段固定这些参数，只把新输入映射为预测。模型参数由训练更新；学习率、batch 大小（一次更新用的样本数）、训练轮数（遍历训练数据的次数）、模型宽度（网络每层的单元数）和正则化强度是超参数，由研究者设定或借助验证集选择。

模型容量 容量描述模型可以表示多复杂的输入–输出关系。容量不足可能欠拟合；容量很大则可能记住训练数据中的偶然模式。训练表现、验证表现和简单基线共同支持模型容量选择。

两分钟任务卡 任选一个熟悉的物理数据问题，写出：

一个样本 = _____, 输入 = _____, 目标 = _____.

再判断它是分类、回归还是暂时没有标签的探索任务。

4 最小模型与损失：用公式明确角色

4.1 线性回归：预测一个连续量

最简单的标量线性模型是

$$\hat{y} = wx + b.$$

对 d 维输入，它推广为

$$\hat{y} = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b.$$

给定一批回归样本，常用均方误差（mean squared error, MSE）

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

衡量预测与目标的平均平方偏差。

> **线性模型提供最低基线**　它回答特征的线性组合能解释多少，并让参数、单位和误差容易检查。当更复杂模型提供稳定增量时，增加容量就有明确理由。

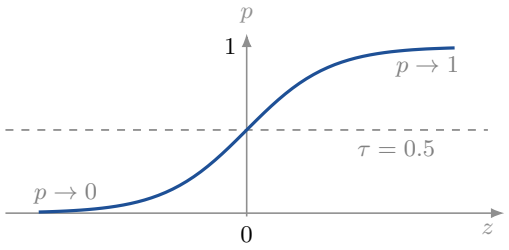
4.2 对数几率回归（log-odds regression）：输出二分类概率

对二分类目标 $y \in \{0,1\}$（该样本的类别标签），先计算标量分数 z（score，第 5 讲称 logit；无界实数，越大越支持正类，还不是概率）

$$z = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b,$$

再用 sigmoid 函数把任意实数映射到 $(0,1)$：

$$p_\theta(y=1 \mid \boldsymbol{x}) = \sigma(z) = \frac{1}{1+e^{-z}}.$$



$p_\theta(y=1 \mid \boldsymbol{x})$ 表示给定 $\boldsymbol{x}$ 时该样本属于正类（$y=1$）的概率。等价地，

$$\log\frac{p}{1-p} = z = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b,$$

即模型是对数几率（log-odds）上的线性回归，名称由此而来。二元交叉熵为

$$\mathcal{L}_{\mathrm{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log p_i + (1-y_i)\log(1-p_i)\right].$$

当真实标签为 1 时，模型应提高 p_i；当标签为 0 时，模型应降低 p_i。

分数、概率和类别各有角色　z 是未归一化分数，$p=\sigma(z)$ 是模型给出的概率参数，$\hat{y}=\mathbb{I}(p>\tau)$ 才是阈值 τ 下的类别决定。改变阈值不会重新训练参数，但会改变分类结果。

4.3 神经网络是可训练函数的组合

一层隐藏层的多层感知机（multi-layer perceptron, MLP）可写成

$$\boldsymbol{h}=\phi(W_1\boldsymbol{x}+\boldsymbol{b}_1),\qquad \hat{\boldsymbol{y}}=W_2\boldsymbol{h}+\boldsymbol{b}_2.$$

其中 ϕ 是逐元素非线性激活。若没有非线性激活，多层线性映射仍可合并为一个线性映射。第 5 讲将进一步讨论激活、参数量、反向传播和科学验证；本讲只需认出：

$$\boxed{\text{输入}\to\text{带参数的计算}\to\text{预测}\to\text{损失}}.$$

4.4 训练损失、经验风险与报告指标

单个样本的损失写作 $\ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i),y_i)$；这里的“损失”不是丢失了什么，而是预测错了要付多少代价，代价规则由研究者选定。对训练集取平均得到经验风险

$$\widehat{R}_{\text{train}}(\boldsymbol{\theta})=\frac{1}{N_{\text{train}}}\sum_{i=1}^{N_{\text{train}}}\ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i),y_i)\,.$$

训练的直接目标是减小经验风险；加入参数惩罚后可写成

$$\widehat{R}_{\text{train}}(\boldsymbol{\theta})+\lambda\Omega(\boldsymbol{\theta}),$$

其中 λ 是控制正则化强度的超参数。

损失需要可用于优化，报告指标则应回答研究问题。二分类可用 BCE 训练，但报告准确率、精确率、召回率或 ROC-AUC；回归可用 MSE 训练，但报告 MAE、RMSE 或具有物理单位的误差。二者相关，并分别承担优化与解释职责。ROC-AUC 综合所有阈值下的分类表现（0.5 接近随机）；MAE 为平均绝对误差；RMSE 为均方根误差，量纲与目标相同。

分别写出优化目标与报告指标　模型可能在概率校准上降低 BCE，却未改变固定阈值下的准确率；也可能降低少数大残差主导的 MSE，却没有改善所有物理区间。训练前分别写出优化目标和最终报告指标，便于解释两者的变化。

5 训练如何组织：认识 batch 与 epoch

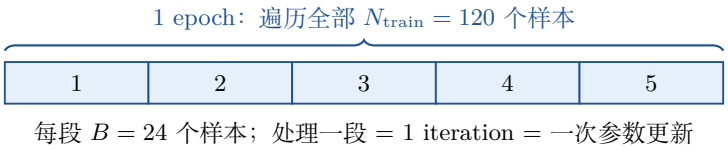
5.1 四个常用训练单位

术语	含义
dataset	当前数据集合中的全部样本。
batch / mini-batch	一次前向、反向和参数更新使用的一组样本。
iteration / step	处理一个 batch 并执行一次参数更新。
epoch	训练流程大致遍历全部训练样本一次。

若训练集有 $N_{\text{train}} = 120$ 个样本，batch size 为 $B = 24$，且不丢弃最后一个 batch，则每个 epoch 有

$$\left\lceil \frac{N_{\text{train}}}{B} \right\rceil = 5$$

次 iteration；训练 20 个 epoch 约执行 100 次参数更新。



batch size 控制单次梯度估计使用多少样本，也影响内存、梯度噪声和优化速度。

5.2 从 batch 损失到一次更新

对 batch $\mathcal{B}$，常用平均损失

$$\mathcal{L}_{\mathcal{B}}(\boldsymbol{\theta}) = \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i), y_i)\,.$$

一次 iteration 先用当前参数计算 batch 预测和损失，再求 $\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\mathcal{B}}$，最后更新参数。shuffle 改变每个 epoch 中样本组成的顺序；数据独立性由划分规则保证。

6 教师引导：梯度如何产生一次参数更新

6.1 先手算一个标量例子

考虑无偏置模型

$$\hat{y} = wx, \qquad \mathcal{L}(w) = \frac{1}{2}(wx - y)^2.$$

由链式法则，

$$\frac{\mathrm{d}\mathcal{L}}{\mathrm{d}w} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial w} = (\hat{y} - y)x = (wx - y)x.$$

梯度下降用学习率 $\eta > 0$ 更新

$$w_{\text{new}} = w_{\text{old}} - \eta \left. \frac{\mathrm{d}\mathcal{L}}{\mathrm{d}w} \right|_{w_{\text{old}}}.$$

取 $x = 2$、$y = 5$、$w = 1$、$\eta = 0.1$：

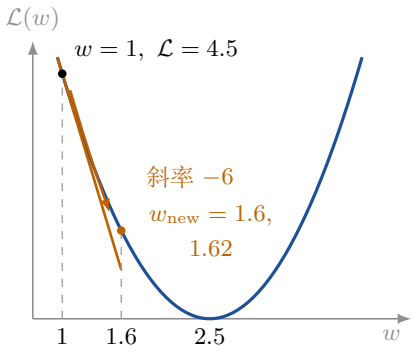
$$\hat{y} = 2, \qquad \mathcal{L} = \frac{1}{2}(2-5)^2 = 4.5, \qquad \frac{\mathrm{d}\mathcal{L}}{\mathrm{d}w} = (2-5)\times 2 = -6,$$

因此

$$w_{\text{new}} = 1 - 0.1 \times (-6) = 1.6.$$

更新后

$$\hat{y}_{\text{new}} = 3.2, \qquad \mathcal{L}_{\text{new}} = \frac{1}{2}(3.2-5)^2 = 1.62 < 4.5.$$

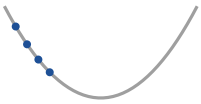


一次训练步的四个问题

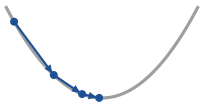
1. 前向计算给出了什么预测？
2. 损失把预测与什么目标比较？
3. 梯度说明参数向哪个方向变化会最快增加损失？
4. 优化器是否沿负梯度方向更新，并使当前批次损失下降？

6.2 学习率决定步长，不决定目标

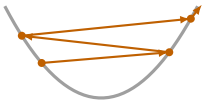
学习率太小时，参数更新缓慢；太大时，更新可能跨过低损失区域并振荡或发散。但学习率不会改变模型究竟要拟合哪个目标，损失函数和数据才定义训练问题。



η 过小



η 合适



η 过大

单步下降验证局部更新　它检查当前参数、当前批次和当前实现下，更新方向与局部梯度一致。泛化（generalization，模型在未参与训练的新数据上的表现）、数据独立性和目标的物理意义由后续验证支持。

7 代码地图：最小 PyTorch 训练闭环

7.1 数据加载与关键训练步骤

```
import torch
from torch import nn
from torch.utils.data import DataLoader, TensorDataset
```

```
x = torch.tensor([[-1.0], [0.0], [1.0], [2.0]])
y = torch.tensor([[-1.0], [1.0], [3.0], [5.0]])

model = nn.Linear(in_features=1, out_features=1)
loss_fn = nn.MSELoss()
optimizer = torch.optim.SGD(model.parameters(), lr=0.1)
loader = DataLoader(TensorDataset(x, y),
                    batch_size=2, shuffle=True)

for epoch in range(50):
    for x_batch, y_batch in loader:
        prediction = model(x_batch)
        loss = loss_fn(prediction, y_batch)

        optimizer.zero_grad(set_to_none=True)
        loss.backward()
        optimizer.step()
```

代码	数学角色
`x, y = tensor(...)`	构造输入 X 与目标 $\boldsymbol{y}$；此例形状均为 $(4,1)$。
`DataLoader(...)`	将训练集按 batch size 组织；此例每个 epoch 有两个 batch。
`optimizer = optim.SGD(...)`	指定优化器与学习率；此例为随机梯度下降（stochastic gradient descent, SGD），`lr=0.1`。
`model(x_batch)`	用当前参数完成前向计算，得到当前 batch 的预测。
`loss_fn(prediction, y_batch)`	把当前 batch 的预测和目标压缩为一个标量损失。
`zero_grad(...)`	清除上一步留在参数上的梯度，避免无意累积。
`loss.backward()`	沿计算图执行反向模式自动微分，把梯度写入参数的 `.grad`。
`optimizer.step()`	读取当前梯度，并根据优化规则和学习率更新参数。

代码地图中的最小链

$$\boxed{\texttt{tensor} \to \texttt{model} \to \texttt{loss} \to \texttt{zero_grad} \to \texttt{backward} \to \texttt{step}}.$$

`backward` 计算梯度，`step` 使用梯度更新参数。

7.2 运行前先检查形状

对 `nn.Linear(1, 1)`，最后一个输入维度为 1。因此四个标量样本写成形状 $(4,1)$，可以明确区分样本轴和特征轴。当 batch size 为 2 时，循环内 `x_batch`、`y_batch` 和 `prediction` 的形状均为 $(2,1)$。

最小调试顺序

`print(x.shape, y.shape)`：输入和目标的 batch 维是否一致？
`print(prediction.shape)`：模型输出是否与目标形状相容？
`print(loss.ndim)`：损失是否为标量？
`print(model.weight.grad)`：`backward` 后是否产生有限梯度？
比较更新前后参数：`step` 是否真的改变了参数？

7.3 训练模式与评价模式

对这里只有线性层的模型，`model.train()` 与 `model.eval()` 的数值行为相同；但含 dropout 或 batch normalization 时二者会改变前向行为。形成正确习惯：

```
model.train()
# parameter updates

model.eval()
with torch.no_grad():
    validation_prediction = model(x_validation)
```

`torch.no_grad()` 表示评价时不构建求导图，减少内存和无意梯度操作；数据集合的用途仍由训练、验证和测试权限决定。

8 训练、验证与测试的权限

8.1 三个集合回答三个问题

集合	主要用途	决策边界
训练集	拟合参数；拟合标准化等预处理；计算训练损失。	新数据表现由独立数据评价。
验证集	选择学习率、模型大小、正则化、训练轮数和阈值。	它参与方案选择，承担开发期评价。
测试集	在冻结开发决定后评价一次最终方案。	使用后保持模型、阈值、代码和报告选择不变。

从计算步骤看，训练步在训练集上完成前向、损失、梯度与参数更新四个动作；验证与测试只对给定参数计算前向与损失（评价），不产生梯度，也不改变参数。冻结开发决定（development decisions），指把验证阶段选定的模型、超参数、训练轮数与阈值等固定下来、不再修改。

最小权限原则　影响参数、超参数、预处理、阈值、报告选择或代码修改的数据属于开发数据。冻结开发决定后使用测试集，才能得到独立评价。

8.2　欠拟合、过拟合与泛化间隙

现象	训练/验证表现	优先检查
欠拟合	训练和验证表现都差。	特征信息、模型容量、优化是否充分、损失与标签是否正确。
合理拟合	训练较好，验证接近且稳定。	多次划分或随机种子下是否保持，指标是否符合任务目标。
过拟合	训练持续改善，验证停滞或恶化。	容量、正则化、训练轮数、数据量、重复样本和划分方式。

训练表现与验证表现之间的差距常称为泛化间隙。早停（early stopping）应根据验证集决定，并把选定轮数视为超参数；测试集用于评价冻结后的训练轮数。欠拟合和过拟合提供诊断起点，具体物理失效机制还需要针对性检查。

8.3　桥接单元建立数据权限，第 5 讲展开验证专题

第 5 讲将进一步区分 IID 测试、临界窗口、参数扫描和分布外测试，并讨论生成组隔离、数据泄漏、物理基线、多随机种子、消融和对称性检查。本讲进入第 5 讲前建立以下分工：

$$\boxed{\text{训练集更新参数}\quad\text{验证集选择方案}\quad\text{测试集评价冻结后的方案}}.$$

9　概念自检与第 5 讲衔接

9.1　八项概念自检

先用普通语言回答，再把答案对应到专业术语：

1. 固定规则程序与监督机器学习的输入和产出有什么不同？
2. 在一个熟悉的物理问题中，什么是一个样本、输入特征和目标？
3. 预测连续能量与判断两个已定义类别，分别属于什么任务？
4. 模型参数是在训练中改变，还是在每次推断时由人重新填写？
5. 损失为什么需要同时看到预测和目标？
6. batch、iteration 和 epoch 分别描述训练的哪个尺度？
7. 训练集表现很好而验证集明显较差，可能发生了什么？
8. 训练集、验证集和测试集分别回答什么问题？

本讲最重要的产出　能够画出并口头解释本讲的六步概念图，并把“参数更新”一步展开为

梯度与更新两个环节：

$$\text{数据} \to \text{模型} \to \text{预测} \to \text{损失} \to \text{梯度} \to \text{更新} \to \text{新数据检验}$$

其中每一步在做什么；训练中“更新”回到“预测”反复迭代，“新数据检验”是这一闭环的出口。把尚待解决的梯度或 PyTorch 问题写入概念学习单，教师将在第 5 讲继续解释。

9.2 本讲小结

1. 机器学习通过训练数据调整模型参数，并用训练后的参数生成预测。
2. 样本是研究对象，特征是模型输入，标签/目标是希望预测的量。
3. 数据划分先于会从数据拟合参数的预处理；标准化统计量来自训练集。
4. 分类预测离散类别或类别概率，回归预测连续量；监督学习使用成对的输入和目标。
5. 线性回归与对数几率回归提供理解参数和损失的简单例子；神经网络是更复杂的模型族。
6. 经验风险是训练样本损失的平均；训练损失与最终报告指标承担不同职责。
7. batch 决定一次更新使用的样本，iteration 是一次更新，epoch 是一次数据遍历。
8. 梯度给出损失对参数的局部变化率，学习率控制更新步长。
9. 反向传播/自动微分产生梯度，优化器根据梯度更新参数。
10. 训练、验证和测试拥有不同权限；训练/验证差距可用于初步诊断过拟合。
11. 第 5 讲将在这张概念地图上加入 MLP、完整反向传播、梯度核查和科学验证。

9.3 建议阅读

1. **必读**：Lecture 4.5 零基础讲义与配套概念学习单。
2. **选读**：Mehta et al., *A High-Bias, Low-Variance Introduction to Machine Learning for Physicists*, Phys. Rep. **810**, 1–124 (2019)，监督学习入门部分。
   DOI: 10.1016/j.physrep.2019.03.001
3. **操作材料**：PyTorch 官方入门教程中 tensors、`nn.Module`、autograd 和 optimization loop 的最小示例，链接由课程资源页按当学期版本提供。