第 5 讲

机器学习基础与科学验证

AI 赋能的物理学研究：工具、方法与前沿

课程讲义（Article Note）

周毅

中国科学院物理研究所

2026 年 10 月

本讲核心问题

一个监督学习模型如何把输入变成预测，
又如何用链式法则、反向传播和自动微分把损失变成参数更新?
测试结果如何经过独立划分、基线与破坏性测试，成为**可复核的物理证据**?

本讲主线：

任务 → 模型 → 损失 → 梯度 → 优化 → 独立验证.

本讲接续第 4.5 讲建立的六步概念图（数据 → 模型 → 预测 → 损失 → 参数更新 → 新数据检验），
直接沿用其中的 batch/epoch 分工、$y = 2x + 1$ 的 PyTorch 最小循环和三集合权限表。
本讲以二维零场 Ising 模型为贯穿案例：从对数几率回归（log-odds regression）
进入一层 MLP（多层感知机，multi-layer perceptron），手工写出一次反向传播，
再用自动微分和有限差分核对梯度；随后比较多数类、磁化强度、
简单特征模型和小型网络，并审计数据隔离、临界窗口与尺寸迁移。
学生既要解释参数如何更新，也要说明测试结果能支持哪一层物理主张。

Contents

1 本讲目标与工作规则 **4**
1.1 学习目标 . . . 4
1.2 90 分钟课堂安排 . . . 4
1.3 本讲的四条规则 . . . 4

2 从物理问题到可检验的学习任务 **6**
2.1 任务定义同时写清评价分布 . . . 6
2.2 先决定要证明哪一层 . . . 6
2.3 贯穿案例：有限尺寸 Ising 构型分类 . . . 7
2.4 数据如何生成，模型看到的输入是什么 . . . 7

3 监督学习与基本模型 **7**
3.1 经验风险最小化 . . . 8
3.2 线性回归：最小的可训练模型 . . . 8
3.3 对数几率回归：把线性得分变成概率 . . . 8
3.4 一层 MLP：线性模型如何获得非线性表达能力 . . . 9
3.5 落到 Ising 案例：同一协议标签，三种输入表示 . . . 9

4 计算图、反向传播与自动微分 **10**
4.1 计算图把复合函数拆成局部运算 . . . 10
4.2 从 BCE 到一层 MLP 的完整反向传播 . . . 11
4.3 自动微分、反向传播和优化器承担不同角色 . . . 11
4.4 有限差分为自动微分提供独立核查 . . . 12
4.5 训练曲线定位优化问题，独立测试支撑科学主张 . . . 13

5 科学验证：划分、泄漏与评价 **14**
5.1 三个集合回答三个问题 . . . 14
5.2 独立同分布、参数扫描与分布外测试 . . . 14
5.3 沿物理控制参数分解评价指标 . . . 14

6 科学数据的泄漏与隔离 **16**
6.1 Monte Carlo 快照不是自动独立的样本 . . . 16
6.2 六类常见泄漏 . . . 16
6.3 数据划分的推荐顺序 . . . 17

7 基线、变异来源与破坏性测试 **17**
7.1 基线阶梯逐级回答诊断问题 . . . 17
7.2 随机种子只刻画一类训练变异 . . . 18
7.3 消融与反事实比“模型关注哪里”更直接 . . . 19
7.4 公平比较的最低条件 . . . 19

8 Ising 相分类的完整审计 **20**
8.1 推荐实验协议 . . . 20

8.2 一种适合课堂的温度划分 20
8.3 四类模型能回答什么 21
8.4 结果图至少应展示四个维度 21
8.5 从结果到主张：沿证据阶梯升级 21

9 补充阅读：统计物理类比及其边界 **23**
9.1 损失景观可以像能量，但并不自动是能量 23

10 方法实践 A 与提交规范 **23**
10.1 方法实践 A：Ising 相分类与科学机器学习（ML）审计 23
10.2 建议阅读 24

11 本讲小结与自检 **24**
11.1 带走的九句话 24
11.2 提交前自检 25

1 本讲目标与工作规则

1.1 学习目标

完成本讲后，你应能够：

1. 理解线性/对数几率回归和多层感知机的前向计算、激活函数、损失与正则化。
2. 用计算图和链式法则解释反向传播，区分自动微分、梯度计算和优化器的角色。
3. 区分训练、验证、独立同分布（IID）测试、参数扫描和分布外测试，识别生成组泄漏、过拟合、有限尺寸偏差和不公平比较。
4. 用物理基线、多随机种子、生成组重采样、消融（ablation，移除或限制输入/组件后重训，观察性能变化）和对称性测试审计学习结果。
5. 用二维 Ising 相分类案例说明：有限尺寸标签由生成协议（label-generation protocol）定义，分类性能与独立物理证据共同界定相变主张。

1.2 90 分钟课堂安排

时长	环节	本讲产出
10 min	概念回顾与学习任务	回应第 4.5 讲学习单疑问；认识 Ising 快照、独立链与输入表示；形成一句目标主张和一张输入–目标–评价分布任务卡。
20 min	监督学习与基本模型	线性/对数几率回归、MLP 前向计算、激活、损失和正则化；三类模型在 Ising 案例中的输入表示。
15 min	计算图与优化	一次完整反向传播、自动微分调用和有限差分梯度核查。
15 min	科学验证风险	训练/验证/测试权限、生成组隔离和泄漏审计。
10 min	基线、变异与破坏性测试	一条基线阶梯、一份变异来源表和一个反事实测试。
15 min	Ising 相分类案例	比较 $\lvert m\rvert$、$(\lvert m\rvert, e)$ 对数几率回归与小型 MLP，检查临界窗口、$\mathbb{Z}_2$ 和尺寸迁移。
5 min	方法实践路径预览	方法实践 A 与第 8 讲方法实践 B 的选择规则。

1.3 本讲的四条规则

1. **先写前向图，再调用框架**。明确张量形状、损失定义和参数如何影响输出。
2. **先核对梯度，再扩展训练**。自动微分降低求导成本，有限差分提供独立实现核查。
3. **先写评价问题，再划分数据**。让划分方式服务于“要泛化到什么分布”。
4. **先过基线和破坏性测试，再解释增量**。稳定增量与已知物理检查共同支撑解释。

本讲的核心追问 先问“模型计算了什么、梯度从哪里来、优化器更新了什么”，再问“测试样本如何独立于训练样本、最简单的基线达到多少、结果如何随随机种子、温度和尺寸变化，

以及这些证据允许把结论写到多强”。

2 从物理问题到可检验的学习任务

2.1 任务定义同时写清评价分布

监督学习常被简写为从输入 x 预测目标 y。对科学问题而言，这还不够。一项可复核任务至少应写成

$$\mathcal{T} = (\mathcal{X}, \mathcal{Y}, P_{\text{train}}, P_{\text{eval}}, \ell, M, \mathcal{C}),$$

其中 $\mathcal{X}$ 与 $\mathcal{Y}$ 是输入和目标空间，P_{train} 与 P_{eval} 是训练和评价分布，ℓ 是训练损失，M 是报告指标，$\mathcal{C}$ 是允许作出的科学主张。

任务	例子	定义时回答
分类	构型属于哪个已知区域?	类别由什么独立规则给出？类别不平衡如何处理?
回归	从结构预测能量或力。	标签误差、单位、尺度和外推范围是什么?
降维	用低维变量组织构型。	低维结构用何种物理测量验证?
生成	学习玻尔兹曼分布或实验分布。	生成分布与目标分布用哪些可观察量和覆盖率比较?
反演	从响应函数推断模型参数。	解是否唯一？噪声和先验如何影响可识别性?

标签与输入不需要统计独立。 监督学习正是利用这种相关性；需要排除的是输入中混入了不属于科学问题的答案通道，例如文件名中的温度、按类别不同的数组尺寸、划分前计算的全数据统计量，或与目标一一对应的模拟器标识。

2.2 先决定要证明哪一层

同样高的准确率可以对应强度完全不同的主张；先确定要证明哪一层，再准备相应证据。

主张层级	所需证据
模型拟合了当前训练样本	训练损失下降；这是最低层，不说明泛化。
模型预测同一数据流程的新样本	独立生成组上的测试结果和置信区间。
模型利用了某个物理特征	消融、反事实样本、特征受限基线和对称性测试。
模型跨尺寸或数据来源泛化	预先声明的尺寸、边界条件或独立生成流程测试。
模型定位了相变或发现了新相	独立物理可观察量、有限尺寸标度和替代解释排除；分类准确率不够。

2.3 贯穿案例：有限尺寸 Ising 构型分类

考虑二维正方格、周期边界、零外场铁磁 Ising 模型

$$H(\boldsymbol{\sigma}) = -J \sum_{\langle ij \rangle} \sigma_i \sigma_j, \qquad \sigma_i \in \{-1, +1\}, \qquad J > 0.$$

取 $k_{\mathrm{B}} = J = 1$ 时，热力学极限的临界温度为

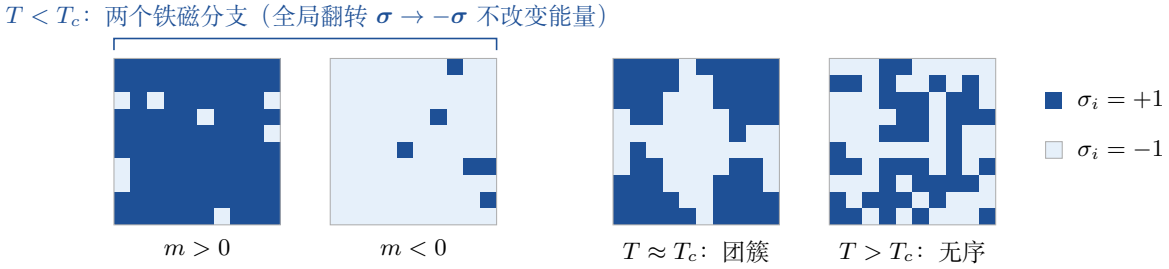
$$T_c = \frac{2}{\ln(1+\sqrt{2})} \approx 2.269.$$

对有限 $L \times L$ 系统，配分函数是解析的，不存在真正的热力学奇点。因此，以 $y = \mathbb{I}(T < T_c)$ 标注有限尺寸构型时，y 由**生成协议（label-generation protocol）**定义：把生成温度与热力学极限的 T_c 对照，而不能从单个构型无歧义地读出。

有限尺寸标签的正确解释　远离 T_c 的样本可用于学习两侧典型构型；临界窗口中的类别分布会重叠，错误率不必趋近于零。模型在该窗口的输出更适合作为诊断曲线，不能单独当作相变的证明。

2.4 数据如何生成，模型看到的输入是什么

本讲的数据由 Monte Carlo（MC）采样产生。对每个温度 T 和尺寸 L 运行多条独立的 MC 链；每条链先经过热化（thermalization），即丢弃尚未达到平衡的初始段，之后每隔固定步数保存一张构型快照，并记录链 ID、T、L、算法与代码版本。快照是**样本单位**，独立链是**生成组**：同一条链上的快照彼此相关（第 6.1 节），后面的划分与泄漏审计都以链而非快照为单位。



低温构型分属两个铁磁分支：零场下全局翻转不改变能量，$m > 0$ 与 $m < 0$ 的构型同属 $y = 1$。临界附近出现各种尺度的团簇，高温构型无序。模型看到的输入就是快照本身：$\boldsymbol{\sigma} \in \{\pm 1\}^{L \times L}$ 展平为 $\boldsymbol{x} \in \mathbb{R}^{L^2}$，标签 y 由生成温度按协议给出（第 2.3 节）；也可以先把快照压缩为少数物理特征再交给模型（第 3.5 节）。

样本单位与生成组　快照是样本单位，独立链才是生成组。

3 监督学习与基本模型

3.1 经验风险最小化

给定训练集 $D_{\mathrm{tr}} = \{(x_i, y_i)\}_{i=1}^{N_{\mathrm{tr}}}$，模型 $f_{\boldsymbol{\theta}}$ 通过最小化经验风险得到参数

$$\hat{\boldsymbol{\theta}} = \arg\min_{\boldsymbol{\theta}} \left[\frac{1}{N_{\mathrm{tr}}} \sum_{i=1}^{N_{\mathrm{tr}}} \ell\big(f_{\boldsymbol{\theta}}(x_i), y_i\big) + \lambda \Omega(\boldsymbol{\theta}) \right].$$

方括号中第一项是经验风险（empirical risk）：真实分布上的期望损失 $\mathbb{E}_P\big[\ell\big(f_{\boldsymbol{\theta}}(x), y\big)\big]$ 无法直接计算，只能用训练样本上的平均损失近似，“经验”即指来自观测样本。连同正则项在内，这一做法称为（正则化）经验风险最小化（empirical risk minimization, ERM）。经验风险下降只说明拟合了当前训练样本，不直接说明泛化（见第 2.2 节的主张层级）。这一定义包含三个不同对象：

- 模型 $f_{\boldsymbol{\theta}}$ 决定从输入到预测的函数族；
- 损失 ℓ 决定单个样本的拟合代价；
- 正则项 Ω 表达对参数规模、稀疏性或函数平滑性的偏好，如 L_2 惩罚 $\Omega(\boldsymbol{\theta}) = \|\boldsymbol{\theta}\|_2^2$。

优化算法只负责寻找更小的目标值，并不保证模型族、标签或科学主张正确。

3.2 线性回归：最小的可训练模型

对回归任务，线性模型为

$$\hat{y} = \boldsymbol{w}^{\mathsf{T}} \boldsymbol{x} + b.$$

若假定观测误差是独立同方差高斯噪声，最大似然估计等价于最小化均方误差

$$\ell_{\mathrm{MSE}} = \frac{1}{2}(\hat{y} - y)^2.$$

线性模型的价值不只是计算便宜：它提供可解释的基线，并直接检验目标能否由输入的线性组合表示。但“线性”是相对所选特征而言的：关于特征 $(|m|, e)$ 线性的模型，对原始自旋并不线性。

3.3 对数几率回归：把线性得分变成概率

对二分类，先计算 logit（对数几率，即第 4.5 讲中的分数 score）

$$z = \boldsymbol{w}^{\mathsf{T}} \boldsymbol{x} + b, \qquad p_{\boldsymbol{\theta}}(y = 1 \mid \boldsymbol{x}) = \sigma(z) = \frac{1}{1 + \mathrm{e}^{-z}},$$

再使用二元交叉熵（binary cross-entropy, BCE）

$$\ell_{\mathrm{BCE}} = -y \ln p - (1 - y) \ln(1 - p).$$

在概率模型解释下，BCE 对应条件伯努利（Bernoulli）似然的负对数（negative log-likelihood, NLL）；均方误差对应同方差高斯观测模型。二者与似然的对应都依赖建模假设，不能简化为“某个损失天然适合所有分类或回归问题”。

logit 与概率不要混用　数值实现通常直接把 logit z 交给稳定的 `BCEWithLogitsLoss`，由它合并 sigmoid 与对数运算。若先手工计算 sigmoid，再把概率当作 logit 输入，模型仍可能运行，但优化目标已经写错。

3.4 一层 MLP：线性模型如何获得非线性表达能力

令输入 $\boldsymbol{x} \in \mathbb{R}^d$，隐藏宽度为 q。一层 MLP 的前向计算是

$$\boldsymbol{a} = W_1\boldsymbol{x} + \boldsymbol{b}_1, \qquad \boldsymbol{h} = \phi(\boldsymbol{a}), \qquad z = \boldsymbol{w}_2^{\mathsf{T}}\boldsymbol{h} + b_2, \qquad p = \sigma(z),$$

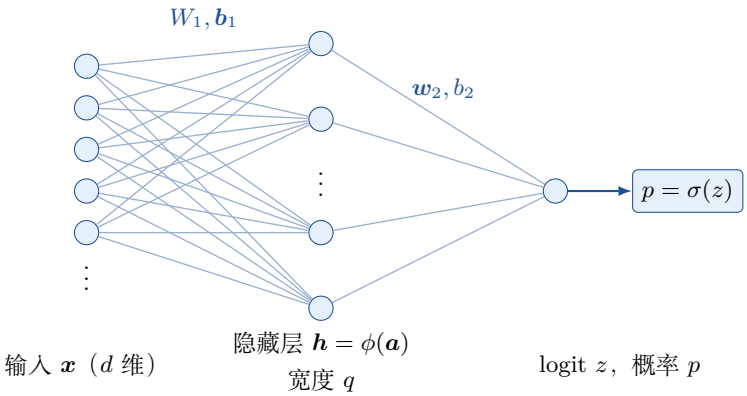
其中 $W_1 \in \mathbb{R}^{q\times d}$、$\boldsymbol{w}_2 \in \mathbb{R}^q$。若没有非线性激活 ϕ，多层线性变换仍可合并成一个线性变换，深度不会扩大函数族。常见激活包括线性整流单元（rectified linear unit, ReLU）与 tanh：

$$\mathrm{ReLU}(a) = \max(0, a), \qquad \tanh(a).$$

该 MLP 的参数量为

$$q(d+1) + (q+1).$$

对原始 $L \times L$ Ising 构型，$d = L^2$；隐藏宽度、正则化和输入表示共同决定容量与样本需求。



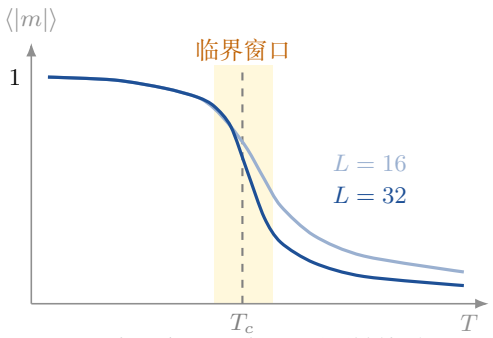
容量描述函数空间，物理价值来自稳定增量。 更宽的 MLP 能表示更复杂的分界面，也更容易利用位置、尺寸、元数据和生成流程中的捷径。因此，模型容量应结合基线、独立测试和破坏性测试一起解读。

3.5 落到 Ising 案例：同一协议标签，三种输入表示

同一标签协议下，第 3.2–3.4 节的模型可以接收不同的输入表示。先定义两个低维物理特征：

$$m(\boldsymbol{\sigma}) = \frac{1}{L^2}\sum_i \sigma_i, \qquad e(\boldsymbol{\sigma}) = -\frac{1}{L^2}\sum_{\langle ij\rangle} \sigma_i\sigma_j,$$

即每格磁化强度与每格能量；取 $|m|$ 消去两个铁磁分支的符号差别（第 2.4 节）。热力学极限下 $\langle|m|\rangle$ 在 T_c 处连续降为零；有限 L 下这一变化被抹圆，$T > T_c$ 一侧仍保留随 L 增大而减小的有限值。这正是临界窗口中两类分布重叠的来源。



示意：有限 L 在 T_c 附近被抹圆

模型	输入 $\boldsymbol{x}$	d	输出	回答的问题
$\lvert m\rvert$ 阈值	$\lvert m\rvert$	1	$\hat{y}=\mathbb{I}(\lvert m\rvert>m_0)$	单个序参量是否已足够?
对数几率回归	$(\lvert m\rvert, e)$	2	$p=\sigma(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}+b)$	两个已知可观察量是否足够?
一层 MLP	展平的 $\boldsymbol{\sigma}$	L^2	$p=\sigma(\boldsymbol{w}_2^{\mathsf{T}}\boldsymbol{h}+b_2)$	原始构型是否含有已知量之外的稳定结构?

前两行只用已知可观察量；网络的价值只能相对它们来判断（第 7.1 节的基线阶梯）。

4 计算图、反向传播与自动微分

4.1 计算图把复合函数拆成局部运算

第 3.4 节 MLP 的单样本前向图可写为

$$\boldsymbol{x} \longrightarrow \boldsymbol{a} \longrightarrow \boldsymbol{h} \longrightarrow z \longrightarrow p \longrightarrow \ell.$$

前向传播保存中间量并得到预测与损失。反向传播从标量损失出发，按相反顺序重复应用链式法则，把一个上游梯度乘以当前节点的局部导数。

为什么必须逆序？训练需要的每个目标量都是损失对某节点或参数的导数 $\partial\ell/\partial(\cdot)$，链式法则把它写成“上游梯度 × 局部导数”：

$$\frac{\partial \ell}{\partial z}=\frac{\partial \ell}{\partial p}\,\sigma'(z), \qquad \frac{\partial \ell}{\partial \boldsymbol{h}}=\frac{\partial \ell}{\partial z}\,\boldsymbol{w}_2, \qquad \frac{\partial \ell}{\partial \boldsymbol{a}}=\frac{\partial \ell}{\partial \boldsymbol{h}}\odot\phi'(\boldsymbol{a}).$$

注意链式法则只给出递推：要算出其中任意一项，必须先知道其靠损失一侧相邻节点的梯度。递推需要一个无需计算即已知的起点；这条链上唯一这样的量是损失对自身的导数 $\partial\ell/\partial\ell=1$，它位于损失端。因此起点由依赖关系唯一确定：求解只能从标量损失出发，沿计算图逆着前向顺序逐个回传。前向传播保存的 $\boldsymbol{a},\boldsymbol{h},z,p$ 使各局部导数在反向到达时有数值可代入。

为什么不从输入端开始？从输入端出发的递推（前向模式）同样合法，但回答的是另一个问题：它从“输入对自身的导数”出发，逐方向计算每个节点对某一输入方向的导数；要得到损失对全部参数的梯度，每个参数方向都要单独走一遍，开销随参数总数线性增长，参数达百万量级时不可行。反向模式把递推起点放在损失端，每个节点只携带“损失对该节点的导数”（与该节点同形状），与

参数总数无关；损失为标量时，一次前向加一次反向即得到全部参数的梯度，总代价只是前向计算的常数倍。这就是“反向传播 = 标量损失上的反向模式自动微分”（第 4.3 节）在大规模训练中不可替代的原因。

4.2 从 BCE 到一层 MLP 的完整反向传播

sigmoid 与 BCE 组合后有一个关键简化：

$$\frac{\partial \ell}{\partial z} = \frac{\partial \ell}{\partial p}\frac{\partial p}{\partial z} = p - y \equiv \delta_2.$$

因此输出层梯度为

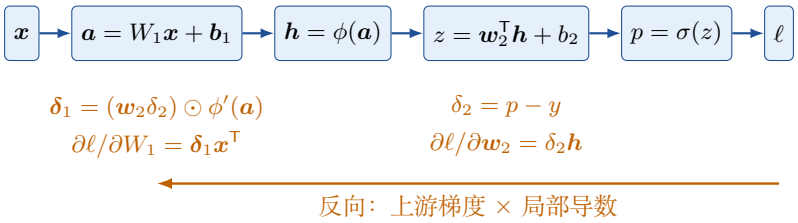
$$\frac{\partial \ell}{\partial \boldsymbol{w}_2} = \delta_2 \boldsymbol{h}, \qquad \frac{\partial \ell}{\partial b_2} = \delta_2.$$

把梯度继续传到隐藏层：

$$\boldsymbol{\delta}_1 = (\boldsymbol{w}_2 \delta_2) \odot \phi'(\boldsymbol{a}),$$

$$\frac{\partial \ell}{\partial W_1} = \boldsymbol{\delta}_1 \boldsymbol{x}^{\mathsf{T}}, \qquad \frac{\partial \ell}{\partial \boldsymbol{b}_1} = \boldsymbol{\delta}_1.$$

批量训练时，对样本梯度求和或平均。矩阵写法只是把同一条链式法则并行应用到一个 batch。第 4.5 讲已建立 batch 与 epoch 的分工——每个 batch 触发一次参数更新，完整遍历训练集为一个 epoch；此处沿用同一约定。



两分钟形状检查　若 $\boldsymbol{x} \in \mathbb{R}^d$、隐藏层宽度为 q，请逐项写出 $\boldsymbol{a}, \boldsymbol{h}, \delta_2, \boldsymbol{\delta}_1, \partial\ell/\partial W_1$ 的形状。形状对不上时，数值框架的广播（broadcasting，形状不同时按规则自动扩维）机制可能让错误代码照常运行而不报错。

4.3 自动微分、反向传播和优化器承担不同角色

自动微分（automatic differentiation, autodiff）只对基本运算（乘法、加法、指数、激活等）使用解析导数规则或专门算法求出局部导数，再沿计算图按链式法则自动组合。一句话概括：自动微分不是不需要解析导数，而是把解析导数下沉到基本算子，整体求导自动化。这样做的好处是：任意复杂的组合都由链式法则自动完成，不需要生成庞大的导数表达式；局部导数不用差商，因此没有截断误差，数值精度接近机器精度。反向传播就是标量损失上的反向模式自动微分。各对象的分工如下表。

对象	做什么	不做什么
前向计算	按模型和数据得到 logit、预测与损失。	不计算参数更新。
反向传播	对当前计算图应用反向模式链式法则。	不决定学习率或更新规则。
自动微分	记录基本运算并自动组合局部导数，生成梯度。	不判断损失、标签和图是否符合物理任务。
优化器	用梯度和内部状态更新参数，如 SGD 或 Adam。	不提供独立泛化证据。

表中 SGD 即随机梯度下降（stochastic gradient descent）：每次用一个小批量（batch）的梯度近似全量训练集梯度来更新参数；Adam 在此基础上加入动量与逐参数自适应步长。二者都是“读梯度、更新参数”的优化器实例。

典型 PyTorch 训练步是

```
logits = model(x)
loss = criterion(logits, y)
optimizer.zero_grad(set_to_none=True)
loss.backward()
optimizer.step()
```

`zero_grad` 清除此前累积的梯度；`backward` 计算当前损失对参数的梯度；`step` 才根据优化器规则更新参数。忘记清零会把多个 batch 的梯度意外累加。这与第 4.5 讲用 `Linear(1,1)`、`MSELoss` 和 SGD（`lr=0.1`）拟合 $y = 2x + 1$ 的最小循环结构相同，这里只是把同一骨架推广到多层模型。

一个可以直接核对的最小例子沿用第 4.5 讲的手算数字（$\hat{y} = wx$、$\mathcal{L} = \frac{1}{2}(wx - y)^2$、$x = 2$、$y = 5$、$w = 1$）：

```
w = torch.tensor(1.0, requires_grad=True)
loss = 0.5 * (w * 2 - 5) ** 2
loss.backward()
w.grad            # tensor(-6.)
```

框架没有生成任何导数表达式：记中间量 $u = 2w$、$v = u - 5 = -3$、$\ell = \frac{1}{2}v^2$，它把 $\ell = \frac{1}{2}v^2$ 视为一步，记录三步运算的局部导数 $\partial u/\partial w = 2$、$\partial v/\partial u = 1$、$\partial \ell/\partial v = v$，沿计算图相乘得到 $2 \times 1 \times (-3) = -6$，与手算 $(\hat{y} - y)x = -6$ 一致。

4.4 有限差分为自动微分提供独立核查

对参数 θ_j，中心有限差分（FD）给出

$$g_j^{\mathrm{FD}} = \frac{\mathcal{L}(\boldsymbol{\theta} + \epsilon \boldsymbol{e}_j) - \mathcal{L}(\boldsymbol{\theta} - \epsilon \boldsymbol{e}_j)}{2\epsilon}.$$

将其与自动微分（AD）结果 g_j^{AD} 比较，例如报告

$$r_j = \frac{|g_j^{\mathrm{AD}} - g_j^{\mathrm{FD}}|}{\max\left(1, |g_j^{\mathrm{AD}}|, |g_j^{\mathrm{FD}}|\right)}.$$

ϵ 太大产生截断误差，太小产生灾难性相消（catastrophic cancellation）；应在双精度、小模型和固定 batch 上扫描若干 ϵ。梯度核查不用于每一步训练，而用于验证自定义损失、层或手写实现。

训练实现自检 开始大规模训练前，至少确认：前向输出有限；损失与标签定义一致；一个小 batch 能过拟合；有限差分与自动微分一致；更新前后参数确实改变；训练/验证曲线按预期记录。完成这些检查后，“训练不收敛”才成为可以定位原因的问题。

4.5 训练曲线定位优化问题，独立测试支撑科学主张

训练曲线指训练损失与验证损失（或验证指标）随训练步数（或 epoch）画出的两条演化曲线；下表的诊断力来自二者的对照。

现象	优先排查	下一项证据
训练损失不下降	梯度、学习率、数据尺度、标签、损失和参数更新。	小 batch 过拟合与梯度核查。
训练下降、验证恶化	容量、正则化、早停、划分变异和泄漏。	冻结流程后的独立测试。
训练和验证都较差	表达能力、优化困难、标签噪声或输入信息不足。	简单基线与输入充分性。
曲线波动很大	batch、学习率、梯度范数和生成组差异。	分离优化变异与样本变异。

5 科学验证：划分、泄漏与评价

5.1 三个集合回答三个问题

集合	可用于什么	不能用于什么
训练集	拟合模型参数和训练期统计量。	报告最终泛化性能。
验证集	选模型、阈值、正则化、早停和超参数。	反复使用后仍声称它是未见测试。
测试集	对冻结后的完整流程做一次最终评价。	选阈值、改特征、挑随机种子或决定报告哪个模型。

这张表正是第 4.5 讲数据权限表的展开：训练集更新参数、验证集选择方案、测试集只评价冻结后的方案，即最小权限原则。

“共享温度是否泄漏”不能脱离评价问题回答：

- 若目标是**同温度、同尺寸、同生成流程的新构型**，训练和测试可覆盖相同温度，但必须来自独立链或独立生成组。
- 若目标是**未见温度、临界窗口或跨尺寸泛化**，则应按温度区间或尺寸保留评价集。

5.2 独立同分布、参数扫描与分布外测试

评价	例子	回答的问题
IID 测试	相同 T, L，但来自独立 MC 链。	流程能否预测同一目标分布的新生成组?
参数扫描	只在深低温/深高温训练，扫描未用于拟合的临界窗口。	输出如何随控制参数变化？变化不等于相变证明。
分布外（OOD）测试	换系统尺寸、边界条件或独立采样实现。	模型对预先声明的分布变化是否稳健?

5.3 沿物理控制参数分解评价指标

类别平衡时可报告准确率；类别不平衡时至少报告平衡准确率

$$\mathrm{BAcc} = \frac{1}{2}\left(\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}} + \frac{\mathrm{TN}}{\mathrm{TN}+\mathrm{FP}}\right).$$

其中 TP、FN、TN、FP 分别为正类正确、正类漏报、负类正确、负类误报的计数；BAcc 即正、负两类召回率（recall，某类样本中被正确识别的比例）的平均。Ising 案例还应报告：

1. 随温度变化的预测概率、准确率或混淆矩阵（confusion matrix，逐类的预测 × 真实计数表）；
2. 不同独立链和随机种子上的均值与离散程度；
3. 至少一个概率质量指标，如对数损失或 Brier 分数（预测概率与真实 0/1 标签的均方误差）；
4. 不同尺寸或生成流程上的性能差异。

评价对象是冻结后的流程，而不只是网络权重。 数据读取、去重、标准化、特征计算、阈值选择和模型选择都属于流程。只要其中任何一步看过测试数据，测试分数就不再是独立证据。

6 科学数据的泄漏与隔离

6.1 Monte Carlo 快照不是自动独立的样本

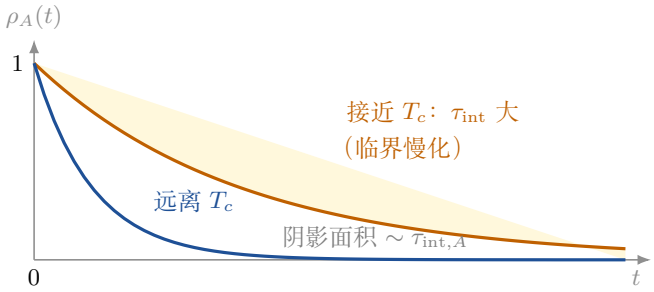
对可观察量 A 的平稳时间序列，归一化自相关函数可写为

$$\rho_A(t) = \frac{\langle A_s A_{s+t}\rangle - \langle A\rangle^2}{\langle A^2\rangle - \langle A\rangle^2}, \qquad \tau_{\mathrm{int},A} = \frac{1}{2} + \sum_{t=1}^{\infty} \rho_A(t).$$

粗略地说，N 个连续快照的有效样本量约为

$$N_{\mathrm{eff}} \approx \frac{N}{2\tau_{\mathrm{int},A}}.$$

临界慢化（critical slowing down）使 τ_{int} 在 T_c 附近显著增大。若把同一条链上相邻快照随机分到训练和测试集，模型可能记住链的局部历史，而非学到可迁移的平衡分布特征。



先按生成组划分，再做任何数据变换。 推荐的最小生成组是独立 Monte Carlo 链、实验批次、样品或仿真任务。同一原始样本的旋转、平移、翻转和裁剪必须跟随原样本进入同一集合。

6.2 六类常见泄漏

泄漏	Ising/物理数据中的例子	阻断方式
身份泄漏	重复构型或增强版本跨集合。	先按原始样本 ID 分组，再增强。
链/批次泄漏	同一 MC 链的相邻快照跨集合。	按独立链或时间块分组划分。
预处理泄漏	用全数据拟合标准化、PCA 或特征选择。	只在训练集拟合，再冻结应用。
元数据泄漏	文件名、目录、顺序、尺寸或填充值编码温度。	删除元数据；统一格式；做标签置乱测试。
模拟器泄漏	两类样本由不同代码、算法或精度生成。	每类使用同一生成流程；跨实现复测。
选择泄漏	多次查看测试结果并据此改模型。	使用验证集；锁定后只做一次最终测试。

表中 PCA 指主成分分析（principal component analysis），一种把相关特征线性压缩为少数正交主成分的降维方法。

6.3 数据划分的推荐顺序

1. 冻结目标主张：IID、临界窗口、跨尺寸还是跨生成流程。
2. 为每个样本记录温度、尺寸、链 ID、时间块、生成代码版本和原始样本 ID。
3. 按最高层级生成组划分训练、验证和测试集合。
4. 只用训练集拟合标准化、PCA、阈值候选范围或数据增强策略。
5. 训练并用验证集选择完整流程。
6. 冻结流程，运行测试和预先声明的分布变化测试。

课堂判断题：虚构的错误流程（故意按快照随机切分） 某同学在每个温度生成一条长链，每隔 10 步保存快照，再随机按 8:1:1 切分。训练与测试准确率均为 99.8%。
结论： 这个数字不能证明模型能够泛化：随机切分很可能让测试集包含训练样本的近邻。应首先按独立链或足够长的时间块重新分组划分，并报告自相关诊断。

7 基线、变异来源与破坏性测试

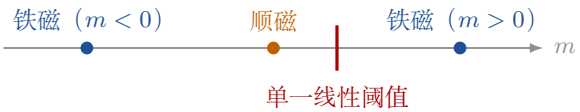
什么时候需要复杂模型？本节把回答拆成四个部分：先搭一条逐级增加复杂度的基线阶梯（参照），再把训练重复、有限样本、划分与系统偏差造成的变异分开估计（噪声底线），然后用破坏性测试主动寻找失败（攻击面），最后规定公平比较的数据权限与选择预算（比较规则）。四者齐备，“网络比基线好”才成为有证据支持的结论；缺少任何一部分，小数点后的优势都不构成采用复杂模型的理由。

7.1 基线阶梯逐级回答诊断问题

Ising 分类可使用以下基线阶梯：

1. **常数/多数类基线：** 检查类别不平衡是否已足以产生高准确率。
2. **磁化强度基线：** $\hat{y}_m = \mathbb{I}(|m| > m_0)$（$m$ 的定义见第 3.5 节），其中阈值 m_0 只能用验证集选择。
3. **物理特征模型：** 用 $(|m|, e)$ 训练对数几率回归（e 为第 3.5 节定义的每格能量）。它检验复杂模型是否只是组合了已知低维可观察量。
4. **原始自旋简单模型：**线性分类器、浅层 MLP 或小型卷积神经网络（convolutional neural network, CNN；第 6 讲正式展开其局域性与权重共享）；其输入、参数量、训练预算和调参次数必须记录。

原始自旋线性分类器是对称性探针，不是可靠序参量基线。 零场铁磁相包含 $m > 0$ 与 $m < 0$ 两个分支，而判据 $|m| > m_0$ 是双侧的。沿磁化方向，一个线性阈值只能切一次，无法同时把正、负两个尾部归为铁磁而把中间归为顺磁。这正是第 6 讲“对称性与归纳偏置”的入口。



7.2 随机种子只刻画一类训练变异

变异指同一训练流程在不同随机种子、数据划分或数据来源下结果的散布；不同来源的变异要分开命名、分开估计，不能混成一个数字。

变异来源	如何估计	报告方式
优化与初始化	固定数据划分，改变模型种子。	多种子均值、标准差和全部点。
有限样本	对独立链/生成组做 bootstrap。	置信区间；不要对相关快照逐点重采样。
数据划分	重复分组划分或交叉验证（cross-validation，轮换留出部分数据作验证的重采样方案）。	分层报告；避免与模型种子混成一个数字。
系统偏差	改变尺寸、边界条件、采样实现或参数区间。	单独的迁移曲线和失败模式。

其中 bootstrap（自举法）指对已有数据做有放回重抽样，以重抽样本上指标的分布近似“假想重复实验”的散布。重抽单位必须是独立链或生成组；逐快照重抽会把高度相关的样本当作独立证据，低估真实不确定度。

对 K 个随机种子的指标 M_k，可报告

$$\bar{M} = \frac{1}{K}\sum_{k=1}^{K} M_k, \qquad s_M = \sqrt{\frac{1}{K-1}\sum_{k=1}^{K}(M_k - \bar{M})^2}.$$

s_M 描述这组训练重复的离散程度，不等同于测量误差、预测置信度或 OOD 不确定度。

7.3 消融与反事实比“模型关注哪里”更直接

测试	操作	可检验结论
全局自旋翻转（$\mathbb{Z}_2$）一致性	比较 $p(\boldsymbol{\sigma})$ 与 $p(-\boldsymbol{\sigma})$。	零场相标签下，预测应近似不变。
平移/旋转一致性	对同一构型做格点平移或方格旋转。	预测变化暴露位置或边界捷径。
已知特征受限	只用 $(\lvert m\rvert, e)$ 训练对数几率回归。	复杂模型增量是否超出已知可观察量。
标签置乱	随机置乱训练标签后重训。	若仍显著高于机会水平，流程可能泄漏。
元数据清除	删除文件名、顺序、填充和尺寸提示。	性能下降说明模型曾利用非物理通道。

7.4 公平比较的最低条件

1. 所有方法使用同一训练、验证和测试生成组。
2. 每个可调阈值和超参数只在验证集选择。
3. 报告调参预算和训练时间，至少报告候选模型数，以免把大量搜索后的最佳网络与未经调优的基线相比。
4. 同时报告平均表现和失败样本，不只选择最好的随机种子。
5. 复杂模型的增量必须与误差条和系统偏差比较，而不是只比较小数点后的差异。

8 Ising 相分类的完整审计

8.1 推荐实验协议

步骤 1：生成与记录　对每个 T 和 L 运行多条独立链；记录热化、采样间隔、链 ID、算法和代码版本。检查能量或磁化强度时间序列及自相关。

步骤 2：预注册（pre-registration）划分　按链划分训练、验证和 IID 测试。另保留临界窗口或不同尺寸作为预先声明的诊断/迁移集。

步骤 3：建立阶梯　比较多数类、$|m|$ 阈值、$(|m|, e)$ 对数几率回归和一个原始构型模型。

步骤 4：冻结流程　阈值、网络和早停均由验证集决定；测试前冻结代码和配置。

步骤 5：破坏性测试　做标签置乱、全局自旋翻转一致性，以及跨尺寸或跨独立采样实现测试。

步骤 6：限制主张　区分“预测协议标签”“利用已知序参量”“跨尺寸稳健”和“定位相变”四种不同结论。

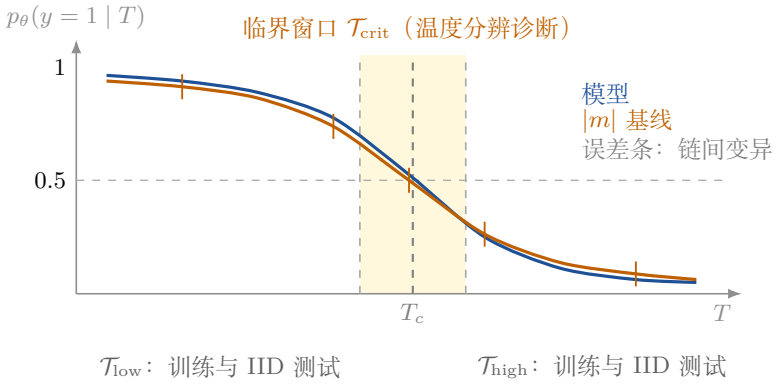
8.2 一种适合课堂的温度划分

可把温度分为三段：

$$\mathcal{T}_{\text{low}} = [T_{\min}, T_c - \Delta], \qquad \mathcal{T}_{\text{crit}} = (T_c - \Delta, T_c + \Delta), \qquad \mathcal{T}_{\text{high}} = [T_c + \Delta, T_{\max}].$$

模型只用深低温和深高温样本拟合，在独立链上做 IID 测试；临界窗口用于观察预测概率如何连续变化。Δ 必须在看结果之前给定，或只用验证数据选择。

临界窗口是温度分辨的诊断区。　若窗口中的标签仍由 $T < T_c$ 硬切，模型错误可能来自有限尺寸分布重叠，而非训练失败。应报告 $p_\theta(y = 1 \mid T)$ 的整体曲线和链间变异，而不是只计算一个“临界区准确率”。



8.3 四类模型能回答什么

方法	主要价值	关键限制	下一项审计
$\lvert m\rvert$ 阈值	可解释的序参量基线。	临界涨落和有限尺寸重叠。	阈值随 L 是否稳定?
$(\lvert m\rvert, e)$ 对数几率回归	检查两个已知可观察量是否足够。	不能发现其外的新结构。	与原始构型模型的增量。
原始自旋线性模型	暴露线性可分性和 $\mathbb{Z}_2$ 冲突。	无法自然表示双侧序参量。	全局翻转一致性。
MLP/CNN	可学习非线性和局部相关。	容易利用位置、尺寸或模拟器捷径。	对称性、消融和迁移测试。

8.4 结果图至少应展示四个维度

1. **温度：** 画出 $p_\theta(y=1 \mid T)$ 或各温度分箱的指标，而不只给出总分数。
2. **基线：** 同图或同表比较 $\lvert m\rvert$、物理特征模型和原始构型模型。
3. **变异：** 展示随机种子或独立链的散点/区间，不只展示均值。
4. **迁移：** 分面展示训练尺寸与测试尺寸，或相同平衡分布的不同采样实现。

8.5 从结果到主张：沿证据阶梯升级

观察	允许的保守表述
IID 测试优于多数类	模型能预测同一生成流程中的新独立链样本。
与 $\lvert m\rvert$ 基线相当	当前任务主要可由已知序参量解释；复杂模型未显示稳定增量。
优于 $(\lvert m\rvert, e)$ 且通过对称性测试	模型可能利用了这些低维特征之外的稳定结构；仍需定向反事实检验。
跨 L 或跨采样实现保持性能	在已测试的变化范围内具有迁移稳健性；不代表任意 OOD 泛化。
预测曲线在 T_c 附近交叉或变化	与临界区域一致；定位相变仍需有限尺寸标度和独立可观察量。

课堂活动：四张审计卡
每组得到同一模型的四项结果：随机快照切分准确率、按独立链切分准确率、全局翻转一致性、跨尺寸曲线。请完成：
1. 标记可进入独立证据链的数字；
2. 选出最简单且公平调优的基线；

3. 写一句当前证据支持的结论；
4. 写一句仍待补证的结论；
5. 提出下一项成本最低、区分力最高的测试。

9 补充阅读：统计物理类比及其边界

本节不占用 90 分钟核心课堂时间，用于说明“用统计力学的语言理解机器学习”的适用边界。它不能替代本讲前面的模型定义、梯度推导和科学验证。

9.1 损失景观可以像能量，但并不自动是能量

在特定的随机动力学近似下，参数分布形式上可写成

$$\pi(\boldsymbol{\theta}) \propto \exp[-\beta_{\text{eff}}\mathcal{L}(\boldsymbol{\theta})]\,.$$

这种 Gibbs 形式需要噪声、阻尼、平稳性和近似详细平衡等条件。普通小批量 SGD 的噪声通常依赖参数、各向异性且非平稳，因此“学习率就是温度”并不是一般结论。

类比	有用之处	必须检查的边界
损失 ↔ 能量	提供高维景观和亚稳态语言。	损失由数据与参数化定义，不是物理哈密顿量。
正则化 ↔ 约束/先验	理解模型复杂度和偏好。	正则化强度不是可直接测量的热力学场。
SGD 噪声 ↔ 热噪声	启发逃离尖锐极小值的讨论。	一般不满足白噪声、各向同性或详细平衡。
能力突变 ↔ 相变	提示研究随规模变化的集体现象。	需要定义极限、序参量、奇异性和标度；尖锐曲线不足。

正确使用类比的方法 先写出对应关系，再列出使对应成立的动力学和极限条件，最后说明哪些可检验预测来自该类比。没有这些步骤，类比只能作为启发，不能替代关于泛化、相变或普适类的证据。

10 方法实践 A 与提交规范

10.1 方法实践 A：Ising 相分类与科学机器学习（ML）审计

任务： 使用提供或自行生成的二维 Ising 构型，比较一个简单物理基线和一个机器学习模型，完成一条从生成组隔离到物理一致性测试的验证链。

九项提交：

1. **任务卡：** 输入、协议标签、样本单位、评价分布和目标主张；
2. **生成组划分：** 哈密顿量、T, L、采样、热化、间隔、链 ID 与分组；
3. **泄漏检查：** 身份、链/批次、预处理、元数据、模拟器和选择过程；
4. **物理基线：** 多数类、$|m|$ 阈值，并与一个 ML 模型公平比较；
5. **多随机种子：** 不少于 5 个训练种子，报告全部结果和离散程度；

6. **临界窗口或分布变化测试：**温度分辨结果或预声明迁移测试；
7. **至少一个破坏性测试：**标签置乱、$\mathbb{Z}_2$、元数据清除或特征受限；
8. **结果解释：**支持范围、结论边界和一个失败模式；
9. **AI 使用记录：**用途、输入边界、人工核查与责任归属。

实现自检：有限差分梯度核查是本讲推荐的实现质量检查，不单列为第十项提交。

路径规则：本实践与第 8 讲的方法实践 B（神经网络量子态（NQS）/变分蒙特卡洛（VMC）小系统基准）二选一，共同构成第 4 项必做作业；学生在第 8 讲后确认路径。

评价原则：评价聚焦任务定义、独立验证、物理判断、可复现性和诚实的失败分析；最高准确率不是主要评价指标。

10.2 建议阅读

1. **必读：**P. Mehta, M. Bukov, C.-H. Wang, A. G. R. Day, C. Richardson, C. K. Fisher, and D. J. Schwab, "A High-Bias, Low-Variance Introduction to Machine Learning for Physicists," *Phys. Rep.* **810**, 1–124 (2019). 选读监督学习、神经网络基础和 Ising 案例部分。
   DOI: 10.1016/j.physrep.2019.03.001
2. **选读：**J. Carrasquilla and R. G. Melko, "Machine Learning Phases of Matter," *Nat. Phys.* **13**, 431–434 (2017).
   DOI: 10.1038/nphys4035

11 本讲小结与自检

11.1 带走的九句话

1. 线性/对数几率回归给出最小可解释基线；MLP 用非线性激活扩展函数族。
2. 前向传播计算预测与损失；反向传播计算梯度；优化器才更新参数。
3. 自动微分执行链式法则，但不会判断计算图、损失、标签或科学问题是否正确。
4. 学习任务须写清评价分布和允许主张；输入、网络和标签只是完整任务定义的一部分。
5. 有限尺寸 Ising 的高/低温标签来自生成协议；临界窗口中的重叠不是靠训练就能消除的错误。
6. Monte Carlo 快照可能强相关；按独立链或时间块划分可建立生成层面的独立性。
7. 基线应从常数预测、物理序参量和简单特征模型逐级建立，再讨论复杂网络的增量。
8. 多随机种子只测量部分训练变异；有限样本和分布变化需要另外的估计与测试。
9. 分类曲线与临界区域一致，不等于已经证明相变；对称性、独立可观察量与有限尺寸标度仍不可替代。

11.2 提交前自检

1. 我能否写出模型的前向链、每个张量的形状，以及 BCE/回归损失的统计假设？
2. 我是否区分了 `backward` 产生梯度与优化器 `step` 更新参数，并做过最小梯度核查？
3. 我的样本单位是单个快照、独立链、实验批次还是样品？划分是否按这个单位隔离？
4. 标准化、特征选择、阈值和超参数是否只使用训练/验证数据？
5. 最简单物理基线是什么？复杂模型的增量是否大于随机种子和生成组变异？
6. 我报告的是 IID、新温度、临界窗口还是 OOD 性能？是否混用了这些概念？
7. 模型在 $\boldsymbol{\sigma} \to -\boldsymbol{\sigma}$、平移或旋转下是否给出符合任务定义的预测？
8. 标签置乱后性能是否回到机会水平？元数据清除后结论是否保持？
9. 当前证据最多允许我说“预测”“利用特征”“跨范围稳健”还是“定位相变”？
10. 代码、数据卡、配置、随机种子、结果表和 AI 使用记录能否让他人重建这条证据链？