第 4.5 讲　课前桥接单元

机器学习零基础入门
概念与最小训练闭环

AI 赋能的物理学研究：工具、方法与前沿

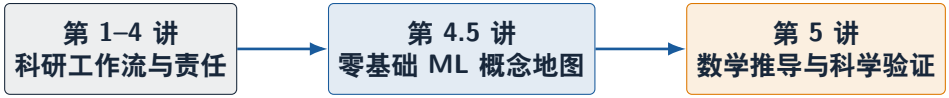
AI 提出候选，人类研究者确立结论。

AI proposes candidates; the human researcher establishes the conclusion.

周毅
中国科学院物理研究所

2026 年 10 月

第 4.5 讲专门为零机器学习基础学生搭桥



本单元首要任务

解释机器学习是什么、模型从数据中学习什么，以及数据、模型、预测、损失、参数更新和新数据检验如何组成一个闭环。

第 5 讲继续展开

MLP（multi-layer perceptron）反向传播、有限差分梯度核查、泄漏、基线、Ising、对称性和迁移测试。

本讲用公式与代码解释概念，完成标准是能够复述并使用这张概念地图。

90 分钟后应能用自己的语言解释五件事

1. 机器学习与人工写定规则有什么不同，训练与推断有什么不同。
2. 什么是样本、特征、标签、模型、预测、参数和损失。
3. 怎样判断分类/回归、监督/无监督；神经网络在其中是什么。
4. 模型怎样沿“预测错误 $\rightarrow$ 调整参数”从示例中改进。
5. 训练集、验证集和测试集如何共同支持新数据判断。

完成本讲后，你将能用一张稳定的概念地图组织术语、公式和代码。

本单元是一条 90 分钟的基础闭环



共同例子

用“根据实验特征预测连续量”贯穿数据、模型、预测、损失和新数据检验。

学习产出

一张六步概念图、一份术语卡、一次教师引导更新和一张泛化判断卡。

课堂行动 先独立写下：你认为机器学习中的“学习”发生在哪里？

90 分钟只围绕一张六步概念地图。

准备问题 1

机器学习到底是什么？

固定规则程序与机器学习的分工不同

固定规则程序

人写出明确规则：

$$\text{输入} + \text{规则} \to \text{输出}.$$

例：按已知公式换算单位。

监督机器学习

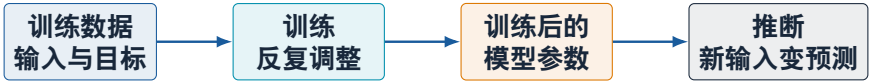
人提供示例、模型和评价方式：

$$(x, y)\ \text{示例} \to \text{训练后的参数}.$$

例：从实验特征预测标定值。

机器学习中的“学习”首先指模型参数随训练数据改变。

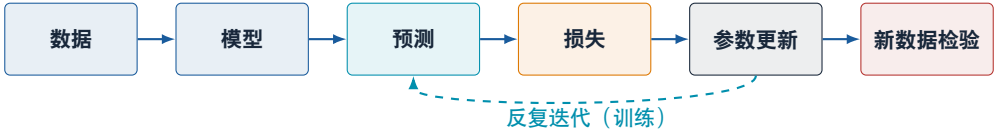
训练产生参数，推断使用参数



- 训练时可以利用目标并改变参数。
- 推断（inference）时参数固定，只计算新输入的预测。
- 物理理解还需要因果证据、机制分析和独立检验。

训练负责产生参数，推断负责使用参数生成预测。

整讲只围绕一张六步概念图展开



三条解释边界

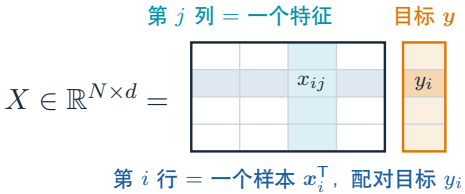
1. 神经网络是模型的一类，不能把“模型”等同于神经网络。
2. 模型输出是待检验的预测，不能把输出当作已成立的结论。
3. 新数据表现需要独立评价，不能从训练损失（training loss，预测与目标差距的标量度量）直接推断泛化（generalization）。

后面的术语、公式和代码为这六个位置提供更精确的表达。

准备问题 2

一项学习任务由哪些对象定义？

数据矩阵的两条轴有不同含义



释义：$x_i \in \mathbb{R}^d$ 第 i 个样本的特征向量；y_i 该样本希望预测的目标。

第一轴：样本

N 个研究对象：实验、图像、构型、结构或数值实例。

第二轴：特征

每个样本的 d 个输入量，例如温度、谱峰位置、像素或局域环境描述。

N 回答“有多少个对象”，d 回答“每个对象如何表示”。

原始数据进入模型前需要一条明确的数据流程



- 先确认一个独立样本是什么，再决定矩阵或张量（多维数组）的轴。
- `train/val/test` 是训练、验证、测试三个数据集合的常用缩写；三者分工在最后一部分展开。
- 单位、量级、缺失值与重复样本会改变模型实际看到的信息。
- 任何从数据拟合参数的变换都属于训练流程。

数据表示不是中性容器，而是学习任务定义的一部分。

标准化参数只能由训练集估计

$$\tilde{x}_{ij} = \frac{x_{ij} - \mu_j^{(\text{train})}}{s_j^{(\text{train})}}$$

其中 x_{ij} 就是数据矩阵 X 的矩阵元：行指标 i 对应样本，列指标 j 对应特征。

为什么标准化

特征可能以 K、eV、nm 为单位，也可能无量纲；尺度差异会使优化步长极不均衡。

正确顺序

用训练集计算均值 μ_j 和标准差 s_j，冻结后对其余数据使用同一变换。

数据权限检查

先划分数据，再用训练集拟合 μ_j, s_j；同一变换随后应用于验证集、测试集和未来数据。

预处理参数来自训练集，测试集由此保持独立。

标签、参数和超参数属于三个不同层次

对象	由谁提供或决定	例子
标签/目标 target y	测量、计算、人工规则或生成协议	能量、力、类别、参数值。
模型参数 parameter θ	训练数据经优化更新	w, b、网络权重。
超参数 hyperparameter	研究者设定或用验证集选择	学习率、层数、正则化（regularization，损失中惩罚过大参数的项）、阈值。

判断方法

看一个量由谁改变：优化器根据训练损失更新参数，研究者借助验证结果选择超参数。

参数由优化器更新；超参数控制训练或模型选择。

训练阶段更新参数，推断阶段固定参数

训练 training

$$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}$$

使用训练数据、目标和损失，反复调整参数；学习率 η 控制每步步长。

推断 inference

$$\hat{y} = f_{\hat{\theta}}(x_{\text{new}})$$

参数固定，只把新输入变为预测。

学习率、batch size（一次更新用的样本数）、epoch 数（遍历训练数据的次数）、模型宽度（网络每层的单元数）与正则化强度是超参数。

“模型会学习”具体指训练阶段的参数被优化器改变。

目标定义学习任务类型

回归 regression

目标是连续量：

$$y \in \mathbb{R}^m.$$

例：从结构预测能量，从信号估计参数。

分类 classification

目标是离散类别：

$$y \in \{1, \dots, K\}.$$

例：判别已定义的谱线类型或状态区域。

同一个神经网络可以输出连续量，也可以输出类别概率。

先看 y 的定义，再判断分类或回归。

无监督学习仍包含明确的建模选择

监督学习

输入与目标成对出现：

$$\{(\boldsymbol{x}_i, y_i)\}_{i=1}^{N}.$$

目标是学习输入到目标的映射。

无监督学习

只有输入：

$$\{\boldsymbol{x}_i\}_{i=1}^{N}.$$

聚类（clustering）、降维或表示学习（representation learning）尝试发现结构。

距离（样本间相似性的度量，如 $\|\boldsymbol{x}_i - \boldsymbol{x}_j\|$）、表示、维数和聚类规则共同定义结果；物理解释还要连接可观测量与机制。

课堂行动 为自己的一个物理数据问题写出“一个样本、输入、目标、任务类型”。

无监督学习用表示、距离和结构假设组织未标注数据。

准备问题 3

模型与损失究竟计算什么？

线性回归是最小连续预测模型

模型是带参数 θ 的可训练映射 $\hat{y} = f_\theta(\boldsymbol{x})$；线性回归是它的最小连续实例：

$$\hat{y} = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b$$

输入

$\boldsymbol{x} \in \mathbb{R}^d$：一个样本的特征。

训练参数

$\boldsymbol{w} \in \mathbb{R}^d$ 与 $b \in \mathbb{R}$。

对 N 个样本，预测向量形状应与目标向量相容。

线性模型先回答“特征的线性组合能解释多少”。

均方误差（MSE）把一批回归误差压缩为标量

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

释义：“损失”不是丢失了什么，而是预测错了要付多少代价；代价规则（MSE、BCE 等）由研究者选定。

- MSE 即 mean squared error；每个残差 $\hat{y}_i - y_i$ 比较一个预测与一个目标。
- 平方使正负偏差都增加损失，并放大大残差。
- 平均使不同 batch 大小下的尺度更易比较。

解释范围

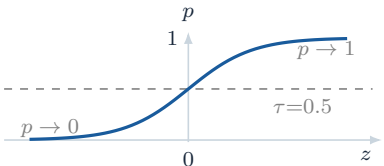
MSE 作用于训练集即训练损失，描述当前拟合；模型在未参与训练的新数据上的表现称为泛化，由独立数据评价。

训练损失量化拟合，新数据评价量化泛化。

对数几率回归（log-odds regression）：输出二分类概率

$$z = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b,$$

$$p(y=1 \mid \boldsymbol{x}) = \sigma(z) = \frac{1}{1+e^{-z}}$$



对单个样本：y 该样本的类别标签（0 或 1）；z 标量分数（score，第 5 讲称 logit），无界实数，越大越支持正类；$p(y=1 \mid \boldsymbol{x})$ 即“给定 $\boldsymbol{x}$ 时 $y=1$”的概率。 等价地，$\log \dfrac{p}{1-p} = z = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b$：对数几率（log-odds）上的线性回归，这正是名称的由来。



阈值类别 $\hat{y}$：p 超过阈值 τ（如 0.5）判为正类，否则为负类；τ 是超参数。

分数、概率和阈值后的类别是三个不同对象。

训练损失与报告指标回答不同问题

	训练损失	报告指标
作用	为梯度优化提供标量目标。	回答研究或应用问题。
分类例子	BCE。	accuracy、recall、ROC-AUC。
回归例子	MSE、Huber loss。	MAE、RMSE、物理单位误差。

配对原则

BCE（binary cross-entropy，二元交叉熵）可用于优化概率输出；固定阈值准确率用于报告分类结果，二者随训练变化的方式可以不同。

释义：accuracy 准确率；recall 召回率（真实正类被检出的比例）；ROC-AUC 综合各阈值的分类表现（0.5 接近随机）；Huber loss 对大残差更稳健；MAE 平均绝对误差；RMSE 均方根误差（与目标同量纲）。

训练前分别写出优化目标和最终报告指标。

准备问题 4

训练如何按 batch 与 epoch 组织？

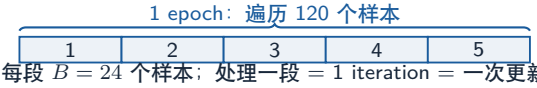
dataset、batch、iteration 与 epoch 描述四个尺度

术语	含义
dataset	当前数据集合中的全部样本。
batch	一次前向（算预测）、反向（算梯度）和更新使用的一组样本。
iteration / step	处理一个 batch 并执行一次参数更新。
epoch	训练流程大致遍历全部训练样本一次。

若 $N_{\text{train}} = 120$、batch size $B = 24$:

$$1 \text{ epoch} = 5 \text{ iterations},$$

$$20 \text{ epochs} = 100 \text{ updates}.$$



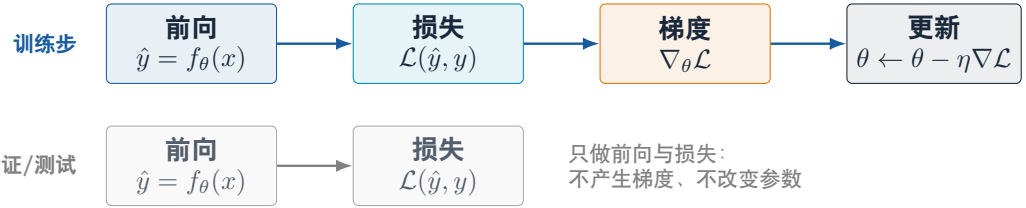
课堂行动 若 batch size 改为 32，每个 epoch 有多少次更新？

epoch 是数据遍历单位，iteration 才对应一次参数更新。

准备问题 5

梯度如何变成一次参数更新？

训练步由四个不同动作组成



局部含义

梯度给出参数微小变化时损失的一阶变化率；负梯度是局部最快下降方向。

一次训练步依次完成前向、损失、梯度和参数更新。

标量模型怎样产生更新方向

$$\hat{y} = wx, \qquad \mathcal{L}(w) = \frac{1}{2}(wx - y)^2$$

$$\frac{\mathrm{d}\mathcal{L}}{\mathrm{d}w} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial w} = (\hat{y} - y)x = (wx - y)x$$

方法关系

前向计算得到预测与损失；反向传播高效实现链式法则并产生梯度；优化器读取梯度并执行参数更新。

释义：$\hat{y}$ 模型预测（随 w 变化）；y 数据给定的目标（求导时视为常数）。

零基础学生先看懂各量的角色；完整链式法则留到第 5 讲。

一次更新如何让当前误差变小

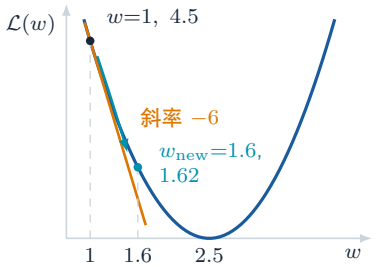
取 $x=2$、$y=5$、$w=1$、$\eta=0.1$：

$$\hat{y}=2,\qquad \mathcal{L}_{\text{old}}=\tfrac{1}{2}(2-5)^2=4.5$$

$$\frac{\mathrm{d}\mathcal{L}}{\mathrm{d}w}=(2-5)\times 2=-6,$$

$$w_{\text{new}}=1-0.1(-6)=1.6$$

$$\mathcal{L}_{\text{new}}=\tfrac{1}{2}(1.6\times 2-5)^2=1.62$$



课堂行动 **先指认**：x、y、w、η **各是数据、参数还是超参数？再用语言解释：参数为什么从 1 变到 1.6？**

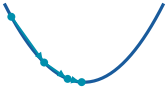
沿负梯度方向一步更新，使该样本损失从 4.5 降到 1.62。

超参数选择：学习率控制步长，不改变训练目标



过小

更新缓慢，有限训练时间内可能几乎不动。



合适

在当前区域持续降低损失并保持数值稳定。



过大

跨过低损失区域，振荡、爆炸或产生非有限数值。

单步损失下降验证局部更新；最终泛化和物理解释由后续独立检验支持。

优化给出拟合过程，独立检验确定结果的解释范围。

准备问题 6

最小代码怎样对应概念图？

张量、数据加载器、模型和损失先确定对象

```
import torch
from torch import nn
from torch.utils.data import DataLoader, TensorDataset

x = torch.tensor([[-1.0], [0.0], [1.0], [2.0]])
y = torch.tensor([[-1.0], [1.0], [3.0], [5.0]])

model = nn.Linear(in_features=1, out_features=1)
loss_fn = nn.MSELoss()
optimizer = torch.optim.SGD(model.parameters(), lr=0.1)
loader = DataLoader(TensorDataset(x, y),
                    batch_size=2, shuffle=True)
```

x,y 形状为 $(4,1)$，循环内 batch 形状为 $(2,1)$；Linear(1,1) 与 MSELoss 对应单特征回归；loader 按 batch size 分批给出样本，shuffle 改变每个 epoch 内样本的顺序；SGD 为随机梯度下降（stochastic gradient descent）优化器。

数据形状、输出含义和损失共同定义一项可运行的学习任务。

两层循环区分 epoch 与 iteration

```
for epoch in range(50):
    for x_batch, y_batch in loader:
        prediction = model(x_batch)
        loss = loss_fn(prediction, y_batch)

        optimizer.zero_grad(set_to_none=True)
        loss.backward()
        optimizer.step()
```

$$\texttt{tensor} \rightarrow \texttt{model} \rightarrow \texttt{loss} \rightarrow \texttt{zero_grad} \rightarrow \texttt{backward} \rightarrow \texttt{step}$$

对应概念图：prediction 即预测，loss 即损失，backward 与 step 共同完成参数更新。

课堂行动 **逐行指出：一个 epoch 有几个 iteration？哪一行产生梯度、哪一行改变参数？**

训练循环是数学闭环的程序表达。

backward 与 step 拥有不同职责

调用	实际作用
`zero_grad`	清除此前累积在参数上的梯度。
`loss.backward()`	沿计算图执行反向模式自动微分，把梯度写入 `parameter.grad`。
`optimizer.step()`	读取当前梯度，按优化规则与学习率改变参数。

职责核对

`backward()` 产生并保存梯度；`step()` 读取梯度并改变参数。

自动微分计算梯度；优化器消费梯度并更新参数。

形状与更新检查建立代码可信起点

最小形状检查

```
x.shape
y.shape
prediction.shape
loss.ndim
```

最小更新检查

`model.weight.grad`
梯度是否有限？
`step` 前后参数是否改变？
单步损失方向是否合理？

对 `nn.Linear(1,1)`，四个标量样本写成 $(4,1)$ 比 $(4,)$ 更明确。

形状相容且参数确实更新，训练结果才有明确的程序含义。

准备问题 7

训练、验证与测试分别允许做什么？

训练与验证表现可以初步区分欠拟合和过拟合

现象	训练/验证表现	优先检查
欠拟合	二者都差。	特征、容量、优化、标签和损失。
合理拟合	训练较好，验证接近且稳定。	多划分、多随机种子和指标适切性。
过拟合	训练改善，验证停滞或恶化。	容量、正则化、epoch、数据量和重复样本。

泛化间隙是训练表现与验证表现之间的差距；它是诊断信号，不是物理机制。

正则化：向损失加入惩罚过大参数的项，强度是超参数（讲义 §4.4）；容量：模型可表示关系的复杂程度（讲义 §3.4）；多随机种子、多划分：在不同初始化与划分下重复检验（讲义 §8.2）。

训练表现描述拟合，验证表现提供泛化诊断。

三个数据集合回答三个不同问题

集合	主要用途	禁止用途
训练集	拟合参数；拟合预处理；计算训练损失。	直接代表未见数据表现。
验证集	选学习率、模型、正则化、轮数、阈值。	调参后仍充当最终独立测试。
测试集	冻结全部开发决定（固定下来、不再修改）后，评价最终方案。	选模型、早停、改代码、挑最好种子。

计算步骤：训练步完成前向、损失、梯度、更新四个动作；验证与测试只做前向与损失（评价），不产生梯度、不改变参数。 早停（early stopping）：按验证集表现决定停止训练的轮数；选定的轮数视为超参数（讲义 §8.2）。

训练集更新参数，验证集选择方案，测试集评价冻结方案。

冻结开发决定后再使用测试集

可复核流程

用训练集拟合参数，用验证集选择网络、学习率、轮数和阈值；把这些开发决定（development decisions）固定下来、不再修改，再用测试集评价最终方案。

独立性边界

第一次根据测试结果修改模型、阈值、代码或报告选择时，测试集就进入了开发过程。

课堂行动 **指出上述流程中测试集第一次失去独立性的时刻。**

测试独立性由决策权限定义，而不由文件名定义。

四组容易混淆的概念对照

对照	各自回答什么	一句话区分
训练 / 推断	参数从哪里来 / 预测怎样产生	训练改变参数；推断冻结参数计算预测。
推断 / 泛化	给定输入输出什么 / 新数据上可信吗	推断是计算预测的操作；泛化是对预测在独立数据上的评价。
拟合 / 泛化	训练数据上多准 / 新数据上多准	训练损失量化拟合；独立评价量化泛化。
验证集 / 测试集	选哪个方案 / 冻结后表现好不好	验证集参与方案选择；测试集只在冻结后评价。

推断是动作，泛化是评价；验证参与开发，测试只作评价。

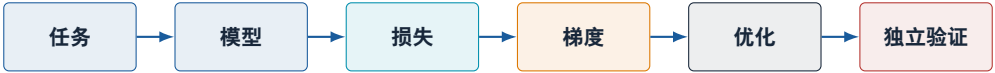
概念学习单用于整理概念图与疑问

1. 用自己的话比较固定规则程序、机器学习、训练和推断。
2. 在一个物理问题中指出样本、特征、目标、模型和预测。
3. 判断分类或回归，并区分损失与报告指标各自回答什么。
4. 解释 batch、iteration、epoch 描述的三个训练尺度。
5. 画出数据到参数更新、再到新数据检验的概念图。
6. 识别欠拟合/过拟合，并说明训练/验证/测试的分工。

学习单不计入四项平时作业成绩；基础部分约 30–40 分钟；C、D 为教师引导观察练习。

完成基础概念图，并把待解决的梯度或代码问题写入疑问卡。

第 5 讲从最小闭环进入完整科学机器学习



六框链是第 5 讲的课程路线：梯度、优化两格即概念图“参数更新”的展开，独立验证即新数据检验。

第 4.5 讲已建立

机器学习概念地图、基本任务、训练组织、一次更新的直觉和新数据检验。

第 5 讲将增加

MLP（multi-layer perceptron）反向传播、有限差分梯度核查、泄漏、基线、Ising、对称性和迁移测试。

机器学习基础同时回答“怎样训练”和“怎样验证”。

建议阅读：把概念图落到文献与代码

1. **必读**：Lecture 4.5 零基础讲义与配套概念学习单。
2. **选读**：Mehta et al., *A High-Bias, Low-Variance Introduction to Machine Learning for Physicists*, Phys. Rep. **810**, 1–124 (2019)，监督学习入门部分。
   `https://doi.org/10.1016/j.physrep.2019.03.001`
3. **操作材料**：PyTorch 官方入门教程中 tensors、`nn.Module`、autograd 和 optimization loop 的最小示例，链接由课程资源页按当学期版本提供。

阅读问题

把六步概念图的每一格对应到 PyTorch 教程中的哪个对象？Mehta 等人如何用偏差–方差语言描述过拟合？

用概念图阅读最小示例，第 5 讲继续展开推导与完整验证。

带走的八句话

1. 机器学习通过训练数据调整参数，并用训练后的参数生成预测。
2. 样本是研究对象，特征是输入，标签/目标是希望预测的量。
3. 先划分数据，再只用训练集拟合标准化等预处理。
4. 分类预测离散类别或概率，回归预测连续量。
5. batch 用于一次更新，iteration 是一次更新，epoch 是一次遍历。
6. 模型产生预测，损失比较预测与目标，训练据此调整参数。
7. `backward` 计算梯度，`step` 更新参数。
8. 训练/验证差距帮助识别过拟合；测试集只评价冻结方案。

先形成稳定概念图，再进入第 5 讲的公式、实现和科学验证。

先建立概念地图，
再进入公式和代码。

第 4.5 讲结束