第 5 讲

机器学习基础与科学验证

AI 赋能的物理学研究：工具、方法与前沿

AI 提出候选，人类研究者确立结论。

AI proposes candidates; the human researcher establishes the conclusion.

周毅
中国科学院物理研究所

2026 年 10 月

本讲同时回答“怎样训练”和“怎样相信”

损失如何经由链式法则变成参数更新？
测试结果又如何成为可复核的物理证据？

从第 4.5 讲出发

沿用六步概念图“数据 → 模型 → 预测 → 损失 → **参数更新** → 新数据检验”。以 batch/epoch 分工、$y = 2x + 1$ 最小循环和三集合权限表为本讲起点。

任务 → 模型 → 损失 → 梯度 → 优化 → 独立验证。

本讲交付模型训练与科学验证两条闭合链

1. 写出线性回归、对数几率回归（log-odds regression）与一层 MLP（multi-layer perceptron）的前向计算、激活、损失和正则化。
2. 用计算图推导一次完整反向传播，解释自动微分与优化器的不同角色。
3. 用有限差分核查梯度，并从训练/验证曲线定位优化与过拟合问题。
4. 按独立链、实验批次或仿真任务隔离数据，建立独立评价。
5. 建立物理基线，用多种子、消融（ablation，移除或限制输入/组件后重训，观察性能变化）、对称性和迁移测试主动寻找失败模式。
6. 将 Ising 分类结果限制为当前证据能够支持的最弱充分主张。

每节一个核心问题；每页一个可检验结论。

本讲按训练链与证据链组织

七个环节，90 分钟



贯穿案例

二维零场 Ising 构型：比较 $|m|$、物理特征模型和小型神经网络。

课堂产出

一张计算图、一次梯度核查、一份分组划分、一条基线阶梯和一句受限结论。

课堂行动 **推导一遍再调用，核查通过再训练，基线通过再解释。**

核心问题 1

物理问题如何成为可检验的学习任务？

科学学习任务同时写清评价对象与主张

$$\mathcal{T} = \left(\mathcal{X}, \mathcal{Y}, P_{\text{train}}, P_{\text{eval}}, \ell, M, \mathcal{C}\right)$$

释义：$\mathcal{T}$ 表示一项完整的科学学习任务（task）。

算法对象

输入空间 $\mathcal{X}$
目标空间 $\mathcal{Y}$
训练损失 ℓ
报告指标 M

科学对象

训练分布 P_{train}
评价分布 P_{eval}
样本单位/生成组（链、批次等）
允许主张 $\mathcal{C}$

写清评价分布，才能把“泛化”落实为可检验问题。

主张强度由证据链闭合的档位决定

不由测试分数决定

主张	最低证据
拟合当前训练样本	训练损失下降。
预测同流程的新样本	独立生成组上的测试结果。
利用了某个物理特征	消融、反事实和特征受限基线。
跨尺寸/来源泛化	预先声明的迁移测试。
定位相变或发现新相	独立可观察量、有限尺寸标度、替代解释排除。

主张升级规则

“分类输出在 T_c 附近变化”只是一个待解释的观察；补上独立可观察量、有限尺寸标度和替代解释排除后，才可升级为相变主张。

让主张停在证据链已经闭合的最高一档。

贯穿案例：有限尺寸 Ising 标签由生成协议定义，不能从单个构型读出

物理模型

$H = -J \sum_{\langle ij \rangle} \sigma_i \sigma_j$，$\sigma_i = \pm 1$。

取 $k_{\mathrm{B}} = J = 1$，
$T_c = 2/\ln(1+\sqrt{2}) \approx 2.269$。

学习协议

输入：有限 $L \times L$ 构型。
标签：$y = \mathbb{I}(T < T_c)$，不能从单个构型读出。
来源：生成协议（label-generation protocol），即把生成温度与热力学极限 T_c 对照。
临界窗口：类别分布可重叠。

解释边界

有限 L 的配分函数解析，不存在真正奇点；临界窗口中的非零错误率不等于训练失败。

背景：Carrasquilla & Melko（2017，选读）按生成温度打标签，Mehta et al.（2019，必读）详细复现。

模型预测的是协议标签；相变结论仍需独立物理证据。

Ising 数据如何生成，模型看到的输入是什么

$T < T_c$：两个铁磁分支（全局翻转 $\boldsymbol{\sigma} \to -\boldsymbol{\sigma}$ 不改变能量）



生成（每个 T, L）

多条独立 Monte Carlo（MC）链；
热化（thermalization）：丢弃初始未平衡段；
之后每隔固定步数保存一张快照；
记录链 ID、T、L、算法与代码版本。

模型看到什么

输入：$\boldsymbol{\sigma} \in \{\pm 1\}^{L \times L}$，展平为 $\boldsymbol{x} \in \mathbb{R}^{L^2}$；
标签：y 由生成温度按协议给出；
样本单位：一张快照；
生成组：一条独立链。

快照是样本单位，独立链才是生成组。

核心问题 2

分类器如何表示预测，如何从损失学到参数？

三类基本模型形成从线性到非线性的最短路径

模型	前向计算	回答的问题
线性回归	$\hat{y} = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b$	目标是否可由特征的线性组合解释？
对数几率回归	$p = \sigma(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b)$	一个线性分界面能否完成概率分类？
一层 MLP	$\boldsymbol{h} = \phi(W_1\boldsymbol{x} + \boldsymbol{b}_1)$，$p = \sigma(\boldsymbol{w}_2^{\mathsf{T}}\boldsymbol{h} + b_2)$	非线性特征组合是否提供稳定增量？

释义：ϕ 为逐元素非线性激活，如 ReLU（rectified linear unit）；σ 为 sigmoid（下页定义）。

复杂度升级标准

神经网络提供更大的函数空间；相对对数几率回归有稳定、可复核的增量时，复杂度才转化为当前任务的证据价值。

复杂度须与实现核查、独立验证同步升级，增量才能进入证据链。

对数几率回归把线性得分变成伯努利（Bernoulli）概率

$$z = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b, \qquad p = \sigma(z) = \frac{1}{1+\mathrm{e}^{-z}},$$

$$\ell_{\mathrm{BCE}} = -y \ln p - (1-y)\ln(1-p)$$

释义：logit z 即标量分数（score，第 4.5 讲的用法）；BCE = 二元交叉熵（binary cross-entropy），即负对数似然（negative log-likelihood, NLL）。

统计假设

BCE 是条件伯努利负对数似然；MSE 对应同方差高斯观测模型。

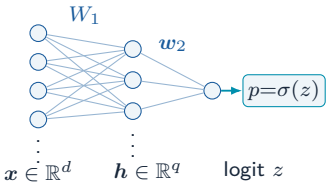
数值实现

直接把 logit z 交给 `BCEWithLogitsLoss`，避免手工 sigmoid 后再取对数。

损失不能按习惯选：它编码输出空间与噪声模型。

非线性激活使一层 MLP 超出线性模型

$$\boldsymbol{a} = W_1\boldsymbol{x} + \boldsymbol{b}_1, \quad \boldsymbol{h} = \phi(\boldsymbol{a}), \quad z = \boldsymbol{w}_2^{\mathsf{T}}\boldsymbol{h} + b_2, \quad p = \sigma(z)$$



形状

$\boldsymbol{x} \in \mathbb{R}^d$，$\boldsymbol{h} \in \mathbb{R}^q$；
$W_1 \in \mathbb{R}^{q\times d}$；
参数量 $q(d+1)+(q+1)$。

激活函数 ϕ

$\mathrm{ReLU}(a) = \max(0, a)$；
$\tanh(a)$。

无激活时，多层线性变换仍等价于单层线性变换。

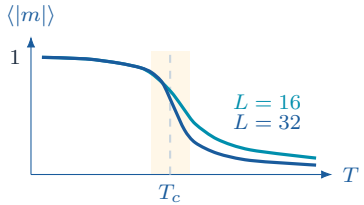
课堂行动 写出 $L \times L$ 原始 Ising 构型对应的输入维数 d。

先确认张量形状和参数量，再讨论“模型学到了什么”。

落到 Ising 案例：同一协议标签，三种输入表示

$$m(\boldsymbol{\sigma}) = \frac{1}{L^2}\sum_i \sigma_i, \qquad e(\boldsymbol{\sigma}) = -\frac{1}{L^2}\sum_{\langle ij\rangle} \sigma_i\sigma_j$$

释义：m 为每格磁化强度，e 为每格能量；取 $|m|$ 消去两个铁磁分支的符号差别。

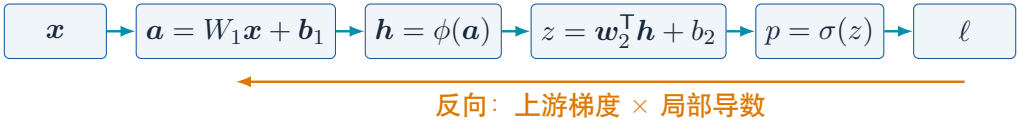


示意：有限 L 在 T_c 附近被抹圆

模型	输入 $\boldsymbol{x}$	d	输出
$\lvert m\rvert$ 阈值	$\lvert m\rvert$	1	$\hat{y} = \mathbb{I}(\lvert m\rvert > m_0)$
对数几率回归	$(\lvert m\rvert, e)$	2	$p = \sigma(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b)$
一层 MLP	展平的 $\boldsymbol{\sigma}$	L^2	$p = \sigma(\boldsymbol{w}_2^{\mathsf{T}}\boldsymbol{h} + b_2)$

前两行只用已知可观察量；网络的价值只能相对它们来判断。

计算图把一个复合函数拆成可检查的局部运算



两种传播

前向传播保存中间量并计算损失；反向传播从标量损失出发，逆序应用链式法则。

释义：链式法则只给出递推——每个节点的梯度都要用它靠损失一侧邻节点的梯度来乘局部导数：$\partial \ell / \partial z = (\partial \ell / \partial p)\, \sigma'(z)$、$\partial \ell / \partial \boldsymbol{h} = (\partial \ell / \partial z)\, \boldsymbol{w}_2$、$\partial \ell / \partial \boldsymbol{a} = (\partial \ell / \partial \boldsymbol{h}) \odot \phi'(\boldsymbol{a})$；递推需要一个无需计算即已知的起点，链上唯一这样的量是 $\partial \ell / \partial \ell = 1$，它位于损失端，所以只能从损失端逆序逐个回传。

自动微分精确执行计算图；任务定义与计算图由研究者核对。

沿计算图逆序走一遍：一次完整的反向传播

sigmoid 与 BCE 组合使输出端 $\delta_2 = p - y$，其余每步同构

沿链从 ℓ 向 x 逆序回传，每步 = 上游梯度 × 局部导数。

$$\delta_2 \equiv \frac{\partial \ell}{\partial z} = p - y$$

$$\frac{\partial \ell}{\partial \boldsymbol{w}_2} = \delta_2 \boldsymbol{h}, \qquad \frac{\partial \ell}{\partial b_2} = \delta_2$$

$$\boldsymbol{\delta}_1 = (\boldsymbol{w}_2 \delta_2) \odot \phi'(\boldsymbol{a}), \qquad \frac{\partial \ell}{\partial W_1} = \boldsymbol{\delta}_1 \boldsymbol{x}^{\mathsf{T}}, \qquad \frac{\partial \ell}{\partial \boldsymbol{b}_1} = \boldsymbol{\delta}_1$$

课堂行动　逐项检查 δ_2、$\boldsymbol{\delta}_1$ 和 $\partial \ell / \partial W_1$ 的形状。

反向传播不是另一种优化器，而是高效计算复合函数梯度的方法。

自动微分沿计算图精确组合局部导数

基本算子的局部导数来自解析规则（或专用算法），再沿计算图自动组合。

这样做的好处

任意复杂组合由链式法则自动完成；
不生成庞大的导数表达式；
局部导数不用差商（无截断误差）。

最小例子：复现第 4.5 讲手算

```
w = torch.tensor(1., requires_grad=True)
loss = 0.5 * (w * 2 - 5) ** 2
loss.backward()
w.grad = -6.，与手算一致
```

$$\frac{\partial \ell}{\partial w} = \underbrace{\frac{\partial \ell}{\partial v}}_{v=-3}\underbrace{\frac{\partial v}{\partial u}}_{1}\underbrace{\frac{\partial u}{\partial w}}_{2} = -6, \qquad u = 2w, \quad v = u - 5, \quad \ell = \tfrac{1}{2}v^2$$

自动微分不是不需要解析导数，而是把解析导数下沉到基本算子，整体求导自动化。

自动微分计算梯度，优化器才更新参数

训练步

```
logits = model(x)
loss = criterion(logits, y)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

角色

backward：反向模式自动微分；
step：SGD/Adam 更新；
zero_grad：清除累积梯度；
验证集：不参与梯度更新。

释义：SGD = 随机梯度下降（stochastic gradient descent），以小批量梯度近似全量梯度。

与第 4.5 讲最小循环对接

$y = 2x + 1$ 示例中的 Linear(1,1)、MSELoss 和 SGD（lr=0.1）已展示完整调用；本页进一步区分计算图、梯度、参数更新与评价权限。

梯度计算、参数更新和泛化评价是三个不同角色。

有限差分是自动微分实现的最小独立基准

$$g_j^{\mathrm{FD}} = \frac{\mathcal{L}(\boldsymbol{\theta} + \epsilon \boldsymbol{e}_j) - \mathcal{L}(\boldsymbol{\theta} - \epsilon \boldsymbol{e}_j)}{2\epsilon}$$

释义：$\boldsymbol{e}_j$ 为第 j 个单位向量（只扰动第 j 个参数），ϵ 为差分步长，$\mathcal{L}$ 为固定小 batch 上的损失。

$$r_j = \frac{|g_j^{\mathrm{AD}} - g_j^{\mathrm{FD}}|}{\max(1, |g_j^{\mathrm{AD}}|, |g_j^{\mathrm{FD}}|)}$$

释义：FD = 有限差分，AD = 自动微分；r_j 为两种实现梯度的相对偏差。

最低训练验收

双精度小模型；固定一个小 batch；扫描若干 ϵ；检查输出和损失有限；确认更新前后参数改变；尝试过拟合一个小 batch。

先验证梯度计算与参数更新正确，再把不收敛归因于物理或模型。

训练曲线把排查定位到具体层级

释义：训练曲线 = 训练损失与验证损失（或指标）随训练步数（或 epoch）的两条演化曲线；诊断力来自二者的对照。

曲线现象	优先排查	下一项证据
训练损失不降	梯度、学习率、数据尺度、标签和更新。	小 batch 过拟合与梯度核查。
训练降、验证升	容量、正则化、早停、划分变异。	冻结流程后的独立测试。
二者都差	表达、优化、标签噪声、输入信息。	简单基线与输入充分性。
波动很大	batch、学习率、梯度范数、生成组。	分离优化变异与样本变异。

训练曲线是计算诊断；独立测试和物理基准才支撑科学主张。

核心问题 3

验证设计如何决定一个分数能说明什么？

训练损失定义拟合目标，不定义科学结论

$$\hat{\boldsymbol{\theta}} = \arg\min_{\boldsymbol{\theta}} \left[\frac{1}{N_{\mathrm{tr}}} \sum_{i} \ell\big(f_{\boldsymbol{\theta}}(x_i), y_i\big) + \lambda \Omega(\boldsymbol{\theta}) \right]$$

释义：$\Omega(\boldsymbol{\theta})$ 为惩罚函数（如 $\|\boldsymbol{\theta}\|_2^2$，惩罚过大参数）；$\lambda\Omega(\boldsymbol{\theta})$ 即正则化项（regularization），以强度 λ 约束容量，λ 由验证集选择。

二分类示例

$p_{\boldsymbol{\theta}}(y = 1 \mid x) = \sigma\big(f_{\boldsymbol{\theta}}(x)\big)$；
二元交叉熵对应条件伯努利似然的负对数。

从拟合到解释

损失下降说明模型更好地拟合当前标签与样本；
独立测试、物理基线和破坏性测试继续判断这一拟合可支持何种解释。

优化回答“如何拟合”，验证设计才回答“拟合结果能说明什么”。

训练、验证、测试：三个集合，三种权限

集合	允许使用	保持独立的方式
训练集	拟合权重与训练期统计量。	最终泛化由测试集报告。
验证集	选阈值、模型、早停、超参数。	明确记录反复选择过程。
测试集	对冻结流程做一次最终评价。	评价前完成模型、种子、特征与阈值选择。

回调第 4.5 讲数据权限表：训练集更新参数、验证集选择方案、测试集只评价冻结方案，即最小权限原则。

完整流程

去重、标准化、PCA、特征选择、阈值选择和模型选择都属于被评价对象。

释义：PCA = 主成分分析（principal component analysis）：把相关特征线性压缩为少数主成分的降维方法。

测试集只评价冻结流程，因此能提供独立证据。

IID、参数扫描和 OOD 回答不同问题

评价	Ising 例子	回答
独立同分布(IID)测试	相同 T, L，独立 MC 链。	同分布新生成组能否预测？
参数扫描	深低/高温训练，扫描临界窗口。	输出如何随 T 变化？
分布外(OOD)测试	换 L、边界条件或独立采样实现。	对声明的分布变化是否稳健？

释义：IID = independent and identically distributed；OOD = out-of-distribution。

命名规则

临界区可以是参数插值、有限尺寸类别重叠或预留分布；先声明训练支持集与评价分布，再将结果命名为 IID、参数扫描或 OOD。

结果叫 IID、参数扫描还是 OOD，取决于事先声明的训练支持集与评价分布。

一个总准确率会遮蔽临界区和类别不平衡

至少报告

平衡准确率或逐类召回率；
随温度的预测概率；
独立链/种子上的离散程度；
跨尺寸或跨流程差异。

平衡准确率

$$\mathrm{BAcc} = \frac{1}{2}\left(\frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}} + \frac{\mathrm{TN}}{\mathrm{TN}+\mathrm{FP}}\right)$$

概率模型还应检查对数损失或 Brier 分数。

释义：TP/FN = 正类被正确预测/漏报的计数，TN/FP = 负类被正确预测/误报的计数；BAcc 即两类召回率的平均；Brier 分数即预测概率与真实 0/1 标签的均方误差。

物理控制参数上的分解曲线比一个汇总数字更有诊断力。

核心问题 4

科学数据如何泄漏答案？

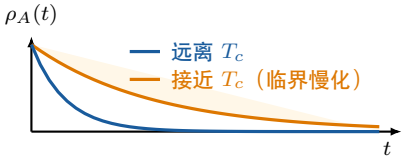
Monte Carlo 快照不是自动独立的样本

$$\rho_A(t) = \frac{\langle A_s A_{s+t}\rangle - \langle A\rangle^2}{\langle A^2\rangle - \langle A\rangle^2}, \qquad \tau_{\mathrm{int},A} = \frac{1}{2} + \sum_{t\geq 1} \rho_A(t)$$

$$N_{\mathrm{eff}} \approx \frac{N}{2\tau_{\mathrm{int},A}}$$

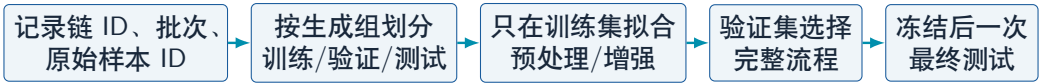
需阻断的生成组泄漏

一条长链每隔 10 步保存，再把全部快照随机按 8:1:1 切分，会让高度相关的相邻快照分落在不同集合；临界慢化会放大这一风险。



按独立生成组划分，让测试样本在生成层面独立于训练数据。

正确顺序：先按生成组划分，再拟合预处理与增强



生成组

独立 MC 链、实验批次、样品、仿真任务或原始观测。同一原始样本的旋转、翻转、平移和裁剪跟随它进入同一集合。

数据增强扩充训练视角；独立证据仍按原始样本或生成组计数。

六条泄漏路径都能制造“漂亮结果”

泄漏	例子	阻断
身份	重复构型或增强版本跨集合。	按原始样本 ID 分组。
链/批次	同一 MC 链相邻快照跨集合。	按链或时间块划分。
预处理	全数据拟合标准化/PCA。	只在训练集拟合。
元数据	文件名、顺序、尺寸编码温度。	删除通道；标签置乱。
模拟器	两类由不同算法或精度生成。	同流程生成；跨实现复测。
选择	查看测试结果后继续改模型。	验证集调参；冻结后测试。

异常高分先进入泄漏审计，通过后再进入物理解释。

审计 99.8% 测试准确率：先删除不能作为证据的数字

虚构的审计流程（故意包含三处污染）

每个温度一条长链；快照随机切分；全数据标准化；最后从 30 个网络中选择测试准确率最高者（99.8%）。

识别到的三处污染

链相关跨集合；
测试统计量进入预处理；
测试集参与模型选择。

最低重做

多条独立链；
按链分组划分；
训练集拟合预处理；
验证集选择；冻结后测试。

课堂行动 两人一组：判断还缺哪一项记录才能复核“独立链”。

污染后的分数退出证据链；修复流程后重新评价。

核心问题 5

什么时候需要复杂模型？

Ising 基线应形成一条逐级增加复杂度的阶梯

1. **常数/多数类**：检查类别不平衡。
2. **磁化强度阈值**：$\hat{y}_m = \mathbb{I}(|m| > m_0)$，$m_0$ 为可调阈值。
3. **物理特征模型**：用 $(|m|, e)$ 训练对数几率回归。
4. **原始构型模型**：线性分类器、浅层 MLP 或小型 CNN。

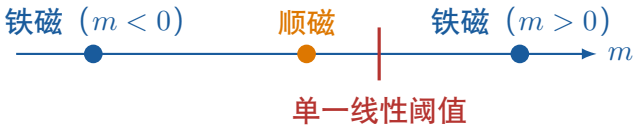
释义：CNN = 卷积神经网络（convolutional neural network），利用局域连接与权重共享处理格点数据，第 6 讲正式展开。

公平比较

m_0、正则化和网络超参数都在验证集选择；基线与网络获得透明、可比的选择预算。

复杂模型的价值等于它相对最强简单基线的稳定增量。

原始自旋线性模型暴露 $\mathbb{Z}_2$ 对称性冲突



为什么线性阈值不够？

零场铁磁相有 $m>0$ 与 $m<0$ 两个分支；$|m|>m_0$ 是双侧判据，一个线性切分不能同时选择两端并排除中间。

释义：$\mathbb{Z}_2$ 指“翻转/不翻转”二元素对称群，这里即全局自旋翻转 $\sigma \to -\sigma$。

模型结构与物理对称性不相容时，增加数据也无法修复表示缺陷。

五个随机种子只测量了不确定度的一部分

来源	估计方式	报告
初始化/优化	固定划分，改变模型种子。	全部点、均值、标准差。
有限样本	对独立链/生成组 bootstrap。	置信区间。
数据划分	重复分组划分。	单独报告划分变异。
系统偏差	改 L、边界或采样实现。	迁移曲线与失败模式。

释义：变异 = 同一流程在不同随机种子、数据划分或数据来源下结果的散布。

释义：bootstrap（自举法）：对已有数据做有放回重抽样，用重抽样本的指标分布近似“假想重复实验”的散布；这里以独立链/生成组为单位重抽，而非逐张快照。

报告结构

五个或更多模型种子刻画初始化/优化变异；生成组 bootstrap、重复划分与迁移测试分别补充其他不确定度来源。

训练重复、样本误差和分布变化分开命名、分开估计。

破坏性测试比“模型关注哪里”更直接

测试	操作	判据
标签置乱	随机置乱训练标签。	应回到机会水平。
$\mathbb{Z}_2$ 一致性	比较 $p(\sigma)$ 与 $p(-\sigma)$。	零场标签下应近似相同。
平移/旋转	变换同一构型。	预测不应依赖位置捷径。
特征受限	只用 $(\lvert m\rvert, e)$。	衡量复杂模型的增量。
元数据清除	删除文件名/顺序/填充。	结论应保持。

能主动让模型失败的测试，通常比事后可视化更有区分力。

公平比较要求相同数据权限和相近选择预算

共享评价条件

训练/验证/测试生成组；
评价指标与温度分箱；
测试集使用次数；
允许使用的输入通道。

透明选择预算

基线阈值扫描范围；
网络候选数与超参数搜索；
训练时间或计算预算；
全部种子而非最佳种子。

增量判据

CNN 相对物理基线的增量，应与模型种子、生成组和调参选择造成的变异共同报告；稳定超过这些变异后，再讨论额外结构。

小数点后的优势只有在选择预算公平且大于变异时才有意义。

核心问题 6

Ising 模型
究竟学到了什么？

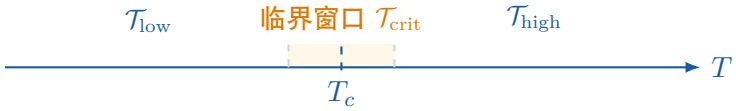
完整协议从生成记录开始，而不是从定义网络开始

1. **生成**：每个 T, L 多条独立链；记录热化、间隔、算法和代码版本。
2. **隔离**：按链划分训练/验证/IID 测试；预留临界窗口或不同尺寸。
3. **基线**：多数类、$|m|$、$(|m|, e)$ 与一个原始构型模型。
4. **选择**：验证集决定阈值、网络和早停；测试前冻结。
5. **破坏**：标签置乱、全局翻转、元数据清除或跨实现复测。
6. **限制**：区分预测标签、利用特征、迁移稳健和定位相变。

模型结构只是协议的一项；数据生成和评价定义同样属于方法。

把临界窗口作为诊断区，而不是硬塞进一个总分数

$$\mathcal{T}_{\mathrm{low}} = [T_{\min}, T_c - \Delta], \quad \mathcal{T}_{\mathrm{crit}} = (T_c - \Delta, T_c + \Delta), \quad \mathcal{T}_{\mathrm{high}} = [T_c + \Delta, T_{\max}]$$



拟合

深低温与深高温的独立链；
验证集选择 Δ 或预先固定；
IID 测试使用同一区域的新链。

诊断

扫描 $p_\theta(y = 1 \mid T)$；
显示链间/种子间变异；
与 $|m|$ 和独立可观察量比较。

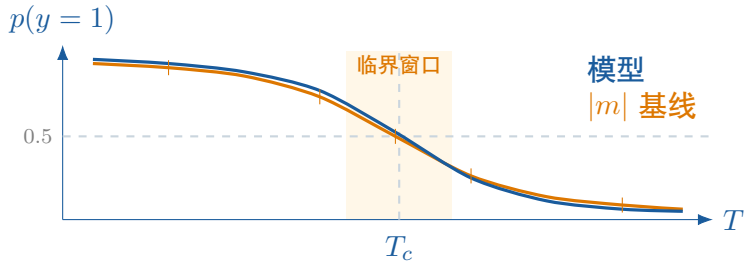
临界区输出是一条需解释的曲线，不是隐藏答案的单一测试分数。

四类模型提供四种不同证据

方法	价值	限制	下一项审计
$\lvert m\rvert$ 阈值	可解释序参量基线。	临界涨落/有限尺寸重叠。	阈值随 L 是否稳定？
$(\lvert m\rvert, e)$ 对数几率回归	检查已知低维量是否足够。	无法发现其外的结构。	原始构型增量。
原始自旋线性	暴露线性可分性与对称性冲突。	双侧序参量需非线性表示。	翻转一致性。
MLP/CNN	学习非线性和局部相关。	易利用位置/尺寸/模拟器捷径。	消融与迁移。

按诊断问题组织模型阶梯，比按准确率排序提供更多物理信息。

结果图至少展开温度、基线、变异和迁移



作图标准：写清误差条的重复来源；不同尺寸分面，同时展示温度分辨结果与汇总量。

一张合格结果图应让读者看见模型何时优于基线、何时失败。

零场任务首先检查全局自旋翻转不变性

$$H(\boldsymbol{\sigma}) = H(-\boldsymbol{\sigma}), \qquad y(\boldsymbol{\sigma}) = y(-\boldsymbol{\sigma})$$

$$\Delta_{\mathbb{Z}_2} = \frac{1}{N}\sum_{i=1}^{N} \left| p_\theta(\boldsymbol{\sigma}_i) - p_\theta(-\boldsymbol{\sigma}_i) \right|.$$

通过

$\Delta_{\mathbb{Z}_2}$ 小，且两个分支上性能相近：与物理对称性一致。

失败

高准确率但只识别 $m > 0$ 分支：模型可能学到了数据不平衡或采样偏置。

已知的对称性直接给出可量化的验收条件，无需借助可解释性方法。

跨尺寸测试必须先规定输入表示和目标是否可比

可比较设计

CNN + 全局池化接收不同 L；
物理特征按体积归一化；
训练 L 与测试 L' 预先声明；
各 L 独立生成和热化。

需排除的尺寸泄漏

若把不同 L 填充到固定数组，
先检查填充值是否直接暴露尺寸，
再评价模型的跨尺寸表现。

释义：全局池化（global pooling）= 对整张特征图取平均（或最大值），得到与输入尺寸无关的向量。

更强测试

在相同 T, L 下换独立采样实现；若性能崩溃，模型可能识别模拟器而非平衡分布。

表示不泄漏尺寸且物理目标可比时，跨尺寸测试才回答迁移问题。

把观察翻译为最弱充分主张

观察	允许表述
独立链 IID 测试优于多数类	能预测同一生成流程的新独立链样本。
与 $\lvert m\rvert$ 相当	当前任务主要可由已知序参量解释。
优于 $(\lvert m\rvert, e)$ 且通过对称性	可能利用了这些低维量之外的稳定结构。
跨 L 或采样实现保持性能	在已测试变化范围内具有迁移稳健性。
输出曲线在 T_c 附近变化	与临界区域一致；不等于证明相变。

科学写作让动词与证据层级一致：预测、利用、迁移或发现。

课堂审计：哪项测试最便宜、区分力最高？

虚构的四张结果卡（故意混入不能作为证据的数字）

A. 随机快照切分准确率 99.5%。
B. 按独立链切分准确率 84%–91%。
C. 全局翻转后 30% 样本预测改变。
D. 从 $L = 16$ 到 $L = 32$，模型低于 $|m|$ 基线。

1. 标记可进入独立证据链的数字。
2. 写一句当前证据支持的结论。
3. 写一句仍待补证的结论。
4. 选择下一项成本最低、区分力最高的修复或测试。

课堂行动 先检查链划分和 $\mathbb{Z}_2$ 一致性，再增加网络复杂度。

优先选择能闭合证据链、且区分力最高的下一步。

核心问题 7

作业如何形成闭合证据链？

方法实践 A：Ising 相分类与科学机器学习（ML）审计

核心任务

使用提供或自行生成的二维 Ising 构型，比较一个物理基线和一个 ML 模型，完成从生成组隔离到物理一致性测试的验证链。

核心比较

多数类或机会水平；
$|m|$ 阈值物理基线；
一个 ML 模型（简单特征模型、MLP 或 CNN）；
温度分辨结果、变异与至少一个破坏性测试。

有限差分梯度核查作为本讲实现练习与自检工具，不单列为提交类别。

作业目标是完成可审计比较，不是训练课程中最复杂的网络。

九项提交物闭合数据、模型与物理证据链

1. **任务卡**：输入、协议标签、样本单位、评价分布与目标主张。
2. **生成组划分**：记录哈密顿量、T, L、采样、热化、间隔、链 ID 与分组。
3. **泄漏检查**：覆盖身份、链/批次、预处理、元数据、模拟器与选择。
4. **物理基线**：多数类、$|m|$，并与一个 ML 模型公平比较。
5. **多随机种子**：模型种子不少于 5 个，报告全部结果与离散程度。
6. **临界窗口或分布变化测试**：给出温度分辨结果或预声明迁移测试。
7. **至少一个破坏性测试**：标签置乱、$\mathbb{Z}_2$、元数据清除或特征受限。
8. **结果解释**：写明支持范围、结论边界与一个失败模式。
9. **AI 使用记录**：记录用途、输入边界、人工核查与责任归属。

每项提交物都应关闭一条具体失败路径。

路径在第 8 讲后确认，负结果可以是高质量结果

方法实践 A

Ising 相分类与科学 ML 审计：
数据隔离、基线、对称性、临界区/迁移。

方法实践 B

神经网络量子态（NQS）/变分蒙特卡洛（VMC）小系统基准：
变分能、采样、可观察量、ED/可解极限。

共同评价原则

评价问题定义、独立基准、变异、失败解释、复现材料与 AI 使用透明度；最高准确率（或最低能量）不是主要评价指标。

AI 协作规则

AI 可辅助代码草稿和图表候选；提交者负责划分、泄漏审计、物理判据与结论，并记录核查过程。

可复核的负结果优于不可解释的高分结果。

本讲小结：训练链与证据链同步闭合

1. 线性/对数几率回归是最小基线；MLP 通过激活获得非线性表达能力。
2. 前向计算损失，反向传播计算梯度，优化器更新参数。
3. 自动微分执行计算图；有限差分为自定义实现提供独立核查。
4. 学习任务写清评价分布与允许主张。
5. MC 快照按独立链或生成组划分，预处理只拟合训练集。
6. 先建立物理基线，再用种子、消融、对称性和迁移测试审计增量。
7. Ising 标签来自生成协议；分类曲线不替代独立可观察量和有限尺寸标度。

先推导、后调用；先隔离、后比较；先破坏、后解释。

课后补充

统计物理类比的成立边界

Gibbs 形式在明确动力学条件下提供类比

$$\pi(\boldsymbol{\theta}) \propto \exp[-\beta_{\mathrm{eff}}\mathcal{L}(\boldsymbol{\theta})]$$

何时有启发

朗之万（Langevin）型近似；
噪声和阻尼受控；
存在平稳分布；
近似详细平衡。

一般 SGD

噪声依赖参数；
各向异性；
非平稳；
学习率不等于温度。

“损失像能量”是有条件的类比，其适用条件决定解释范围。

尖锐变化只有在定义极限和标度后才可能称为相变

类比	可用语言	升级主张所需证据
损失/能量	景观、亚稳态。	与物理哈密顿量的明确对应。
SGD/热噪声	随机逃逸。	平稳分布与有效温度推导。
容量/熵	复杂度竞争。	热力学极限与熵标度。
能力突变/相变	规模依赖集体现象。	奇异性、序参量与普适类。

主张升级

陡峭准确率曲线先报告为规模依赖的能力变化；加入极限、序参量、奇异性和标度证据后，再讨论相变语言。

极限、序参量、奇异性和标度共同支撑相变主张。

建议阅读：用文献对照本讲的验证链

1. **必读**：P. Mehta et al., "A High-Bias, Low-Variance Introduction to Machine Learning for Physicists," *Phys. Rep.* **810**, 1–124 (2019)，选读监督学习、神经网络基础和 Ising 案例部分。https://doi.org/10.1016/j.physrep.2019.03.001
2. **选读**：J. Carrasquilla and R. G. Melko, "Machine Learning Phases of Matter," *Nat. Phys.* **13**, 431–434 (2017). https://doi.org/10.1038/nphys4035

阅读问题

Mehta 等人在 Ising 分类案例中报告的证据链是否包含独立生成组与简单基线？Carrasquilla 与 Melko 的结论按本讲五档主张表应落在哪一档，缺哪一环证据才能升级？

读文献时先找评价分布、生成组划分与基线阶梯，再读准确率。

训练可以很快；
验证必须可辩护。

第 5 讲结束